

Segmentación Semántica Multiclase de Coberturas Urbanas: Comparación entre un Enfoque Basado en Súperpíxeles SLIC y una Arquitectura U-Net

Sara Geraldine Alarcón Prieto
Iván Alberto Lizarazo Salcedo
Joaquín Guillermo Ramírez Gil

Universidad Nacional de Colombia

6 de mayo de 2026

Resumen

Este estudio compara dos paradigmas de segmentación semántica para la clasificación de coberturas urbanas, evaluando su desempeño e implicaciones metodológicas bajo condiciones reales de alta complejidad espacial. Se contrastó un flujo clásico basado en súperpíxeles SLIC acoplado a un clasificador Random Forest con un enfoque de aprendizaje profundo mediante una arquitectura U-Net con codificador preentrenado, en un entorno urbano altamente heterogéneo del municipio de Tunja (Boyacá, Colombia), caracterizado por sombras, oclusión vegetal y diversidad morfológica. La contribución principal radica en la integración explícita de información multifuente ortofoto de muy alta resolución (6 cm), bandas RGB+NIR y datos LiDAR dentro de un marco comparativo controlado espacialmente, lo que permite evaluar no solo la exactitud temática sino también la calidad geométrica de la segmentación. A partir de los datos LiDAR se derivaron DSM, DTM y un modelo normalizado de altura (nDSM), incorporado como variable estructural clave. Metodológicamente, el estudio introduce una partición espacial bloqueada para mitigar la autocorrelación entre subconjuntos, y una estrategia de muestreo ponderado para abordar el desbalance de clases. Los resultados evidencian que la U-Net supera consistentemente al enfoque clásico, alcanzando mayores valores de overall accuracy (0.90 vs 0.86), macro F1 (0.71 vs 0.68) y mean IoU (0.65 vs 0.59), con mejoras sustanciales en la delimitación de contornos (boundary F1: 0.36 vs. 0.16). Bajo condiciones de alta heterogeneidad urbana y evaluación espacialmente controlada, la U-Net preentrenada y adaptada a información multifuente ofrece ventajas temáticas y geométricas claras frente al flujo SLIC–Random Forest, mientras que este último constituye una alternativa viable y de menor costo computacional para contextos con recursos limitados.

Palabras clave: segmentación semántica; súperpíxeles; SLIC; Random Forest; U-Net; aprendizaje profundo; coberturas urbanas; geomática.

Abstract

This study compares two semantic segmentation paradigms for urban land cover classification, evaluating their performance and methodological implications under real-world conditions of high spatial complexity. A classic flow based on SLIC superpixels coupled with a Random Forest classifier was contrasted with a deep learning approach using a U-Net architecture with a pre-trained encoder in a highly heterogeneous urban environment in the municipality of Tunja (Boyacá, Colombia), characterized by shade, vegetation occlusion, and morphological diversity. The main contribution lies in the specific integration of multi-source information—very high-resolution orthophotos (6 cm), RGB+NIR bands, and LiDAR data—within a spatially controlled comparative framework. This allows for the evaluation of not only thematic accuracy but also the geometric quality of the segmentation. DSMs, DTMs, and a normalized height model (nDSM) were derived from the LiDAR data and incorporated as a variable structural key. Methodologically, the study introduces a locked spatial partition to mitigate autocorrelation between subsets and a weighted sampling strategy to address class imbalance. The results show that the U-Net consistently outperforms the classical approach, achieving higher overall accuracy (0.90 vs 0.86), macro F1 (0.71 vs 0.68), and mean IoU (0.65 vs 0.59), with substantial improvements in boundary delineation (F1 limit: 0.36 vs. 0.16). Under conditions of high urban heterogeneity and spatially controlled evaluation, the pre-trained U-Net, adapted to multi-source data, offers clear thematic and geometric advantages over the SLIC–Random Forest flow, while the latter constitutes a viable and less computationally expensive alternative for contexts with limited resources.

Keywords: semantic segmentation; superpixels; SLIC; Random Forest; U-Net; deep learning; urban land cover; geomatics.

1. Introducción

La clasificación precisa de coberturas urbanas a partir de imágenes de muy alta resolución espacial es un insumo estratégico para la actualización catastral, la planificación territorial y la evaluación de riesgo (Persello et al., 2022). En entornos urbanos reales, la segmentación semántica multiclase enfrenta retos sustantivos: alta variabilidad espectral y textural, sombras proyectadas, oclusión vegetal y heterogeneidad morfológica y constructiva. Estos factores incrementan la confusión entre clases y dificultan la generalización entre zonas y fechas de captura (Ma et al., 2019). Durante la última década se ha consolidado un cambio metodológico desde flujos de trabajo clásicos basados en segmentación orientada a objetos (OBIA), extracción manual de características y clasificación supervisada, hacia arquitecturas de aprendizaje profundo capaces de aprender representaciones directamente desde los datos (Wurm et al., 2019).

En el primer paradigma, el algoritmo SLIC (*Simple Linear Iterative Clustering*) genera superpíxeles compactos que equilibran similitud radiométrica y proximidad espacial, preservando bordes de objetos, y mantiene vigencia por su interpretabilidad y bajo costo computacional (Achanta et al., 2012). En el segundo, la arquitectura U-Net, con sus conexiones de salto entre codificador y decodificador, ha demostrado una capacidad superior para recuperar detalle espacial y delinear contornos en escenas complejas (Ronneberger et al., 2015). Sin embargo, el debate metodológico en teledetección no se centra ya en si el aprendizaje profundo funciona, sino en bajo qué condiciones y con qué costo real frente a alternativas clásicas bien diseñadas (Persello et al., 2022).

Una línea de evidencia robusta en teledetección urbana es la fusión de información espectral y altimétrica. Los datos LiDAR permiten derivar modelos digitales de superficie normalizados (nDSM) que mejoran la separabilidad entre clases espectralmente similares cubiertas planas versus copas arbóreas, por ejemplo y su integración como canal adicional en redes profundas o como covariable en clasificadores clásicos tiende a mejorar sistemáticamente el desempeño (Audebert et al., 2018). El banco de datos ISPRS ha establecido comparaciones estandarizadas que confirman este beneficio, aunque su transferibilidad a contextos tropicales con alta heterogeneidad constructiva, como los municipios colombianos, sigue siendo limitada (Wurm et al., 2019).

Un punto metodológico crítico y frecuentemente subestimado es el sesgo por autocorrelación espacial en la evaluación. Bajo partición aleatoria, los conjuntos de entrenamiento y prueba comparten vecindades espaciales, lo que produce estimaciones de desempeño optimistas que no reflejan la capacidad de generalización a zonas realmente no vistas (Kattenborn et al., 2022). La partición espacial bloqueada que garantiza separación geográfica entre subconjuntos es el estándar metodológico recomendado para evaluaciones imparciales en aplicaciones geospaciales (Wadoux et al., 2021). Su omisión puede revertir las conclusiones sobre qué método es superior, constituyendo un sesgo sistemático de gran impacto práctico.

Con base en lo anterior, este estudio aborda la necesidad de comparaciones robustas y reproducibles entre enfoques clásicos y de aprendizaje profundo para la segmentación de coberturas urbanas. Aunque métodos basados en objetos como SLIC y arquitecturas profundas como U-Net han sido ampliamente utilizados, existe un vacío en evaluaciones controladas que eviten sesgos espaciales y que integren simultáneamente el desempeño y el costo computacional (Wadoux et al., 2021).

En este contexto, se plantea la hipótesis de que un modelo de segmentación semántica basado en U-Net supera a un enfoque clásico basado en SLIC en términos de exactitud temática y geométrica, aunque con posibles diferencias en eficiencia computacional e impacto ambiental. En consecuencia, la pregunta de investigación es: *¿un modelo U-Net mejora el desempeño frente a SLIC en la clasificación de coberturas urbanas a partir de imágenes RGB+NIR de alta resolución y datos LiDAR?* Para responder, ambos enfoques se entrenan y evalúan bajo un protocolo consistente y reproducible, empleando el mismo conjunto de datos, área de estudio (Tunja, Colombia), esquema multiclase y partición espacial sin fuga. El desempeño se evalúa considerando no solo la calidad de la segmentación, sino también el costo computacional, el consumo energético y las emisiones, utilizando **CodeCarbon**. El objetivo es establecer una línea base metodológica y cuantitativa para futuros desarrollos, incluyendo la integración de enfoques OBIA y la fusión con datos LiDAR.

2. Datos y métodos

Con el fin de facilitar la comprensión del diseño experimental, la Figura 1 presenta de forma esquemática el flujo metodológico completo del estudio. El diagrama ilustra los dos paradigmas comparados, el método clásico basado en superpíxeles SLIC con clasificador Random Forest (Rama A) y el enfoque de aprendizaje profundo mediante U-Net preentrenada (Rama B) así como las etapas comunes de preprocesamiento, evaluación y análisis de resultados. Ambas ramas comparten los mismos datos de entrada, el mismo esquema de partición espacial y las mismas métricas de evaluación, garantizando un entorno experimental comparable. Los apartados siguientes describen en detalle cada componente del

flujo.




Figura 1: Flujo metodológico SLIC y U-Net.

2.1. Área de estudio e insumos

El estudio se desarrolló sobre un subconjunto representativo de 106 ha del perímetro urbano del municipio de Tunja, Boyacá, Colombia (Figura 2), localizado a aproximadamente 2775 m s. n. m. en el altiplano cundiboyacense. Su emplazamiento en relieve ondulado, con pendientes entre 5.00° y 20.00°, condiciona la geometría de las sombras proyectadas sobre cubiertas y vías, constituyendo una fuente relevante de ambigüedad espectral. El área concentra una alta heterogeneidad de cubiertas: teja cerámica, cubiertas metálicas, fibrocemento, losas de concreto y vegetación arbórea de porte medio, junto con un marcado desbalance de clases, especialmente en la clase agua (menor que el 1 % del área total).




Figura 2: Área de estudio en Tunja, Boyacá, Colombia.

Se utilizaron tres insumos geospaciales con fecha consistente del 19 de enero de 2022 (Anexo A): (i) una ortofoto de cuatro bandas espectrales (R, G, B y NIR) con resolución espacial de 6.024 cm/píxel; (ii) una nube de puntos LiDAR con densidad aproximada de 6.63 pts/m², a partir de la cual se derivaron el modelo digital de superficie (DSM), el modelo digital del terreno (DTM) y el modelo normalizado de superficie (nDSM = DSM – DTM); y (iii) una máscara de referencia multiclase generada a partir de cartografía oficial del IGAC. Los tres insumos comparten la misma grilla ráster (27.538 por 19.589 píxeles, EPSG: MAGNA-SIRGAS CMT12), lo que garantiza correspondencia píxel a píxel sin remuestreo adicional. El uso combinado de ortofotos de muy alta resolución y derivados LiDAR constituye una estrategia establecida para mejorar la separabilidad entre coberturas espectralmente similares (Audebert et al., 2018).

La clasificación se definió como una tarea de segmentación semántica multiclase con cinco categorías: fondo (0), construcción (1), pavimento (2), vegetación (3) y agua (4), empleando el valor 255 como *ignore index*. Las variables de entrada difieren entre métodos: nDSM, R, G, B y NIR se emplearon en ambos enfoques, mientras que el NDVI, definido como $NDVI = \frac{NIR - R}{NIR + R + \epsilon}$, se incorporó exclusivamente como atributo del método clásico, dado que las redes convolucionales profundas pueden aprender implícitamente esta relación espectral (Audebert et al., 2018).

2.2. Protocolo experimental compartido

Ambos métodos operaron bajo el mismo protocolo experimental para garantizar la comparabilidad. El conjunto de datos se particionó mediante una división espacial bloqueada sobre el eje x del ráster (70/15/15 para entrenamiento, validación y prueba), con el fin de reducir el sesgo por autocorrelación espacial que puede producir estimaciones optimistas cuando se emplean particiones aleatorias (Kattenborn et al., 2022). El procesamiento se realizó sobre teselas de 256 por 256 píxeles, sin solapamiento ($stride = 256$). La evaluación final de ambos métodos se realizó sobre el ráster reconstruido a resolución de píxel, garantizando que la comparación entre el método clásico, que opera a nivel de superpíxel, y U-Net, que predice a nivel de píxel, fuera estrictamente equivalente (Y. Chen et al., 2021).

La evaluación final de ambos métodos se realizó sobre el raster reconstruido a resolución de píxel del conjunto de prueba, excluyendo los píxeles con valor 255 (*ignore index*). Se emplearon tres dimensiones de evaluación complementarias: exactitud temática, calidad geométrica de contornos y eficiencia computacional.

La exactitud temática se cuantificó mediante tres métricas: exactitud global (*Overall Accuracy*, OA), macro-F1 y mean IoU (mIoU). La OA se definió como la proporción de píxeles correctamente clasificados sobre el total evaluado; el macro-F1 se calculó como la media aritmética no ponderada del F1 por clase; y la mIoU se definió como la media de la IoU por clase. Para una clase dada, la IoU corresponde al cociente entre la intersección y la unión de las predicciones y las referencias (Long et al., 2015):

$$\begin{aligned} OA &= \frac{\sum_i TP_i}{N}, \\ F1_i &= \frac{2TP_i}{2TP_i + FP_i + FN_i}, \\ IoU_i &= \frac{TP_i}{TP_i + FP_i + FN_i}. \end{aligned} \tag{1}$$

donde TP_i , FP_i y FN_i corresponden, respectivamente, a los verdaderos positivos, falsos positivos y falsos negativos para la clase i , y N representa el total de píxeles evaluados. El uso de métricas macro, sin ponderación por frecuencia de clase, es especialmente relevante en presencia de desbalance, ya que otorga el mismo peso a clases minoritarias como agua y vegetación (Chen et al., 2021). Las métricas se reportan tanto a nivel global como por clase individual, lo que permite analizar el comportamiento diferenciado del modelo para la clase construcción, considerada de mayor interés aplicado, y para aquellas clases con mayor riesgo de confusión espectral.

La calidad geométrica de las segmentaciones se evaluó mediante el índice Boundary-F1 (BF1), el cual combina la precisión de borde (*Boundary Precision*, BP) y la exhaustividad de borde (*Boundary Recall*, BR). Esta métrica permite analizar qué tan bien coinciden los contornos predichos con los contornos de referencia, como se expresa en la Ecuación (2).

$$BF1 = \frac{2BPBR}{BP + BR} \tag{2}$$

donde BP representa la proporción de píxeles de borde predichos que coinciden con los bordes de referencia dentro de una tolerancia espacial definida, y BR representa la proporción de píxeles de borde de referencia que fueron correctamente recuperados por la predicción.

Esta métrica compara los mapas de bordes de la predicción y de la referencia dentro de una banda de tolerancia generada mediante dilatación morfológica. De esta forma, permite identificar casos en los que la predicción es temáticamente correcta, pero presenta imprecisiones geométricas en la delimitación de los objetos (Y. Chen et al., 2021).

El BF1 se calculó en dos niveles: (i) multiclase, sobre las máscaras completas de predicción y referencia; y (ii) binario, específico para la clase construcción (construcción frente a no construcción), dada su relevancia directa para aplicaciones catastrales. Valores más altos de BF1 indican mayor fidelidad geométrica en la delineación de los objetos segmentados.

Finalmente, el desempeño computacional de ambos métodos se registró mediante tiempo de ejecución en segundos para las fases de entrenamiento e inferencia, energía consumida en kWh y emisiones estimadas de CO2 equivalente en kg, instrumentadas con la herramienta CodeCarbon (Schmidt et al., 2021). El experimento basado en U-Net fue ejecutado en un entorno Linux con 16 núcleos físicos, 32 núcleos lógicos, 31.19 GB de RAM y una GPU NVIDIA T1000 de 8 GB, con disponibilidad de CUDA. En contraste, el flujo SLIC + Random Forest se ejecutó como un método clásico basado principalmente en CPU, por lo que los resultados de desempeño computacional deben interpretarse como una comparación operativa bajo las condiciones reales de ejecución de cada enfoque, y no como una comparación estrictamente controlada de hardware. Esta dimensión de evaluación responde al creciente reconocimiento de que el impacto ambiental del entrenamiento de modelos de aprendizaje profundo constituye un criterio relevante en la selección de métodos para aplicaciones geoespaciales a escala (Schwartz et al., 2020).

2.3. Método clásico: SLIC + Random Forest

El método clásico se estructuró como un pipeline orientado a objetos compuesto por tres etapas secuenciales: segmentación no supervisada en superpíxeles, extracción de atributos estadísticos por segmento y clasificación supervisada mediante Random Forest (Hossain & Chen, 2019).

La segmentación se realizó mediante SLIC *Simple Linear Iterative Clustering*, que opera como una adaptación eficiente de *k-means* en un espacio conjunto color-posición, minimizando para cada píxel una distancia compuesta:

La segmentación basada en superpíxeles se realizó mediante el algoritmo SLIC, cuya distancia de agrupamiento combina información radiométrica y espacial, como se expresa en la Ecuación (3).

$$D = \sqrt{d_c^2 + \left(\frac{m}{S}d_s\right)^2} \quad (3)$$

donde d_c es la distancia de color, d_s es la distancia espacial euclidiana, S es el paso de muestreo asociado al tamaño esperado del superpíxel y m es el parámetro de compactación que regula el equilibrio entre similitud radiométrica y proximidad espacial (Achanta et al., 2012).

La segmentación operó exclusivamente sobre los canales RGB de la ortofoto, con conversión previa al espacio de color CIELAB mediante el parámetro `convert2lab = True`, con el fin de mejorar la homogeneidad perceptual. La incorporación directa del canal HEIGHT en esta etapa tendió a sobrefragmentar coberturas y a suavizar bordes relevantes entre clases con diferencias altimétricas moderadas; por esta razón, dicho canal fue excluido de la segmentación y reservado para la etapa posterior de clasificación. La

configuración adoptada fue `n_segments = 500`, `compactness = 1.0`, `sigma = 1.0` y `enforce_connectivity = True`, garantizando segmentos espacialmente conexos. Cada tesela de 256 por 256 píxeles fue segmentada de forma independiente, como se resume en el Anexo B.

Para cada superpíxel se construyó un vector de 43 atributos. Cuarenta y dos de ellos se obtuvieron calculando siete estadísticos de resumen media, mediana, desviación estándar, mínimo, máximo, percentil 25 y percentil 75 sobre seis variables espectrales y altimétricas: las bandas R, G, B y NIR, la altura normalizada derivada del nDSM (HEIGHT) y el Índice de Vegetación de Diferencia Normalizada (NDVI) (figura a1). El atributo restante corresponde al área del superpíxel expresada en número de píxeles (`area_px`), que aporta información sobre el tamaño relativo de cada región homogénea. El NDVI es ampliamente empleado en teledetección para cuantificar la presencia y el vigor de la vegetación, aprovechando el contraste entre la elevada reflectancia de la vegetación sana en el infrarrojo cercano y su menor respuesta en la banda roja del espectro visible (Rouse et al., 1974). Su expresión es la siguiente:

$$\text{NDVI} = \frac{\text{NIR} - \text{R}}{\text{NIR} + \text{R} + \epsilon} \quad (4)$$

donde NIR corresponde al valor espectral de la banda del infrarrojo cercano, R corresponde al valor espectral de la banda roja visible y ϵ es un término de estabilidad numérica incorporado para evitar divisiones por cero cuando la suma $\text{NIR} + \text{R}$ toma valores muy bajos o nulos.

En términos generales, el NDVI tiende a presentar valores más altos en coberturas vegetales, mientras que superficies urbanas, suelo desnudo, agua o sombras suelen presentar valores menores o cercanos a cero, dependiendo de las condiciones radiométricas de la imagen. El NDVI fue incorporado exclusivamente como atributo estadístico del clasificador; no fue utilizado como canal de entrada en la etapa de segmentación ni en ninguno de los experimentos U-Net. Adicionalmente, se incluyó el área del superpíxel, expresada en píxeles, como atributo geométrico. Los superpíxeles con menos de 20 píxeles válidos o con una proporción de píxeles válidos inferior al 50 por ciento fueron excluidos del entrenamiento y la evaluación, preservándose sus píxeles con valor 255 en el ráster de salida.

La etiqueta de cada superpíxel se asignó por mayoría sobre la máscara de referencia, excluyendo los píxeles con valor 255 (*ignore index*). La clasificación supervisada se realizó con Random Forest (Belgiu & Drăguț, 2016), con la siguiente configuración: `n_estimators = 300`, `max_depth = 30`, `min_samples_leaf = 2`, `max_features = sqrt`, `class_weight = balanced` y `random_state = 42`. El parámetro `class_weight = balanced` ajustó automáticamente los pesos de cada clase de forma inversamente proporcional a su frecuencia, mitigando el desbalance documentado entre clases (Anexo C). El modelo fue entrenado exclusivamente con los superpíxeles del conjunto de entrenamiento y validado sobre la partición de validación; el conjunto de prueba no participó en ninguna decisión de ajuste. No se realizó búsqueda exhaustiva de hiperparámetros para preservar la comparabilidad con U-Net y evitar ventajas asimétricas entre métodos.

Durante la inferencia, la predicción del clasificador fue proyectada de vuelta al espacio raster mediante una tabla de búsqueda, asignando a cada píxel la clase predicha para el superpíxel al que pertenece. Este paso garantiza que la evaluación del método clásico se realice a resolución de píxel sobre el mismo raster de prueba que U-Net, condición necesaria para que las métricas de exactitud temática y geométrica sean estrictamente comparables entre métodos (Y. Chen et al., 2021). La implementación utilizó scikit-learn

(Pedregosa et al., 2011).

2.4. Método de aprendizaje profundo: U-Net con encoder preentrenado

El método de aprendizaje profundo se implementó mediante una arquitectura U-Net (Ronneberger et al., 2015) con encoder ResNet34 preentrenado en ImageNet (He et al., 2016), instanciada a través de la librería `segmentation_models_pytorch`. La arquitectura sigue un esquema encoder-decoder con conexiones de salto (skip connections) que preservan información espacial de alta resolución a lo largo del decodificador, permitiendo al modelo capturar simultáneamente contexto semántico de alto nivel y detalle geométrico de bajo nivel capacidad especialmente relevante en escenas urbanas de muy alta resolución donde la precisión de los contornos es crítica (Ronneberger et al., 2015). Se evaluaron dos configuraciones experimentales bajo el mismo protocolo: un experimento control RGB con tres canales de entrada (24436949 parámetros entrenables) y un experimento multifuente con cinco canales R, G, B, NIR y HEIGHT (nDSM) (24443221 parámetros entrenables).

Para el experimento multifuente, la primera capa convolucional del encoder fue adaptada para aceptar cinco canales de entrada. Los pesos correspondientes a los canales R, G y B fueron inicializados con los valores preentrenados en ImageNet, mientras que los canales NIR y HEIGHT fueron inicializados mediante la media de los pesos preentrenados del primer bloque convolucional. Esta estrategia de inicialización permite aprovechar el conocimiento transferido desde ImageNet mientras se adapta el modelo a las nuevas fuentes de información, y ha demostrado ser más estable que la inicialización aleatoria en tareas de fusión multimodal con datos de teledetección (Audebert et al., 2018). El NDVI no fue incorporado como canal de entrada en ninguna de las dos configuraciones, dado que las redes convolucionales profundas pueden aprender implícitamente las relaciones espectrales equivalentes a partir de los canales NIR y R directamente (Audebert et al., 2018).

Previo al entrenamiento se aplicó una rutina de saneamiento y normalización sobre los insumos, cuyos parámetros se estimaron exclusivamente a partir del conjunto de entrenamiento para evitar fuga de información (Kattenborn et al., 2022). Las bandas R, G, B y NIR fueron escaladas mediante los percentiles 2 y 98 del conjunto de entrenamiento. El canal HEIGHT fue recortado con los percentiles 1 y 99 (intervalo [0.33, 18] m) y estandarizado a media cero y varianza unitaria ($\mu = 3,79$ m, $\sigma = 6,08$ m). El desbalance de clases se abordó mediante dos mecanismos complementarios: pesos por clase en la función de pérdida y un `WeightedRandomSampler` sobre las teselas de entrenamiento, que incrementó la representación relativa de vegetación de 2.96 % a 8.40 % y de agua de 0.28 % a 0.82 % (Buda et al., 2018).

Ambos experimentos se entrenaron bajo la misma configuración (Anexo E y Anexo F). La función de pérdida fue *CrossEntropyLoss* con `ignore_index = 255`. La optimización se realizó con AdamW (Loshchilov & Hutter, 2019) con tasa de aprendizaje inicial de $1 \cdot 10^{-4}$, `weight_decay = 1 \cdot 10^{-4}` y gradient clipping con norma máxima de 1.0. La tasa de aprendizaje se ajustó dinámicamente mediante *ReduceLROnPlateau* con factor de reducción de 0.5 y paciencia de 3 épocas. El entrenamiento se detuvo por early stopping con paciencia de 7 épocas, monitoreando `val_mean_iou` como métrica principal por su sensibilidad al desbalance de clases. El tamaño de lote fue de 8 teselas por iteración. El experimento control RGB alcanzó su mejor modelo en la época 11 (`val_mean_iou = 0.67`) y se detuvo en la época 11. El experimento multifuente alcanzó su mejor modelo en la época

14 ($\text{val_mean_iou} = 0.68$) y se detuvo en la época 21 (Anexo G). La implementación se realizó en PyTorch (Paszke et al., 2019) con aceleración GPU mediante CUDA.

3. Resultados

La Figura 3 presenta la comparación directa de desempeño entre el método clásico SLIC + Random Forest y la arquitectura U-Net sobre el mismo conjunto de prueba, bajo el mismo protocolo de evaluación espacialmente controlado. U-Net multifuente superó en todas las métricas evaluadas, confirmando la jerarquía esperada. Sin embargo, la magnitud de las diferencias varía sustancialmente según la dimensión considerada: las mejoras en exactitud temática son moderadas, mientras que las diferencias en exactitud geométrica son sustanciales, con el *Boundary F1* de construcción más que duplicándose entre el método clásico (0.252) y U-Net multifuente (0.561).




Figura 3: Comparación global SLIC + Random Forest vs U-Net.

3.1. Desempeño temático y geométrico

La Figura 3 evidencia el desempeño por clase y los indicadores globales para ambos métodos. El análisis por clase revela un patrón consistente con la distribución de clases y la complejidad espectral del área de estudio. La clase construcción obtuvo el mejor desempeño individual en ambos métodos: $F_1 = 0.948$ e $\text{IoU} = 0.901$ en SLIC+RF, y $F_1 = 0.961$ e $\text{IoU} = 0.922$ en U-Net multifuente, lo que refleja que la información altimétrica del nDSM favorece especialmente la discriminación de superficies elevadas respecto al suelo. Esta interpretación es consistente con el análisis de importancia de variables del Random Forest (Anexo C), donde los cinco atributos más importantes corresponden a estadísticos del canal HEIGHT: $\text{HEIGHT_p25} = 0.062$, $\text{HEIGHT_mean} = 0.056$, $\text{HEIGHT_min} = 0.055$, $\text{HEIGHT_median} = 0.044$ y $\text{HEIGHT_max} = 0.040$, concentrando en conjunto el 23.8 por ciento de la importancia total del modelo (Mo et al., 2019).

Las clases fondo y pavimento mostraron desempeños aceptables en ambos métodos, con valores de precisión y recall equilibrados que sugieren discriminación consistente. La clase vegetación presentó un comportamiento diferenciado: en SLIC+RF, el recall (0.673)

fue inferior a la precisión (0.737), indicando que una proporción de píxeles de vegetación fue clasificada erróneamente como otras coberturas en zonas de sombra o vegetación baja (Anexo H); en U-Net multifuente, esta tendencia se invierte (recall = 0.861, precisión = 0.802), lo que sugiere una ligera sobreclasificación de vegetación que puede atribuirse a la incorporación del canal NIR.

La clase agua no fue recuperada de forma significativa por ninguno de los dos métodos: $F1 = 0.064$ en SLIC+RF y $F1 = 0.000$ en U-Net multifuente. Este resultado es consecuencia directa de su representación extremadamente escasa, menor que 1 % del área de prueba, y de su similitud radiométrica con superficies oscuras como sombras y pavimento húmedo. Cabe notar que la variante U-Net RGB obtuvo un $F1$ ligeramente mayor para agua (0.032) que la variante multifuente (0.0004), resultado que podría explicarse por la interferencia del canal HEIGHT en la caracterización de cuerpos de agua, cuyos valores de nDSM tienden a cero o negativos y pueden generar confusión con otras superficies planas.

La ventaja de U-Net multifuente es especialmente pronunciada en la dimensión geométrica. *El Boundary F1* multiclase aumentó en 0.194 puntos respecto al método clásico (de 0.168 a 0.362), y el *El Boundary F1* específico para construcción aumentó en 0.310 puntos (de 0.252 a 0.561). Estos resultados son coherentes con la naturaleza de cada método: el flujo clásico opera a nivel de superpíxel y la precisión geométrica está acotada por la granularidad de la segmentación SLIC, produciendo bordes angulares propios de los límites de los segmentos; U-Net aprende directamente a nivel de píxel y genera contornos espacialmente más continuos y coherentes con los límites reales de las coberturas (Y. Chen et al., 2021). Esta diferencia es ilustrada en el Anexo I, que muestran predicciones representativas de los tres métodos sobre el conjunto de prueba.

La incorporación de los canales NIR y HEIGHT en el experimento multifuente produjo mejoras consistentes respecto al control RGB en todas las métricas. Las curvas de entrenamiento de ambos experimentos U-Net (Anexo J y Anexo K) mostraron convergencia estable sin señales de sobreajuste severo. El experimento RGB alcanzó su mejor modelo en la época 11 ($\text{val_mean_iou} = 0.674$, detenido en época 18) y el experimento multifuente en la época 14 ($\text{val_mean_iou} = 0.689$, detenido en época 21), con una convergencia ligeramente más lenta que confirma el mayor costo de aprender representaciones sobre cinco canales heterogéneos. La matriz de confusión normalizada del experimento multifuente (9) revela los principales patrones de error: fondo se confunde en un 8 % con pavimento, construcción en un 4 % con fondo, y vegetación en un 12 % con fondo, todos consistentes con la similitud espectral y las condiciones de sombra del área de estudio.

3.2. Eficiencia computacional e impacto ambiental

El análisis computacional revela un balance asimétrico con implicaciones prácticas relevantes. En la fase de entrenamiento, SLIC+RF demandó únicamente 56.7 s frente a los 4.368,7 s de U-Net multifuente una diferencia de aproximadamente 77 veces con disparidades equivalentes en consumo energético (0.000828 vs 0.065750 kWh) y emisiones (0.000150 vs 0.011946 kg CO₂eq). Sin embargo, el comportamiento se invierte de forma notable durante la inferencia: U-Net completó la predicción sobre el conjunto de prueba en 18.8 s frente a los 317.1 s de SLIC+RF 17 veces más rápido con un consumo energético y emisiones significativamente menores (0.000283 kWh y 0.000052 kg CO₂eq vs 0.004802 kWh y 0.000872 kg CO₂eq). Este resultado contraintuitivo tiene una implicación práctica directa: en escenarios de producción donde el modelo se entrena una vez y se aplica repetidamente sobre nuevas imágenes, la eficiencia de inferencia de U-Net re-

presenta una ventaja operativa significativa que compensa parcialmente su mayor costo inicial de entrenamiento (Schwartz et al., 2020).




Figura 4: Eficiencia computacional e impacto ambiental.

4. Discusión

4.1. Respuesta a la pregunta de investigación y comparación de métodos

Los resultados permiten responder afirmativamente la pregunta de investigación: U-Net multifuente superó al flujo clásico SLIC + Random Forest en todas las dimensiones evaluadas bajo un protocolo espacialmente controlado. Sin embargo, la magnitud de esta superioridad varía según la dimensión considerada. Las mejoras en exactitud temática son moderadas (+0.038 OA, +0.031 macro F1, +0.056 mean IoU), lo que sugiere que un flujo clásico bien diseñado con variables altimétricas y espectrales puede aproximarse al desempeño temático de una arquitectura profunda preentrenada en las clases dominantes hallazgo coherente con Persello et al. (2022), quienes argumentan que el debate en tele-detección debería centrarse no en si el aprendizaje profundo funciona, sino en bajo qué condiciones y con qué costo real.

La ventaja de U-Net es estructuralmente más pronunciada en la dimensión geométrica, donde el *Boundary* F1 de construcción más que se duplicó ($0.252 \rightarrow 0.561$). Esta diferencia es explicable por la naturaleza de cada método: el flujo clásico opera a nivel de superpíxel y la precisión geométrica está acotada por la granularidad de la segmentación SLIC, mientras que U-Net aprende representaciones directamente a nivel de píxel (Y. Chen et al., 2021). Para aplicaciones de actualización catastral y cartografía base urbana, donde la precisión posicional de los objetos es un criterio de calidad fundamental, esta diferencia geométrica es el hallazgo más relevante del estudio.

La comparación entre el experimento control RGB y el experimento multifuente confirma el aporte informativo del NIR y el nDSM como canales de entrada, con mejoras consistentes en todas las métricas. No obstante, el resultado contraintuitivo en la clase agua donde la variante multifuente obtuvo un F1 inferior a la variante RGB (0.000 vs 0.032) podría explicarse por la interferencia del canal HEIGHT en superficies con valores de nDSM cercanos a cero, como cuerpos de agua o pavimento húmedo, y constituye una línea de análisis futura.

4.2. Influencia de los datos, las clases y las etiquetas

El bajo desempeño en la clase agua refleja una limitación estructural que trasciende la elección metodológica: con menos del 1 % del área de prueba, las estrategias de balance adoptadas fueron insuficientes para compensar una representación tan marginal. Estrategias más agresivas como *focal loss* (Lin et al., 2017) o sobremuestreo sintético podrían mitigar este efecto en experimentos futuros. Este resultado ilustra además un riesgo frecuente en evaluaciones con desbalance: las métricas globales como OA tienden a reflejar principalmente el desempeño en clases dominantes, mientras que el macro F1 hace visible el bajo desempeño en clases minoritarias (Y. Chen et al., 2021).

Un factor estructural que afecta la evaluación de ambos métodos es la discrepancia entre las etiquetas cartográficas y lo observable en la imagen aérea. La máscara de referencia representa huellas catastrales en planta, mientras que la ortofoto captura techos con voladizos, aleros y oclusiones vegetales que superan el perímetro catastral. Este desajuste introduce ruido sistemático en los bordes de los objetos, lo que podría explicar parcialmente los valores moderados de *Boundary* F1 observados en ambos métodos, independientemente de su capacidad real de delineación (Wurm et al., 2019). La adopción de partición espacial bloqueada garantiza que los valores reportados sean estimaciones conservadoras del desempeño real sobre zonas no vistas, más representativas de condiciones de producción que las obtenidas bajo partición aleatoria (Kattenborn et al., 2022).

4.3. Desempeño computacional, limitaciones e implicaciones geomáticas

El balance computacional entre métodos tiene implicaciones prácticas que van más allá de la comparación metodológica. Aunque U-Net demanda aproximadamente 77 veces más tiempo y energía en entrenamiento, su inferencia es 17 veces más rápida que el flujo clásico. En escenarios de producción cartográfica donde el modelo se entrena una vez y se aplica sistemáticamente sobre nuevas imágenes, esta eficiencia de inferencia puede compensar el mayor costo inicial. La medición del impacto ambiental mediante CodeCarbon responde al creciente reconocimiento de que la huella de carbono del entrenamiento debe considerarse como criterio de selección en aplicaciones geoespaciales a escala (Schwartz et al., 2020).

Las principales limitaciones del estudio son: la restricción a 106 ha de un único municipio, que limita la evaluación de transferibilidad; la ausencia de búsqueda exhaustiva de hiperparámetros en SLIC+RF, que podría subestimar marginalmente su potencial; y la no comparación con arquitecturas más recientes como DeepLabv3+ (L.-C. Chen et al., 2018) o modelos basados en transformadores, que han demostrado superar a U-Net estándar en varios *benchmarks* de segmentación urbana. Los resultados establecen una línea base metodológica reproducible para clasificación urbana de alta resolución en contextos latinoamericanos dominio subrepresentado respecto a los *benchmarks* europeos ISPRS y abren rutas concretas de investigación: evaluación de estrategias de balance más agresivas para clases minoritarias, exploración de fusión tardía del nDSM, y validación de los modelos sobre otras zonas del municipio para estimar la transferibilidad intra-urbana bajo condiciones de alta heterogeneidad constructiva.

5. Conclusiones

Este estudio demostró que una arquitectura U-Net con codificador ResNet34 preentrenado y entrada multifuente (RGB+NIR+nDSM) supera a un flujo clásico SLIC + Random Forest en la clasificación de coberturas urbanas a partir de imágenes aéreas de muy alta resolución en Tunja, Colombia, bajo un protocolo de evaluación espacialmente controlado. La ventaja más significativa no reside en la exactitud temática global donde las diferencias son moderadas (+0.038 OA, +0.056 mean IoU) sino en la precisión geométrica de los contornos predichos, donde el *Boundary F1* para construcción más que se duplicó (0.252 $\rightarrow$ 0.561), resultado de especial relevancia para aplicaciones de actualización catastral y cartografía base urbana. El análisis computacional reveló un balance asimétrico: aunque U-Net demanda un costo de entrenamiento aproximadamente 77 veces mayor, su inferencia es 17 veces más rápida que el flujo clásico, lo que favorece su adopción en escenarios de producción de alto volumen. La incapacidad de ambos métodos para recuperar la clase agua evidencia que el desbalance extremo de clases minoritarias constituye el principal reto no resuelto del experimento, y motiva el desarrollo de estrategias de balance más agresivas y la exploración de arquitecturas más recientes como DeepLabv3+ o modelos basados en transformadores de visión. Los resultados establecen una línea base metodológica y cuantitativa reproducible para la clasificación urbana de alta resolución en contextos latinoamericanos de alta heterogeneidad, contribuyendo a un dominio subrepresentado respecto a los *benchmarks* europeos disponibles en la literatura.

Disponibilidad de código, datos y resultados

El código, los notebooks, los archivos de configuración del entorno computacional y los resultados derivados de los experimentos se encuentran disponibles en el [Repositorio público](#) del proyecto:

El repositorio incluye los recursos necesarios para reproducir el flujo experimental desarrollado en este estudio, incluyendo notebooks, resultados del enfoque basado en superpíxeles SLIC, resultados del enfoque basado en U-Net y archivos de configuración para el despliegue local del ambiente de trabajo mediante Docker.

Referencias

- Achanta, R., Shaji, A., Smith, K., Lucchi, A., Fua, P., & Süsstrunk, S. (2012). SLIC Superpixels Compared to State-of-the-Art Superpixel Methods. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 34 (11), 2274-2282. <https://doi.org/10.1109/TPAMI.2012.120>
- Audebert, N., Le Saux, B., & Lefèvre, S. (2018). Beyond RGB: Very high resolution urban remote sensing with multimodal deep networks [Geospatial Computer Vision]. *ISPRS Journal of Photogrammetry and Remote Sensing*, 140, 20-32. <https://doi.org/https://doi.org/10.1016/j.isprsjprs.2017.11.011>
- Belgiu, M., & Drăguț, L. (2016). Random forest in remote sensing: A review of applications and future directions. *ISPRS Journal of Photogrammetry and Remote Sensing*, 114, 24-31. <https://doi.org/https://doi.org/10.1016/j.isprsjprs.2016.01.011>

- Buda, M., Maki, A., & Mazurowski, M. A. (2018). A systematic study of the class imbalance problem in convolutional neural networks. *Neural Networks*, 106, 249-259. <https://doi.org/https://doi.org/10.1016/j.neunet.2018.07.011>
- Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., & Adam, H. (2018). Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation. En V. Ferrari, M. Hebert, C. Sminchisescu & Y. Weiss (Eds.), *Computer Vision – ECCV 2018* (pp. 833-851). Springer International Publishing.
- Chen, Y., Liu, X., Xiao, Y., Zhao, Q., & Wan, S. (2021). Three-Dimensional Urban Land Cover Classification by Prior-Level Fusion of LiDAR Point Cloud and Optical Imagery. *Remote Sensing*, 13(23). <https://doi.org/10.3390/rs13234928>
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778. <https://doi.org/10.1109/CVPR.2016.90>
- Hossain, M. D., & Chen, D. (2019). Segmentation for Object-Based Image Analysis (OBIA): A review of algorithms and challenges from remote sensing perspective. *ISPRS Journal of Photogrammetry and Remote Sensing*, 150, 115-134. <https://doi.org/https://doi.org/10.1016/j.isprsjprs.2019.02.009>
- Kattenborn, T., Schiefer, F., Frey, J., Feilhauer, H., Mahecha, M. D., & Dormann, C. F. (2022). Spatially autocorrelated training and validation samples inflate performance assessment of convolutional neural networks. *ISPRS Open Journal of Photogrammetry and Remote Sensing*, 5, 100018. <https://doi.org/https://doi.org/10.1016/j.ophoto.2022.100018>
- Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. *2017 IEEE International Conference on Computer Vision (ICCV)*, 2999-3007. <https://doi.org/10.1109/ICCV.2017.324>
- Long, J., Shelhamer, E., & Darrell, T. (2015). Fully convolutional networks for semantic segmentation. *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 3431-3440. <https://doi.org/10.1109/CVPR.2015.7298965>
- Ma, L., Liu, Y., Zhang, X., Ye, Y., Yin, G., & Johnson, B. A. (2019). Deep learning in remote sensing applications: A meta-analysis and review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 152, 166-177. <https://doi.org/https://doi.org/10.1016/j.isprsjprs.2019.04.015>
- Mo, Y., Zhong, R., Sun, H., Wu, Q., Du, L., Geng, Y., & Cao, S. (2019). Integrated Airborne LiDAR Data and Imagery for Suburban Land Cover Classification Using Machine Learning Methods. *Sensors*, 19(9). <https://doi.org/10.3390/s19091996>
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Kopf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., ... Chintala, S. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. En *Advances in Neural Information Processing Systems* (pp. 8024-8035, Vol. 32). Curran Associates, Inc. <https://papers.nips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12(85), 2825-2830.
- Persello, C., Wegner, J. D., Hänsch, R., Tuia, D., Ghamisi, P., Koeva, M., & Camps-Valls, G. (2022). Deep Learning and Earth Observation to Support the Sustaina-

- ble Development Goals: Current approaches, open challenges, and future opportunities. *IEEE Geoscience and Remote Sensing Magazine*, 10(2), 172-200. <https://doi.org/10.1109/MGRS.2021.3136100>
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. En N. Navab, J. Hornegger, W. M. Wells & A. F. Frangi (Eds.), *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015* (pp. 234-241). Springer International Publishing.
- Rouse, J. W., Haas, R. H., Schell, J. A., Deering, D. W., & Harlan, J. C. (1974). *Monitoring the Vernal Advancement and Retrogradation of Natural Vegetation* (Technical Report) (NASA/GSFC Type III Final Report). National Aeronautics y Space Administration, Goddard Space Flight Center. Greenbelt, Maryland.
- Schmidt, V., Goyal, K., Joshi, A., Feld, B., Conell, L., Laskaris, N., Blank, D., Wilson, J., Friedler, S., & Luccioni, S. (2021). *CodeCarbon: Estimate and Track Carbon Emissions from Machine Learning Computing* [Software]. Zenodo. <https://doi.org/10.5281/zenodo.4658424>
- Schwartz, R., Dodge, J., Smith, N. A., & Etzioni, O. (2020). Green AI. *Communications of the ACM*, 63(12), 54-63. <https://doi.org/10.1145/3381831>
- Wadoux, A. M.-C., Heuvelink, G. B., de Bruin, S., & Brus, D. J. (2021). Spatial cross-validation is not the right way to evaluate map accuracy. *Ecological Modelling*, 457, 109692. <https://doi.org/https://doi.org/10.1016/j.ecolmodel.2021.109692>
- Wurm, M., Stark, T., Zhu, X. X., Weigand, M., & Taubenböck, H. (2019). Semantic segmentation of slums in satellite images using transfer learning on fully convolutional neural networks. *ISPRS Journal of Photogrammetry and Remote Sensing*, 150, 59-69. <https://doi.org/https://doi.org/10.1016/j.isprsjprs.2019.02.006>

Anexo A. Alineamientos

Tabla Anexo A.1: Características principales de los insumos geospaciales utilizados en el estudio.

Característica	Ortofoto (RGB+NIR)	nDSM	Máscara de referencia
Archivo	orto_clip.tif	ndsm_clip_corr0.tif	mask_multiclase_v3.tif
Número de bandas	4 (R, G, B, NIR)	1	1
Dimensiones (filas por columnas)	27 538 por 19 589	27 538 por 19 589	27 538 por 19 589
Tipo de dato	uint16	float32	uint8
Resolución espacial (m/píxel)	0.0602	0.0602	0.0602
Sistema de referencia	EPSG: MAGNA-SIRGAS CMT12	EPSG: MAGNA-SIRGAS CMT12	EPSG: MAGNA-SIRGAS CMT12
Valor nodata	65535	-3.40e38	255
Extensión Oeste (m)	4960 588.34	4960 588.34	4960 588.34
Extensión Norte (m)	2 172 054.84	2 172 054.84	2 172 054.84
Extensión Este (m)	4961 768.44	4961 768.44	4961 768.44
Extensión Sur (m)	2 170 395.87	2 170 395.87	2 170 395.87

Anexo B. Configuración del método SLIC

Tabla Anexo B.1: Parámetros del método SLIC.

Parámetro	Valor ejecutado	Observación
Algoritmo	SLIC	Segmentación por superpíxeles.
Canales usados para SLIC	RGB	La variable HEIGHT no se usó para generar los superpíxeles.
n_segments	500	Número esperado de segmentos por tesela.
compactness	1.0	Controla la regularidad espacial del superpíxel.
sigma	1.0	Suavizado previo aplicado durante la segmentación.
start_label	1	Etiquetado de segmentos desde 1.
channel_axis	-1	Indica que los canales se encuentran al final del arreglo.
convert2lab	True	Aplicado por tratarse de una entrada RGB.
enforce_connectivity	True	Mantiene la conectividad espacial de los superpíxeles.
HEIGHT dentro de SLIC	No	HEIGHT se usó como atributo posterior para la clasificación.
NDVI dentro de SLIC	No	NDVI se usó como atributo posterior para la clasificación.

Anexo C. Importancia de variables Random Forest




Figura 5: Importancia de variables Random Forest método SLIC.

Anexo D. Configuración Random Forest

Tabla Anexo D.1: Hiperparámetros ejecutados para el clasificador Random Forest.

Hiperparámetro	Valor ejecutado	Observación
Modelo	RandomForestClass	Clasificador supervisado usado sobre atributos por superpíxel.
n_estimators	300	Número de árboles del bosque.
max_depth	30	Profundidad máxima permitida para cada árbol.
min_samples_leaf	2	Número mínimo de muestras requeridas en una hoja.
max_features	sqrt	Número de variables consideradas en cada división.
class_weight	balanced	Manejo del desbalance entre clases.
random_state	42	Semilla usada para favorecer la reproducibilidad.
n_jobs	-1	Uso de todos los núcleos disponibles.
Variables predictoras	43	Atributos derivados por superpíxel.

Anexo E. Configuración del modelo U-Net

Tabla Anexo E.1: Configuración general Modelo U-Net.

Componente	Configuración RGB	Configuración multifuente
Arquitectura	U-Net	U-Net
Librería	segmentation_models_ pytorch	segmentation_models_ pytorch
Encoder	ResNet34	ResNet34
Pesos preentrenados	ImageNet	ImageNet adaptado
Canales de entrada	3	5
Variables de entrada	RGB	RGB + NIR + HEIGHT
Clases de salida	5	5
Activación final	None	None
Tamaño de parche	256 por 256	256 por 256
Batch size	8	8
Entrenamiento desde cero	No	No
Encoder preentrenado	Sí	Sí
Adaptación de primera convolución	No aplica	Sí, de 3 a 5 canales

Anexo F. Hiperparámetros de entrenamiento modelo U-Net

Tabla Anexo F.1: Configuración de entrenamiento del modelo U-Net.

Hiperparámetro	Valor
Función de pérdida	CrossEntropyLoss
ignore_index	255
Pesos de clase	Sí
Muestreo ponderado	WeightedRandomSampler
Optimizador	AdamW
Learning rate inicial	0.0001
weight_decay	0.0001
Scheduler	ReduceLROnPlateau
Métrica monitoreada	val_mean_iou
Early stopping	Sí
Paciencia early stopping	7 épocas
Épocas máximas	25
AMP	False

Anexo G. Resultados experimentos RGB y multifuente

Tabla Anexo G.1: Resultados experimentos RGB y multifuente.


#	Experimento	Best epoch	Val loss	Val acc	Val macro F1	Val mean IoU
0	RGB control	11	0.254346	0.927499	0.735461	0.674228
1	RGB+NIR+HEIGHT	14	0.245608	0.939322	0.738886	0.686959

Anexo H. Métricas por clase del método SLIC+RF


Tabla Anexo H.1: Métricas por clase sobre test método clásico.

clase_id	clase_nombre	precision	recall	f1	iou	support_true_px	support_pred_px
0	fondo	0.865013	0.872086	0.868535	0.767620	14551670	14670660
1	construccion	0.953078	0.942736	0.947879	0.900922	4976760	4922757
2	pavimento	0.833732	0.846486	0.840061	0.724228	8738499	8872171
3	vegetacion	0.737003	0.672736	0.703404	0.542501	1147940	1047838
4	agua	0.307439	0.035956	0.064382	0.033262	111610	13053


Anexo I. Predicción sobre el conjunto de prueba



(a) Predicción método clásico.



(b) Predicción método U-Net RGB.



(c) Predicción método U-Net multifunción.

Figura 6: Predicciones sobre el conjunto de prueba.

Anexo J. Curvas de entrenamiento RGB




Figura 7: Curvas de entrenamiento experimento RGB.

Anexo K. Curvas de entrenamiento multifuente




Figura 8: Curvas de entrenamiento experimento multifuente.

Anexo L. Matriz de confusión experimento multifuente




Figura 9: Matriz de confusión normalizada experimento multifuente.

Anexo M. Métricas finales métodos evaluados

Tabla Anexo M.1: Comparación global de métricas entre los métodos evaluados.

Método	OA	Macro F1	Mean IoU	BF1 Constr.
SLIC + RF	0.8655	0.6849	0.5937	<i>0.252</i>
U-Net RGB	0.8788	0.7022	0.6197	0.4596
U-Net Multi	0.904	0.7158	0.6496	0.5614

Anexo N. Desempeño computacional final

Tabla Anexo N.1: Desempeño computacional final.

#	metrica	slic_rf	UNET_multifuente	UNET_menos_slic_rf
0	overall_acc	0.865507	0.903976	0.038469
1	macro_f1	0.684852	0.715829	0.030977
2	mean_iou	0.593707	0.649553	0.055846
3	f1_construccion	0.947879	0.959620	0.011741
4	iou_construccion	0.900922	0.922374	0.021452
5	boundary_f1_multiclass	0.167865	0.362221	0.194356
6	boundary_f1_construccion	0.251661	0.561411	0.309750
7	train_wall_time_sec	56.698058	4368.701700	4312.003640
8	train_energy_kwh	0.000828	0.065750	0.064922
9	train_emissions_kgco2eq	0.000150	0.011946	0.011796
10	test_wall_time_sec	317.083823	18.827658	-298.256165
11	test_energy_kwh	0.004802	0.000283	-0.004519
12	test_emissions_kgco2eq	0.000872	0.000052	-0.000820