

CONTROL DE CAMBIOS		
FECHA DE MODIFICACIÓN	SECCIÓN	DESCRIPCIÓN DEL CAMBIO
17/02/2026	Introducción Pregunta de investigación	Se actualiza la introducción del artículo de Seminario 2 en coherencia con los ajustes metodológicos discutidos, cambiando el enfoque de la comparación entre tres arquitecturas de deep learning a una evaluación controlada entre un método clásico basado en superpíxeles (SLIC) y un método de deep learning para segmentación semántica multiclase, utilizando datos del municipio de Tunja. Asimismo, se somete a revisión la formulación del problema, la justificación del caso de estudio, la pertinencia de la pregunta de investigación especialmente en términos de desempeño y costo-beneficio del uso de deep learning y posibles mejoras en estructura, alcance, soporte teórico y diseño experimental.
23/02/2026	Introducción Datos y métodos	Se actualiza el documento incorporando las correcciones sugeridas principalmente en redacción y referencias, así como la inclusión del abstract y la sección de datos y métodos para revisión previa. Adicionalmente, se anexa un diagrama de flujo preliminar del procedimiento metodológico.
24/02/2026	Datos y métodos	Se realizaron correcciones en la redacción, el ajuste del workflow, la inclusión de algunas ecuaciones que estaban faltando y la modificación de varias figuras.
13/03/2026	Pregunta de investigación Modelo conceptual Datos Flujo de procesos Resultados	Se planteó pregunta de investigación final y se ajustaron los datos en relación a las figuras y se anexan resultados del primer modelo clásico.
27/03/2026	Datos y métodos resultados	En esta versión se incorporaron varios ajustes frente al documento anterior. En particular, se amplió la explicación sobre cómo se evaluará el desempeño de los métodos bajo un entorno comparable, se precisaron conceptos clave asociados a las fórmulas y variables empleadas, tales como DSM, DTM, NDVI, R, G, B y NIR, y se complementaron aspectos faltantes del método clásico basado en SLIC. Asimismo, se incluyó mayor detalle sobre las métricas de textura que se utilizarán junto con sus ecuaciones, y se fortaleció la descripción del modelo Random Forest, incluyendo el número de árboles, la optimización de parámetros y la definición de los datos de entrenamiento y validación. También se ajustó el workflow, asignándole secciones y mejorando su ubicación dentro del documento. En cuanto a los resultados, hasta el momento se han obtenido avances favorables en la segmentación semántica clásica mediante SLIC y Random Forest. Sin embargo, en la aproximación de deep learning, inicialmente se optó por entrenar un modelo desde cero, pero no se logró un ajuste adecuado ni resultados satisfactorios. Por esta razón, se tomó la decisión de replantear esta parte

		metodológica y realizar la segmentación semántica con un modelo preentrenado, específicamente una U-Net con encoder preentrenado en ImageNet, para posteriormente entrenar con mis datos cómo se quedó acordado con el profe Joaquín. Debido a este cambio, una de las observaciones que aún no se ha podido desarrollar completamente en este borrador es la descripción detallada del método de deep learning, particularmente en aspectos como el uso o no de preentrenamiento, el modelo específico, el tamaño de parches, la distribución de clases, la función de pérdida, la tasa de aprendizaje y las métricas de evaluación por lote. Esta información, junto con los resultados correspondientes, se espera tenerla consolidada para el 31 de marzo, fecha de entrega del avance 2.
06/04/2026	Tabla cambios realizados Título Abstract	Se ajusta redacción, se agrega número de páginas, se ajustan referencias, se modifica el flujo para que sea consistente con lo que se describe en el texto principal de la introducción..
21/04/2026	Resultados	Notebooks finales de ambos experimentos y ajuste de resultados.(clase)
27/04/2026	Resumen Introducción Datos y Métodos Resultados Discusión Conclusión	Se ajusta el título final dejándolo directamente con SLIC y UNet. Para esta tercera entrega se ajustó el resumen en relación a agregar resultados cuantitativos de las métricas finales, además de eliminar de la redacción la variable de textura que se decidió sacar del modelo. En la parte de la introducción se trata de resumir más y dividirla en párrafos para una mayor comprensión y se ajusta redacción. se ajusta la transición hacia la pregunta de investigación y se agrega de qué manera se va a hacer una contribución científica en la manera de permitir la reproducibilidad controlada y se dividió en las siguientes secciones como se solicitó: a. importancia de la segmentación urbana, b. limitaciones de enfoques clásicos y profundos, c. utilidad de datos multimodales RGB+NIR + LiDAR, d. problema de fuga espacial en validación, e. gap + hipótesis + pregunta + objetivo El workflow se ajustó totalmente, se hizo más informativo, más visual para que se complementará como enfoque de trabajo, además se hizo cada paso más detallado en relación a cada uno de los métodos y también se agregaron gráficos y lo que se quería tener como resultado. En datos y métodos básicamente se corrigió todo, se agregaron tablas de métricas, se añadió el porqué se escogió Tunja como zona de estudio y aspectos como: rango altitudinal, pendiente o topografía si afecta sombras, características del tejido urbano, tipo de cubiertas predominantes, proporción aproximada de clases. Se aclara que no hubo co-registro pero si una alineación de insumos y se reporta la resolución final de todos los análisis. Se da más detalle de los datos utilizados y se ajustan las figuras de insumos y localización a una sola figura.
30/04/2026		

SEGMENTACIÓN SEMÁNTICA MULTICLASE DE COBERTURAS URBANAS: COMPARACIÓN ENTRE UN ENFOQUE BASADO EN SÚPERPIXELES SLIC Y UNA ARQUITECTURA U-NET

Versión 0.7

Autor: SGAP – 27.04.2026

Directores: IL – JR

visto bueno Director

Codirector: Joaquín Guillermo Ramirez Gil

visto bueno Coodirector

Abstract

Este estudio compara dos paradigmas de segmentación semántica para la clasificación de coberturas urbanas, evaluando su desempeño e implicaciones metodológicas bajo condiciones reales de alta complejidad espacial. Se contrastó un flujo clásico basado en superpíxeles SLIC acoplado a un clasificador Random Forest con un enfoque de aprendizaje profundo mediante una arquitectura U-Net con codificador preentrenado, en un entorno urbano altamente heterogéneo del municipio de Tunja (Boyacá, Colombia), caracterizado por sombras, oclusión vegetal y diversidad morfológica. La contribución principal radica en la integración explícita de información multifuente ortofoto de muy alta resolución (~6 cm), bandas RGB+NIR y datos LiDAR dentro de un marco comparativo controlado espacialmente, lo que permite evaluar no solo la exactitud temática sino también la calidad geométrica de la segmentación. A partir de los datos LiDAR se derivaron DSM, DTM y un modelo normalizado de altura (nDSM), incorporado como variable estructural clave. Metodológicamente, el estudio introduce una partición espacial bloqueada para mitigar la autocorrelación entre subconjuntos, y una estrategia de muestreo ponderado para abordar el desbalance de clases. Los resultados evidencian que la U-Net supera consistentemente al enfoque clásico, alcanzando mayores valores de overall accuracy (0.90 vs. 0.86), macro F1 (0.71 vs. 0.68) y mean IoU (0.65 vs. 0.59), con mejoras sustanciales en la delimitación de contornos (boundary F1: 0.36 vs. 0.16). Bajo condiciones de alta heterogeneidad urbana y evaluación espacialmente controlada, la U-Net preentrenada y adaptada a información multifuente ofrece ventajas temáticas y geométricas claras frente al flujo SLIC–Random Forest, mientras que este último constituye una alternativa viable y de menor costo computacional para contextos con recursos limitados.

1. INTRODUCCIÓN

La clasificación precisa de coberturas urbanas a partir de imágenes de muy alta resolución espacial es un insumo estratégico para la actualización catastral, la planificación territorial y la evaluación de riesgo (Persello et al., 2022). En entornos urbanos reales, la segmentación semántica multiclase enfrenta retos sustantivos: alta variabilidad espectral y textural, sombras

proyectadas, oclusión vegetal y heterogeneidad morfológica y constructiva. Estos factores incrementan la confusión entre clases y dificultan la generalización entre zonas y fechas de captura (Zhu et al., 2017; Ma et al., 2019). Durante la última década se ha consolidado un cambio metodológico desde flujos de trabajo clásicos basados en segmentación orientada a objetos (*OBI*), extracción manual de características y clasificación supervisada, hacia arquitecturas de aprendizaje profundo capaces de aprender representaciones directamente desde los datos (Zhu et al., 2017).

En el primer paradigma, el algoritmo *SLIC* (*Simple Linear Iterative Clustering*) genera superpíxeles compactos que equilibran similitud radiométrica y proximidad espacial, preservando bordes de objetos, y mantiene vigencia por su interpretabilidad y bajo costo computacional (Achanta et al., 2012). En el segundo, la arquitectura *U-Net*, con sus conexiones de salto entre codificador y decodificador, ha demostrado una capacidad superior para recuperar detalle espacial y delinear contornos en escenas complejas (Ronneberger et al., 2015). Sin embargo, el debate metodológico en teledetección no se centra ya en si el aprendizaje profundo funciona, sino en bajo qué condiciones y con qué costo real frente a alternativas clásicas bien diseñadas (Persello et al., 2022).

Una línea de evidencia robusta en teledetección urbana es la fusión de información espectral y altimétrica. Los datos *LiDAR* permiten derivar modelos digitales de superficie normalizados (*nDSM*) que mejoran la separabilidad entre clases espectralmente similares cubiertas planas versus copas arbóreas, por ejemplo y su integración como canal adicional en redes profundas o como covariable en clasificadores clásicos tiende a mejorar sistemáticamente el desempeño (Audebert et al., 2018; Zhang et al., 2021). El banco de datos *ISPRS* (Vaihingen, Potsdam) ha establecido comparaciones estandarizadas que confirman este beneficio, aunque su transferibilidad a contextos tropicales con alta heterogeneidad constructiva, como los municipios colombianos, sigue siendo limitada (Wurm et al., 2019).

Un punto metodológico crítico y frecuentemente subestimado es el sesgo por autocorrelación espacial en la evaluación. Bajo partición aleatoria, los conjuntos de entrenamiento y prueba comparten vecindades espaciales, lo que produce estimaciones de desempeño optimistas que no reflejan la capacidad de generalización a zonas realmente no vistas (Kattenborn et al., 2022). La partición espacial bloqueada que garantiza separación geográfica entre subconjuntos es el estándar metodológico recomendado para evaluaciones imparciales en aplicaciones geoespaciales (Wadoux et al. 2021; Kattenborn et al., 2022). Su omisión puede revertir las conclusiones sobre qué método es superior, constituyendo un sesgo sistemático de gran impacto práctico.

Con base en lo anterior, este estudio aborda la necesidad de comparaciones robustas y reproducibles entre enfoques clásicos y de aprendizaje profundo para la segmentación de coberturas urbanas. Aunque métodos basados en objetos como *SLIC* y arquitecturas profundas como *U-Net* han sido ampliamente utilizados, existe un vacío en evaluaciones controladas que eviten sesgos espaciales y que integren simultáneamente el desempeño y el costo computacional (Wadoux et al., 2021). En este contexto, se plantea la hipótesis de que un modelo de segmentación semántica basado en *U-Net* supera a un enfoque clásico basado en *SLIC* en términos de exactitud temática y geométrica, aunque con posibles diferencias en eficiencia computacional e impacto ambiental. En consecuencia, la pregunta de investigación es: *¿un modelo U-Net mejora el desempeño frente a SLIC en la clasificación de coberturas urbanas a partir de imágenes RGB+NIR de alta resolución y datos LiDAR?* Para responder, ambos enfoques se entrenan y evalúan bajo un protocolo consistente y reproducible, empleando el mismo conjunto de datos, área de estudio (Tunja, Colombia), esquema multiclase y partición espacial sin fuga. El desempeño se evalúa considerando no solo la calidad de la segmentación, sino también el costo

computacional, el consumo energético y las emisiones, utilizando CodeCarbon. El objetivo es establecer una línea base metodológica y cuantitativa para futuros desarrollos, incluyendo la integración de enfoques OBIA y la fusión con datos LiDAR.




Figura 1. Workflow

2. DATOS Y MÉTODOS

2.1 Área de estudio y selección del subconjunto

El presente estudio se desarrolló en el perímetro urbano del municipio de Tunja, capital del departamento de Boyacá, Colombia, localizado en el altiplano cundiboyacense de la cordillera oriental andina a aproximadamente 2.775 m s. n. m., con una extensión urbana de 3.792 ha. Su emplazamiento en el valle del río Jordán, con relieve ondulado y pendientes que oscilan entre 5° y 20° en sectores periurbanos, condiciona la geometría de las sombras proyectadas sobre cubiertas y vías, constituyendo una fuente relevante de ambigüedad espectral en tareas de segmentación.




Figura 1. Ubicación del área de estudio

El análisis se realizó sobre un subconjunto representativo de 106 ha (Figura 1), seleccionado por su alta heterogeneidad espacial. El área concentra cubiertas de teja cerámica de respuesta espectral rojiza, junto con desarrollos residenciales periféricos con cubiertas metálicas, de fibrocemento y losas de concreto, cuya respuesta espectral se superpone frecuentemente con la clase pavimento. La vegetación arbórea de porte medio genera oclusión parcial sobre vías y construcciones, dificultando la delimitación de límites entre clases. La distribución de clases presenta un desbalance marcado, con predominio de construcciones y pavimento, y una representación mínima de agua (< 1 % del área total). La clasificación se planteó como segmentación semántica multiclase con cinco categorías: fondo (0), construcción (1), pavimento (2), vegetación (3) y agua (4). Los píxeles sin información válida se codificaron con el valor 255 (*ignore index*) y fueron excluidos del entrenamiento y la evaluación. Todos los insumos se procesaron bajo el sistema de referencia MAGNA-SIRGAS / Origen Nacional (EPSG:9377).

2.2 Datos y co-alineamiento geométrico

Para este experimento se utilizaron tres insumos geoespaciales con fecha consistente del 19 de enero de 2022. El primer insumo fue una ortofoto de muy alta resolución espacial de cuatro bandas espectrales (R, G, B y NIR), con una resolución nominal de 6,024 cm/píxel, adquirida mediante levantamiento aerofotogramétrico. El segundo insumo correspondió a una nube de puntos *LiDAR* con densidad aproximada de 6,63 pts/m², a partir de la cual se derivaron el modelo digital de superficie (*DSM*), el modelo digital de terreno (*DTM*) y el modelo normalizado de altura (*nDSM*), descritos en la sección 2.3. El tercer insumo fue una máscara de referencia multiclase generada a partir de cartografía base oficial del Instituto Geográfico Agustín Codazzi (IGAC), empleada como referencia para el entrenamiento y la evaluación de ambos métodos. El uso de ortofotos de muy alta resolución combinadas con datos *LiDAR* derivados es una estrategia establecida en teledetección urbana para mejorar la separabilidad entre coberturas espectralmente similares (Audebert et al., 2018; Dabove et al., 2024).

Los tres insumos fueron recortados al área de estudio de 106 ha y registrados sobre una grilla raster común, con dimensiones de 19.589 × 27.538 píxeles y sistema de referencia MAGNA-

SIRGAS / Origen Nacional (EPSG:9377). La alineación espacial entre la ortofoto, el *nDSM* y la máscara de referencia fue validada verificando la coincidencia de dimensiones, sistema de referencia y transformación afín entre capas, garantizando una correspondencia píxel a píxel sin necesidad de remuestreo adicional durante el modelado. Cuando fue necesario visualizar o inspeccionar los datos, se empleó remuestreo bilineal para variables continuas (ortofoto y *nDSM*) y vecino más cercano para la máscara temática, por tratarse de datos categóricos. La exactitud posicional de los insumos corresponde a la reportada en los metadatos de los productos cartográficos originales, dado que no se realizó una evaluación independiente con puntos de control adicionales.

2.3 Derivados LiDAR y variables espectrales

A partir de la nube de puntos *LiDAR* se generaron dos superficies altimétricas de referencia. El modelo digital de superficie (*DSM*, *Digital Surface Model*) representa la elevación de la parte superior de los elementos sobre el terreno, incluyendo edificaciones, vegetación y otras estructuras. El modelo digital de terreno (*DTM*, *Digital Terrain Model*) representa la elevación del suelo desnudo, excluyendo edificaciones y cubierta vegetal. A partir de ambas superficies se calculó el modelo normalizado de alturas (*nDSM*, *normalized Digital Surface Model*) como:

$$\mathbf{nDSM = DSM - DTM}$$

El *nDSM* aproxima la altura relativa de los objetos sobre el terreno y fue incorporado como variable de entrada en ambos métodos, dado su aporte a la separabilidad entre coberturas urbanas con ambigüedad radiométrica, particularmente entre construcciones y vegetación arbórea, así como en zonas afectadas por sombra. Su integración como canal adicional en redes profundas o como covariable en clasificadores clásicos tiende a mejorar sistemáticamente el desempeño en escenarios de clasificación urbana (Guo et al., 2019).

En el dominio espectral se emplearon las bandas roja (R), verde (G), azul (B) e infrarrojo cercano (NIR, *Near-Infrared*) de la ortofoto. Las bandas del visible capturan diferencias de reflectancia que permiten discriminar materiales urbanos como techos, pavimento, suelo expuesto y vegetación, aunque con limitaciones en zonas de sombra (Toth & Józków, 2016). La banda NIR, en la que la vegetación sana presenta una reflectancia marcadamente elevada, mejora la distinción entre cubiertas vegetales y superficies artificiales (Tucker, 1979). Las bandas R, G, B y NIR fueron utilizadas como canales de entrada en ambos métodos.

Adicionalmente, a partir de las bandas NIR y R se calculó el índice normalizado de vegetación (*NDVI*, *Normalized Difference Vegetation Index*):

$$\mathbf{NDVI = (NIR - R) / (NIR + R + \epsilon)}$$

Donde ϵ es un término de estabilidad numérica para evitar divisiones por cero. El NDVI toma valores en el intervalo $[-1, 1]$, donde valores próximos a 1 indican vegetación densa y activa, valores cercanos a 0 corresponden a suelos desnudos o superficies artificiales, y valores negativos se asocian a superficies de agua o sombra profunda (Rouse et al., 1974). El NDVI fue utilizado exclusivamente como atributo de clasificación en el método clásico SLIC +

Random Forest; no fue incorporado como canal de entrada en ninguno de los experimentos de U-Net.

Variable	Descripción	SLIC+RF	U-Net
R, G, B	Bandas visibles de ortofoto	Entrada a RF (feature)	Canal de entrada
NIR	Infrarrojo cercano	Feature de RF	Canal de entrada
nDSM (HEIGHT)	Altura normalizada LiDAR	Feature de RF	Canal de entrada
NDVI	Índice de vegetación	Feature de RF	✗ No utilizado

Tabla 1. Variables espectrales y altimétricas utilizadas en cada método. En SLIC+RF, todas las variables se incorporan como atributos estadísticos por superpíxel. En U-Net, R, G, B, NIR y HEIGHT se concatenan como canales del tensor de entrada (experimento multifuente).

2.3 Partición espacial topológica

Para mitigar el sesgo por autocorrelación espacial en la evaluación, el conjunto de datos se dividió mediante una partición espacial bloqueada sobre el eje x del raster, asignando el 70 % del ancho a entrenamiento, el 15 % a validación y el 15 % a prueba. Esta estrategia garantiza separación geográfica entre subconjuntos, obligando a los modelos a generalizar hacia zonas espacialmente distintas a las observadas durante el ajuste, en contraste con una partición aleatoria que produciría estimaciones de desempeño optimistas no representativas de zonas no vistas (Kattenborn et al., 2022; Wadoux et al., 2021). La adopción de esquemas de partición espacialmente conscientes es el estándar metodológico recomendado para evaluaciones imparciales en aplicaciones geoespaciales (Meyer & Pebesma, 2022).

El procesamiento se realizó sobre teselas de 256×256 píxeles con $stride = 256$, es decir, sin solapamiento, y descartando teselas incompletas en los bordes del raster. Ambos métodos comparten el mismo esquema de partición y teselado, lo que garantiza que las diferencias observadas en desempeño sean atribuibles a los modelos y no al protocolo de evaluación. La evaluación final de ambos enfoques se realizó sobre el raster reconstruido a resolución de píxel sobre el conjunto de prueba, lo cual es metodológicamente necesario para que la comparación entre el método clásico que aprenda a nivel de superpíxel y U-Net que predice a nivel de píxel sea estrictamente equivalente.

3. Método clásico basado en SLIC y Random Forest


El flujo clásico se estructuró como un *pipeline* orientado a objetos compuesto por tres etapas secuenciales: pre-segmentación de la imagen en superpíxeles mediante SLIC, extracción de atributos espectrales, altimétricos y geométricos por segmento, y clasificación supervisada mediante Random Forest. Este esquema es análogo a flujos de segmentación-clasificación ampliamente documentados en la literatura de extracción de coberturas urbanas a partir de imágenes de muy alta resolución (Blaschke, 2010; Hossain & Chen, 2019).

SLIC (Simple Linear Iterative Clustering) puede entenderse como una adaptación eficiente de *k-means* en un espacio conjunto color-posición, que limita el vecindario de búsqueda y produce superpíxeles compactos con buena adherencia a bordes (Achanta et al., 2012). En su formulación estándar, la asignación de cada píxel a un centroide minimiza una distancia compuesta:

$$D = \sqrt{d_c^2 + \left(\frac{m}{S}\right)^2 d_s^2}$$

donde dc es la distancia de color entre el píxel y el centroide del superpíxel, d_{es} es la distancia espacial euclidiana, S es el paso de muestreo aproximado asociado al tamaño esperado del superpíxel, y m es el parámetro de compactación que regula el equilibrio entre similitud radiométrica y proximidad espacial (Achanta et al., 2012). Valores bajos de m producen superpíxeles que se adhieren más fielmente a los bordes de los objetos, mientras que valores altos favorecen formas más regulares y compactas.

3.1. Entrada de datos



El método clásico se implementó a partir de tres insumos raster descritos en la sección 2.2: i) un ortofoto multibanda de cuatro canales espectrales (R, G, B, NIR), ii) una máscara de referencia con cinco clases temáticas (0 = fondo, 1 = construcción, 2 = pavimento, 3 = vegetación, 4 = agua) y iii) un raster de altura normalizada (*nDSM*). Los píxeles con valor 255 fueron tratados como *ignore index* y excluidos de los procesos de entrenamiento y evaluación. El esquema de partición espacial y teselado es el descrito en la sección 2.4: *split* sobre el eje x con proporciones 70/15/15, teselas de 256 × 256 píxeles, *stride* = 256 y descarte de teselas incompletas.

Esta formulación permite integrar información espectral y estructural dentro de un enfoque de análisis basado en objetos, estrategia ampliamente utilizada en teledetección de muy alta resolución para combinar atributos radiométricos, texturales y de altura en unidades espaciales más estables que el píxel aislado (Hossain & Chen, 2019; Kattenborn et al., 2022). El uso conjunto de ortofotos de alta resolución y productos *LiDAR* derivados para clasificación de coberturas en escenas urbanas complejas ha sido documentado en estudios recientes de segmentación orientada a objetos (Guo et al., 2019; Dabove et al., 2024).

3.2. Generación de superpíxel

Aunque el experimento utiliza un *stack* multifuente completo (R, G, B, NIR, *HEIGHT*), se exploraron tres configuraciones de entrada para *SLIC* antes de adoptar la variante final: i) RGB + *HEIGHT* con compactación alta (*compactness* = 10,0), ii) RGB + *HEIGHT* con compactación moderada (*compactness* = 3,0), y iii) RGB solamente con compactación baja (*compactness* = 1,0). La evaluación visual sobre teselas representativas del conjunto de entrenamiento mostró que la

variante RGB con compactación baja produjo superpíxeles geoméricamente más coherentes, con mejor adherencia a los bordes reales de las cubiertas urbanas, en comparación con las variantes que incorporaban directamente la variable de altura en la etapa de segmentación. La incorporación de *HEIGHT* en la segmentación tendió a sobre-fragmentar algunas coberturas y a suavizar bordes relevantes entre clases con diferencias altimétricas moderadas, como pavimento y construcciones bajas.

Esta decisión es consistente con la lógica *OBIA* en imágenes de muy alta resolución, donde la segmentación inicial busca delimitar regiones localmente homogéneas con bordes plausibles, mientras que la información adicional como altura o índices espectrales se incorpora en etapas posteriores como atributos de clasificación (Hossain & Chen, 2019; Blaschke, 2010). Esta separación entre segmentación y clasificación permite mayor control sobre la calidad geométrica de los objetos y facilita la interpretación del modelo (Achanta et al., 2012).




Figura 2. Verificación final de SLIC adoptado

La configuración final adoptada fue: $n_segments = 500$, $compactness = 1,0$, $sigma = 1,0$, conversión al espacio de color *LAB* activada ($convert2lab = True$) y conectividad espacial forzada ($enforce_connectivity = True$). La conversión al espacio *LAB* es apropiada cuando la entrada es exclusivamente RGB, ya que mejora la percepción de similitud de color en términos perceptualmente uniformes. La conectividad forzada garantiza que cada superpíxel forme una región espacialmente contigua, evitando segmentos fragmentados que introducirán ruido en la etapa de clasificación posterior.

3.3. Atributos por objeto

Una vez generados los superpíxeles, cada segmento fue descrito mediante un vector de atributos construido a partir de seis variables: las bandas espectrales R, G, B y NIR, la altura normalizada *HEIGHT* (*nDSM*) y el índice de vegetación *NDVI* (definido en la sección 2.3). Para cada una de estas variables se calcularon siete estadísticos de resumen por superpíxel: media, desviación estándar, mínimo, máximo, mediana, percentil 25 y percentil 75. Adicionalmente, se incorporó el área del superpíxel expresada en número de píxeles como atributo geométrico. El vector resultante por objeto tuvo una dimensión de 43 atributos ($6 \text{ variables} \times 7 \text{ estadísticos} + 1 \text{ atributo geométrico}$).

Esta estrategia permite transformar cada región segmentada en una representación compacta que combina información espectral, estructural y geométrica, superando las limitaciones del análisis píxel a píxel en imágenes de muy alta resolución donde la variabilidad intra-objeto es elevada (Blaschke, 2010; Hossain & Chen, 2019). El uso conjunto de variables espectrales, el *nDSM* y el *NDVI* como atributos de clasificación por objeto ha sido reportado como especialmente efectivo para mejorar la discriminación entre coberturas urbanas espectralmente similares pero con

diferencias en estructura vertical o vigor vegetal, como pavimento frente a cubiertas o vegetación baja frente a elementos elevados (Guo et al., 2019; Zhang et al., 2021).

Es importante destacar que el *NDVI* y el *NIR* se incorporaron únicamente en esta etapa de clasificación por atributos, no en la etapa de segmentación *SLIC* descrita en la sección 3.2. Esta distinción es metodológicamente relevante porque permite que la geometría de los superpíxeles quede determinada exclusivamente por similitud visual en el espacio RGB, mientras que la discriminación semántica entre clases se enriquece posteriormente con información espectral y estructural adicional.

3.4 Asignación de etiqueta por mayoría

La etiqueta objetivo de cada superpíxel se asigna a partir de la clase mayoritaria presente en el ráster de referencia dentro del área del segmento, ignorando los píxeles con valor 255 (*ignore index*). Esta estrategia de etiquetado por mayoría es coherente con el paradigma *OBIA*, donde la unidad analítica básica es el objeto segmentado y no el píxel individual, y ha sido ampliamente adoptada en flujos de clasificación orientada a objetos para imágenes de muy alta resolución (Blaschke, 2010; Hossain & Chen, 2019).

Para reducir el ruido en el etiquetado supervisado, se aplicaron dos criterios de filtrado: i) se descartaron los superpíxeles con menos de 20 píxeles válidos, y ii) se descartaron aquellos con una proporción de píxeles válidos inferior al 50 % del área total del segmento. Este criterio evitó que segmentos dominados por píxeles *nodata* o por mezcla excesiva de clases introdujera etiquetas poco confiables durante el aprendizaje. Los superpíxeles que no superan estos umbrales fueron excluidos del entrenamiento y la validación, pero sus píxeles se conservaron con el valor 255 en la reconstrucción raster final, preservando así la integridad espacial del producto de salida.

La Tabla 4 resume la distribución de clases a nivel de superpíxel tras el filtrado, tanto para el conjunto de entrenamiento como para el de validación. La distribución resultante mostró un desbalance moderado, con predominio de las clases fondo, construcción y pavimento, y una representación considerablemente menor de vegetación y agua, lo que motivó el uso de *class_weight = balanced* en el clasificador *Random Forest* descrito en la sección 3.5.

3.5 Entrenamiento del Random Forest

La clasificación supervisada se realizó mediante *Random Forest* (RF), un método de aprendizaje en conjunto que construye múltiples árboles de decisión a partir de submuestras aleatorias del conjunto de entrenamiento y aleatorización de variables en cada división, promediando las predicciones individuales para producir una clasificación final robusta (Breiman, 2001). El método es ampliamente reconocido por su capacidad de generalización, su robustez frente a predictores heterogéneos y no lineales, y su utilidad práctica en problemas de clasificación multivariante con datos de teledetección (Belgiu & Drăguț, 2016).

La configuración final del clasificador fue: *n_estimators* = 300, *max_depth* = 30, *min_samples_leaf* = 2, *max_features* = *sqrt*, *class_weight* = *balanced* y *random_state* = 42. El número de árboles (300) fue seleccionado como un valor suficientemente grande para estabilizar las predicciones del ensamble sin introducir un costo computacional excesivo. La profundidad máxima (30) permite capturar relaciones no lineales entre atributos sin llegar a un sobreajuste severo. El parámetro *min_samples_leaf* = 2 impone una restricción mínima de muestras en las hojas, actuando como regularización implícita. El criterio *max_features* = *sqrt* limita el número

de variables consideradas en cada división, reduciendo la correlación entre árboles y mejorando la diversidad del ensamble (Breiman, 2001). El parámetro *class_weight = balanced* asigna pesos inversamente proporcionales a la frecuencia de cada clase, compensando el desbalance documentado en la sección 3.4, particularmente la escasa representación de las clases vegetación y agua.

El modelo se entrenó exclusivamente con los superpíxeles del conjunto de entrenamiento y se validó sobre la partición de validación. El conjunto de prueba no participó en ninguna decisión de ajuste, preservando la independencia de la evaluación final. No se realizó una búsqueda exhaustiva de hiperparámetros mediante *grid search* o *random search*; esta decisión fue intencional para priorizar la reproducibilidad y la comparabilidad con el experimento U-Net, evitando una optimización agresiva que pudiera introducir ventajas asimétricas entre métodos. La semilla de aleatorización (*random_state = 42*) garantiza la reproducibilidad del experimento.

3.6 Optimización del flujo clásico

La optimización del método clásico se realizó en dos niveles. En la etapa de segmentación, se evaluaron tres configuraciones de entrada para *SLIC* antes de adoptar la variante final, como se describió en la sección 3.2. La selección se basó en criterios de coherencia geométrica visual sobre teselas representativas del conjunto de entrenamiento, privilegiando la adherencia a bordes reales de las cubiertas sobre la regularidad de los segmentos.

En la etapa de clasificación, se fijó una configuración moderada de *Random Forest* sin recurrir a búsqueda exhaustiva de hiperparámetros mediante *grid search* o *random search*. Esta decisión fue intencional: una optimización agresiva podría comprometer la comparabilidad con U-Net al introducir ventajas asimétricas entre métodos, o inducir sobreajuste al conjunto de validación. La configuración adoptada, descrita en la sección 3.5, es suficientemente expresiva para capturar relaciones no lineales entre los 43 atributos por objeto, al tiempo que mantiene la estabilidad y reproducibilidad del experimento.

No se aplicó selección explícita de atributos previa al entrenamiento. En su lugar, se conservó el conjunto completo de variables y se analizó su contribución relativa mediante importancia de variables posterior al ajuste del modelo, descrita en la sección 3.7.

3.7 Inferencia y reconstrucción raster

Durante la inferencia sobre el conjunto de prueba, cada tesela fue segmentada nuevamente con *SLIC* usando la configuración final adoptada. A continuación, se extrajeron los mismos 43 atributos por superpíxel y el modelo *Random Forest* entrenado asignó una clase a cada segmento. Las etiquetas predichas se proyectaron sobre la grilla raster original para reconstruir una predicción final a resolución de píxel. Los píxeles pertenecientes a superpíxeles sin etiqueta válida se conservaron con el valor 255 en el raster de salida.

Este paso es metodológicamente crucial porque, aunque el método clásico aprende a nivel de superpíxel, la comparación con U-Net exige que ambas salidas se expresen y evalúen sobre la misma malla raster a resolución de píxel. Evaluar el método clásico únicamente a nivel de objeto subestimaría los errores de delimitación geométrica en los bordes de los segmentos, introduciendo una ventaja artificial frente a U-Net que predice directamente a nivel de píxel (Cheng et al., 2021).

3.8 Importancia de variables e interpretabilidad

Como complemento interpretativo, se analizó la importancia relativa de los 43 atributos mediante la reducción media de impureza (*mean decrease in impurity*, MDI), calculada internamente por el modelo *Random Forest* entrenado. Este análisis permitió identificar qué variables y familias de atributos aportaron más a la discriminación entre clases, y sirvió como evidencia adicional sobre la contribución del *nDSM* en la separación de coberturas urbanas con ambigüedad radiométrica.

Las medidas de importancia basadas en MDI pueden presentar sesgos cuando existen variables continuas o correlacionadas entre sí, tendiendo a sobreestimar la importancia de variables con mayor número de valores únicos (Strobl et al., 2007). Por esta razón, los resultados se interpretaron en términos descriptivos y comparativos entre familias de atributos espectrales, altimétricos e índices derivados sin atribuirles significado causal. Para mayor solidez explicativa, estudios recientes recomiendan complementar el MDI con importancia por permutación (*permutation importance*), que es menos sensible a estas limitaciones (Breiman, 2001; Belgiu & Drăguș, 2016).

3.9 Evaluación temática, geométrica y computacional

La evaluación final se realizó sobre el raster reconstruido del conjunto de prueba, excluyendo los píxeles con valor 255. A partir de la matriz de confusión se calcularon las métricas de exactitud temática descritas en la Tabla 2: exactitud global (*overall accuracy*, OA), precisión (*precision*), exhaustividad (*recall*), F1 e IoU por clase, macro F1 y *mean IoU*. Estas métricas se calcularon de forma equivalente para ambos métodos, garantizando comparabilidad directa.


Ec.	Métrica	Expresión	Variables
(1)	Overall Accuracy	$OA = \sum TP_i / N$	N = total pixels evaluados
(2)	Precision	$P_i = TP_i / (TP_i + FP_i)$	TP_i = verdaderos positivos clase i FP_i = falsos positivos clase i
(3)	Recall	$R_i = TP_i / (TP_i + FN_i)$	FN_i = falsos negativos clase i
(4)	F1 por clase	$F1_i = 2 \cdot TP_i / (2 \cdot TP_i + FP_i + FN_i)$	Media armónica de P_i y R_i
(5)	IoU por clase	$IoU_i = TP_i / (TP_i + FP_i + FN_i)$	Jaccard index por clase
(6)	Macro-F1	$macro_F1 = (1/K) \cdot \sum F1_i$	K = número de clases
(7)	Mean IoU	$mIoU = (1/K) \cdot \sum IoU_i$	Promedio de IoU sobre todas las clases
(8)	Boundary-F1	$BF1 = 2 \cdot BP \cdot BR / (BP + BR)$	Media armónica de BP y BR

Tabla 2. Métricas de evaluación empleadas. TP_i , FP_i , FN_i : verdaderos positivos, falsos positivos y falsos negativos para la clase i. K: número de clases. N: total de píxeles evaluados (excluye valor 255). $\tau = 2$ px: tolerancia espacial para el cálculo del Boundary F1.

Adicionalmente, se calculó el *Boundary F1 (BFI)* con una tolerancia espacial de 2 píxeles, tanto en versión multiclase como específicamente para la clase construcción. Esta métrica evalúa la calidad geométrica de los contornos predichos comparando los bordes de la predicción con los bordes de referencia dentro de una banda de tolerancia, y es significativamente más sensible a errores de delimitación que las métricas basadas en área como IoU (Cheng et al., 2021; Marmanis et al., 2018). Su inclusión es especialmente relevante en geomática urbana, donde la precisión posicional de los objetos es un criterio de calidad fundamental para aplicaciones cartográficas.

Finalmente, el desempeño computacional de ambos métodos se midió mediante tiempo de entrenamiento, tiempo de inferencia, energía consumida y emisiones estimadas de CO₂ equivalente, registradas con la herramienta *CodeCarbon* (Courty et al., 2023) bajo el mismo entorno de ejecución y hardware, con un protocolo de medición consistente para las fases de entrenamiento e inferencia.

4. Método de deep learning con la arquitectura U-Net



4.1 Preprocesamiento de datos

La compatibilidad espacial entre la ortofoto, el *nDSM* y la máscara de referencia fue verificada como se describió en la sección 2.2. Previo al entrenamiento, se aplicó una rutina de saneamiento sobre el canal de altura que: i) convirtió los datos a *float32*, ii) reemplazó el valor *nodata* por NaN, iii) eliminó valores no finitos y iv) descartó valores fuera del intervalo $[-1000, 1000]$ m como valores absurdos. Este procedimiento evitó que valores inválidos del *nDSM* propagaran errores numéricos durante la normalización o el entrenamiento.

La política de normalización fue diferente para la información espectral y para la altura, y en ambos casos los parámetros se estimaron exclusivamente a partir de los tiles del conjunto de entrenamiento, evitando cualquier fuga de información hacia los conjuntos de validación y prueba

(Kattenborn et al., 2022). Para las bandas R, G, B y NIR se aplicó un escalado robusto por banda mediante los percentiles 2 y 98 del conjunto de entrenamiento, obteniéndose los valores mínimos [3, 7, 17, 69] y máximos [251, 252, 252, 249] para las cuatro bandas respectivamente. El uso de percentiles robustos en lugar de valores extremos globales reduce la sensibilidad a valores atípicos asociados a píxeles *nodata* o saturación del sensor (Audebert et al., 2018).

Para el canal *HEIGHT* (*nDSM*) se aplicó un esquema de recorte robusto seguido de estandarización global. Los límites de recorte se definieron con los percentiles 1 y 99 del conjunto de entrenamiento, obteniéndose un intervalo [0,33, 18] m, con media global de 3,79 m y desviación estándar de 6,08 m. Tras el recorte, el canal fue estandarizado a media cero y varianza unitaria, y cualquier valor residual no finito fue reemplazado por cero, interpretado como una altura normalizada neutra. Este diseño evita normalizar la altura por tesela, lo que introduciría inconsistencias locales y comprometería la comparabilidad de la señal altimétrica entre muestras.

4.2 Construcción del conjunto de datos

El teselado y la partición espacial siguieron el protocolo descrito en la sección 2.4, produciendo 8.132 teselas en total antes del filtrado, distribuidas en 5.778 de entrenamiento, 1.177 de validación y 1.177 de prueba. A diferencia del método clásico, el pipeline de U-Net requirió un filtrado de calidad adicional por tesela basado en cuatro criterios: i) fracción mínima de píxeles válidos (distinta de *ignore index*) de 0,10, ii) mínimo de 256 píxeles válidos por tesela, iii) presencia de al menos una clase etiquetada y iv) fracción máxima de valores inválidos en el canal *HEIGHT* de 0,05. Tras este filtrado quedaron 3.259 teselas en entrenamiento, 823 en validación y 479 en prueba.

La distribución de píxeles válidos tras el filtrado mostró un desbalance marcado. En entrenamiento, las proporciones fueron aproximadamente 40,44 % para fondo, 33,38 % para construcción, 22,94 % para pavimento, 2,96 % para vegetación y 0,28 % para agua. Este patrón se mantuvo de forma similar en validación y prueba, con la clase agua como la menos representada. Para mitigar el desbalance se definió una estrategia en dos niveles: pesos por clase en la función de pérdida, y un *WeightedRandomSampler* sobre las teselas de entrenamiento para incrementar la probabilidad de muestreo de aquellas con clases raras o mayor diversidad temática (Buda et al., 2018). Tras el muestreo ponderado, la cobertura relativa de vegetación aumentó de 2,96 % a 8,40 % y la de agua de 0,28 % a 0,82 %, exponiendo con mayor frecuencia las clases minoritarias al modelo durante el aprendizaje.

4.3 Fusión de datos multimodales

Se definieron dos configuraciones experimentales bajo el mismo protocolo metodológico. La primera correspondió a un experimento control *RGB*, en el que solo se emplearon las tres bandas visibles de la ortofoto, produciendo un tensor de entrada de $256 \times 256 \times 3$ por tesela. La segunda correspondió a un experimento multifuente, en el que se concatenaron cinco canales de entrada: R, G, B, NIR y *HEIGHT* (*nDSM*), produciendo un tensor de $256 \times 256 \times 5$. Esta estrategia de fusión temprana por concatenación de canales es el enfoque más extendido en segmentación semántica multimodal con redes convolucionales, ya que permite al modelo aprender conjuntamente representaciones espectrales y altimétricas desde las primeras capas del encoder (Audebert et al., 2018; Zhang et al., 2021).

Es importante destacar que el *NDVI*, utilizado como atributo de clasificación en el método clásico *SLIC + Random Forest*, no fue incorporado como canal de entrada en ninguno de los dos experimentos U-Net. Esta decisión responde a que las redes convolucionales profundas son capaces de aprender implícitamente relaciones entre bandas espectrales equivalentes al *NDVI* a

partir de los canales NIR y R directamente, sin necesidad de calcular el índice de forma explícita (Audebert et al., 2018). Ambos experimentos compartieron el mismo esquema de partición espacial, la misma estrategia de normalización, el mismo criterio de exclusión de píxeles ignorados y el mismo protocolo de evaluación, de modo que las diferencias observadas en desempeño entre el experimento control y el multifuente puedan atribuirse directamente a la incorporación de los canales NIR y *HEIGHT*.

4.4 Arquitectura del modelo

Como arquitectura base se utilizó *U-Net* (Ronneberger et al., 2015) implementada con la librería *segmentation_models_pytorch*, con encoder *ResNet34* preentrenado en *ImageNet* (He et al., 2016; Deng et al., 2009). La arquitectura sigue el esquema encoder-decoder con conexiones de salto (*skip connections*) que preservan información espacial de alta resolución a lo largo del decodificador, facilitando la recuperación de detalle en los contornos de los objetos segmentados. El modelo fue configurado con 5 clases de salida, activación final implícita en la función de pérdida y *batch normalization* en el decodificador (Ioffe & Szegedy, 2015).

Para el experimento control *RGB*, el modelo recibió 3 canales de entrada, alcanzando 24.436.949 parámetros entrenables. Para el experimento multifuente, la misma arquitectura fue adaptada para recibir 5 canales de entrada (R, G, B, NIR, *HEIGHT*). Dado que los pesos preentrenados de *ImageNet* están definidos para tres canales, se modificó la primera capa convolucional del encoder para aceptar la nueva dimensionalidad. La adaptación conservó los pesos originales para los canales R, G y B, mientras que los canales NIR y *HEIGHT* fueron inicializados mediante la media de los pesos preentrenados del primer bloque convolucional, estrategia que ha demostrado ser más estable que la inicialización aleatoria en experimentos de fusión multimodal (Audebert et al., 2018). Tras esta expansión, los pesos preentrenados del encoder se cargaron para el resto de capas. El modelo multifuente resultante alcanzó 24.443.221 parámetros entrenables, manteniendo la misma lógica encoder-decoder con conexiones de salto.




Figura 3. Arquitectura *U-Net* con codificador *ResNet34* preentrenado en *ImageNet* y adaptado para recibir 5 canales de entrada (R, G, B, NIR y *HEIGHT*/nDSM). Las conexiones de salto (líneas discontinuas) concatenan mapas de características del codificador con los del decodificador en cada nivel de resolución, facilitando la recuperación de detalle espacial. La salida es una máscara de segmentación semántica de 256×256 píxeles con 5 clases.

4.5 Configuración del entrenamiento

Ambos experimentos se entrenaron bajo una configuración homogénea para garantizar la comparabilidad de los resultados. Los *DataLoader* se configuraron con *batch size* = 8, valor

seleccionado para equilibrar el uso de memoria GPU con la estabilidad del gradiente durante el entrenamiento. El entrenamiento se realizó en PyTorch sobre dispositivo CUDA, sin precisión mixta (*amp = False*), priorizando estabilidad numérica sobre velocidad de cómputo.

La función de pérdida utilizada fue *CrossEntropyLoss* con manejo explícito de *ignore_index = 255* para excluir los píxeles sin etiqueta válida del cálculo del gradiente. La optimización se realizó con *AdamW* (Loshchilov & Hutter, 2019), usando una tasa de aprendizaje inicial de 1×10^{-4} , *weight_decay = 1×10^{-4}* y *gradient clipping* con norma máxima de 1,0 para prevenir explosión del gradiente. *AdamW* fue preferido sobre *Adam* estándar por su desacoplamiento del término de regularización, lo que mejora la generalización en tareas de visión con arquitecturas profundas (Loshchilov & Hutter, 2019).

Como mecanismo de ajuste dinámico de la tasa de aprendizaje se empleó *ReduceLROnPlateau*, con factor de reducción de 0,5, paciencia de 3 épocas y tasa mínima de 1×10^{-6} . La métrica de monitoreo principal fue *val_mean_iou*, seleccionada por su sensibilidad al desbalance de clases en comparación con la exactitud global. El entrenamiento se detuvo mediante *early stopping* con paciencia de 7 épocas sin mejora, con un máximo definido de 25 épocas.

4.6 Implementación técnica

La implementación se realizó en Python con PyTorch y la librería *segmentation_models_pytorch* para la arquitectura de segmentación. El preprocesamiento ráster y la lectura por ventanas se desarrollaron con rasterio, mientras que las operaciones numéricas y métricas se apoyaron en numpy, matplotlib y scikit-image para el cálculo de bordes en la evaluación geométrica. La ejecución se realizó en un entorno con disponibilidad de GPU CUDA.

4.7 Implementación técnica

Ambos experimentos se implementaron en Python 3.10. El método de aprendizaje profundo utilizó PyTorch (Paszke et al., 2019) como marco de entrenamiento y la librería *segmentation_models_pytorch* para la instanciación de la arquitectura U-Net con encoder ResNet34. El preprocesamiento ráster, la lectura por ventanas y la escritura de productos de salida se desarrollaron con *rasterio*. Las operaciones numéricas y el cálculo de estadísticas se apoyaron en *NumPy* y *pandas*, mientras que la evaluación geométrica de contornos empleó *scikit-image*. El método clásico utilizó *scikit-learn* (Pedregosa et al., 2011) para la implementación del clasificador *Random Forest* y el cálculo de métricas de evaluación.

El consumo energético y las emisiones de CO₂ equivalente de ambos experimentos se estimaron mediante *CodeCarbon* (Courty et al., 2023), ejecutado bajo el mismo entorno de hardware para garantizar comparabilidad. Los experimentos de aprendizaje profundo se ejecutaron sobre GPU NVIDIA, mientras que el método clásico se ejecutó sobre CPU. Ambos flujos se corrieron bajo el mismo sistema operativo y entorno de dependencias, gestionado mediante *conda*, asegurando la reproducibilidad del experimento.

4. RESULTADOS

4.1 Resultados del método SLIC + Random Forest

El modelo SLIC + *Random Forest* alcanzó en el conjunto de prueba una exactitud global (*overall accuracy*) de 0,866, un macro F1 de 0,685 y un *mean IoU* de 0,594, evaluados sobre 29.526.479 píxeles válidos (Tabla 3). Estos valores reflejan un desempeño aceptable en las clases dominantes del área de estudio, aunque con diferencias sustanciales entre clases que se detallan a continuación.

Métrica	Valor
Overall accuracy	0,866
Macro F1	0,685
Mean IoU	0,594
Boundary F1 multiclase ($\tau = 2$ px)	0,168
Boundary F1 construcción ($\tau = 2$ px)	0,252
Píxeles evaluados	29.526.479

Tabla 3 . Métricas globales del método SLIC + Random Forest en el conjunto de pruebas.

El análisis por clase (Tabla 4) revela un patrón consistente con la distribución de clases y la complejidad espectral del área de estudio. La clase construcción obtuvo el mejor desempeño individual con un F1 de 0,948 e IoU de 0,901, lo que indica que el modelo logró discriminar eficazmente las cubiertas de edificaciones, probablemente favorecido por la información altimétrica del *nDSM* que separa estas superficies elevadas de las clases a nivel de suelo. La clase fondo alcanzó un F1 de 0,869 e IoU de 0,768, y pavimento obtuvo un F1 de 0,840 e IoU de 0,724, ambas con valores de precisión y *recall* equilibrados que sugieren una discriminación consistente entre clases. La clase vegetación mostró un desempeño moderado (F1 = 0,703, IoU = 0,543), con un *recall* de 0,673 inferior a su precisión (0,737), lo que indica que una proporción de píxeles de vegetación fue clasificada erróneamente como otras coberturas, posiblemente pavimento o construcción en zonas de sombra o vegetación baja. La clase agua presentó el desempeño más bajo del experimento con un F1 de 0,064 e IoU de 0,033, consecuencia directa de su escasa representación en el conjunto de prueba (111.610 píxeles de referencia frente a 13.053 píxeles predichos), lo que evidencia que el modelo prácticamente no recuperó esta clase a pesar del uso de *class_weight = balanced*.

Clase	Precisión	Recall	F1	IoU
Fondo	0,865	0,872	0,869	0,768
Construcción	0,953	0,943	0,948	0,901
Pavimento	0,834	0,846	0,840	0,724

Vegetación	0,737	0,673	0,703	0,543
Agua	0,307	0,036	0,064	0,033

Tabla 4. Métricas por clase del método SLIC + Random Forest en el conjunto de prueba.

El análisis de importancia de variables mediante reducción media de impureza (*MDI*) reveló que los atributos altimétricos derivados del *nDSM* dominaron la discriminación entre clases (Figura 4). Los cinco atributos más importantes fueron HEIGHT_p25 (0,062), HEIGHT_mean (0,056), HEIGHT_min (0,055), HEIGHT_median (0,044) y HEIGHT_max (0,040), concentrando en conjunto aproximadamente el 23,8 % de la importancia total del modelo. Este resultado confirma que la información de altura normalizada fue la variable más discriminante del experimento, coherente con su capacidad para separar cubiertas elevadas como construcciones y vegetación arbórea de superficies a nivel del suelo como pavimento y suelo desnudo (Guo et al., 2019; Zhang et al., 2021). En el segundo grupo de importancia aparecen atributos de la banda azul (B_p25, B_mean, B_median, B_p75) y del *NDVI* (NDVI_p75, NDVI_median, NDVI_mean), lo que sugiere que la reflectancia en el visible y el índice de vegetación contribuyeron de forma secundaria pero relevante a la discriminación entre cubiertas vegetales y superficies artificiales. Los atributos de las bandas R y G presentaron importancias menores, consistente con su menor capacidad discriminativa en zonas urbanas heterogéneas.




Figura 4. Importancia de variables

La evaluación geométrica mediante *Boundary F1* con tolerancia de 2 píxeles arrojó un valor multiclase de 0,168 y un valor específico para la clase construcción de 0,252 (Tabla 3). Estos valores indican que la delimitación geométrica de los contornos predichos por el método clásico es limitada, lo cual es esperable dado que la unidad de predicción es el superpíxel y no el píxel individual. Los bordes predichos tienden a seguir los límites de los segmentos SLIC, que no

siempre coinciden con los bordes reales de las cubiertas, especialmente en zonas de transición gradual entre pavimento y construcción o en áreas afectadas por sombra.

La Figura 2 ilustra la predicción sobre una tesela representativa del conjunto de prueba. La comparación entre la ortofoto RGB, la máscara de referencia y la predicción muestra que el modelo captura correctamente las grandes manchas de construcción y pavimento, pero tiende a producir bordes angulares y blocky propios de la segmentación por superpíxeles. Las zonas de sombra proyectada sobre vías y construcciones generan confusión entre clases, siendo clasificadas con frecuencia como fondo o pavimento. La clase agua, representada de forma muy minoritaria en el área de prueba, no fue recuperada de forma significativa por el modelo.

4.2 Resultados del método U-Net

4.2.1 Convergencia del entrenamiento

El experimento control *RGB* alcanzó su mejor desempeño en validación en la época 11, con $val_mean_iou = 0,674$, deteniéndose por *early stopping* en la época 18. Las curvas de pérdida mostraron una convergencia estable sin señales de sobreajuste severo: la pérdida de entrenamiento descendió de forma sostenida mientras la pérdida de validación se estabilizó a partir de la época 5 (Figura 5). El experimento multifuente (RGB+NIR+HEIGHT) alcanzó su mejor desempeño en la época 14 con $val_mean_iou = 0,689$, deteniéndose en la época 21. La incorporación de canales adicionales produjo una convergencia ligeramente más lenta pero alcanzó métricas de validación superiores en todas las dimensiones evaluadas (Tabla 5), confirmando el aporte informativo del NIR y el *nDSM* como canales de entrada.




Figura 5. Curvas de entrenamiento del experimento control RGB: (a) pérdida de entrenamiento y validación por época, (b) métricas de validación (OA, macro F1, mean IoU) por época, (c) tasa de aprendizaje por época, y (d) F1 e IoU por clase en la mejor época




Figura 6. Curvas de entrenamiento del experimento multifuente (RGB+NIR+HEIGHT): (a) pérdida de entrenamiento y validación, (b) exactitud global y macro F1 de validación, y (c) mean IoU de validación por época

4.2.2 Evaluación en el conjunto de prueba

El modelo U-Net multifuente alcanzó en el conjunto de prueba una exactitud global de 0,904, un macro F1 de 0,716 y un *mean* IoU de 0,650, superando en todas las métricas al experimento control RGB (OA = 0,878, macro F1 = 0,702, *mean* IoU = 0,620) y al método clásico SLIC + *Random Forest* (Tabla 5).

Experimento	Mejor época	Val. <i>loss</i>	Val. OA	Val. macro F1	Val. <i>mean</i> IoU
RGB control	11	0,254	0,927	0,736	0,674
RGB+NIR+HEIGHT	14	0,246	0,939	0,739	0,689

Tabla 5. Métricas globales de validación por experimento U-Net.

El análisis por clase del experimento multifuente (Tabla 6) muestra que la clase construcción obtuvo el mejor desempeño individual con un F1 de 0,961 e IoU de 0,922. La clase fondo alcanzó F1 = 0,905 e IoU = 0,827, y pavimento obtuvo F1 = 0,882 e IoU = 0,789. La clase vegetación mostró un desempeño aceptable (F1 = 0,831, IoU = 0,710) con un *recall* de 0,861 superior a su precisión (0,802), indicando que el modelo tiende a sobreclasificar ligeramente esta categoría. La clase agua presentó nuevamente el desempeño más bajo (F1 = 0,000, IoU = 0,000), evidenciando que incluso la arquitectura profunda con entrada multifuente no logró recuperar esta clase dada su representación extremadamente escasa en el conjunto de prueba (113.099 píxeles de referencia sobre 14.634.433 de fondo).

Clase	Precisión	<i>Recall</i>	F1	IoU
Fondo	0,911	0,899	0,905	0,827
Construcción	0,966	0,961	0,961	0,922

Pavimento	0,871	0,893	0,882	0,789
Vegetación	0,802	0,861	0,831	0,710
Agua	0,000	0,000	0,000	0,000

Tabla 6. Métricas por clase, U-Net multifuente en conjunto de prueba.




Figura 7. Matriz de confusión multifuente

La matriz de confusión normalizada (Figura 7) revela los principales patrones de error del modelo multifuente. La clase fondo presenta una tasa de confusión del 8 % con pavimento, consistente con la similitud espectral entre estas dos coberturas en zonas de sombra. La clase construcción muestra una confusión del 4 % con fondo, posiblemente asociada a cubiertas de tonos oscuros o zonas con sombra proyectada. La clase vegetación presenta una confusión del 12 % con fondo y del 2 % con pavimento, indicando que la vegetación baja o dispersa sigue siendo una fuente de error incluso con la entrada multifuente. La clase agua es clasificada en un 92 % de los casos como fondo, lo que explica su F1 nulo y refleja el efecto combinado de su escasa representación y su similitud radiométrica con superficies oscuras.

4.3 Comparación entre métodos

4.3.1 Exactitud temática y geométrica

La Tabla 7 presenta la comparación directa entre el método clásico SLIC + *Random Forest* y el método de aprendizaje profundo U-Net multifuente sobre el mismo conjunto de prueba, bajo el mismo protocolo de evaluación espacialmente controlado. U-Net superó a SLIC + *Random Forest* en todas las métricas evaluadas. Las mejoras en exactitud temática fueron moderadas: +0,038 en OA, +0,031 en macro F1 y +0,056 en *mean IoU*. En contraste, las mejoras en exactitud geométrica fueron sustanciales: el *Boundary F1* multiclase aumentó en 0,194 puntos (de 0,168 a 0,362), y el *Boundary F1* específico para la clase construcción aumentó en 0,310 puntos (de 0,252 a 0,561). Estos resultados indican que la principal ventaja de U-Net sobre el flujo clásico no reside

únicamente en una mayor exactitud de clasificación, sino en una delimitación geométrica de los objetos significativamente más precisa, aspecto de especial relevancia para aplicaciones cartográficas y catastrales.

Métrica	SLIC + RF	U-Net multifuente	Diferencia
<i>Overall accuracy</i>	0,866	0,904	+0,038
Macro F1	0,685	0,716	+0,031
<i>Mean IoU</i>	0,594	0,650	+0,056
F1 construcción	0,948	0,960	+0,012
IoU construcción	0,901	0,922	+0,021
<i>Boundary F1 multiclase</i>	0,168	0,362	+0,194
<i>Boundary F1 construcción</i>	0,252	0,561	+0,310

Tabla 7. Comparación de métricas entre SLIC + Random Forest y U-Net multifuente en el conjunto de prueba.

4.3.2 Costo computacional e impacto ambiental

El análisis computacional revela un balance asimétrico entre los dos métodos con implicaciones prácticas relevantes (Tabla 8). Durante la fase de entrenamiento, SLIC + *Random Forest* demandó únicamente 56,7 segundos frente a los 4.368,7 segundos de U-Net multifuente, una diferencia de aproximadamente 77 veces. Esta disparidad se refleja también en el consumo energético del entrenamiento (0,000828 kWh vs 0,065750 kWh) y en las emisiones asociadas (0,000150 vs 0,011946 kg CO₂ equivalente). Sin embargo, el comportamiento se invierte de forma notable durante la inferencia: U-Net completó la predicción sobre el conjunto de prueba en 18,8 segundos, frente a los 317,1 segundos requeridos por SLIC + *Random Forest*, que incluyen la segmentación por tesela, la extracción de atributos y la clasificación. Esta diferencia representa una inferencia aproximadamente 17 veces más rápida para U-Net, con un consumo energético en test significativamente menor (0,000283 kWh vs 0,004802 kWh) y emisiones prácticamente despreciables (0,000052 vs 0,000872 kg CO₂ equivalente).

Indicador	SLIC + RF	U-Net multifuente
Tiempo de entrenamiento (s)	56,7	4.368,7

Energía entrenamiento (kWh)	0,000828	0,065750
Emisiones entrenamiento (kg CO₂eq)	0,000150	0,011946
Tiempo de inferencia (s)	317,1	18,8
Energía inferencia (kWh)	0,004802	0,000283
Emisiones inferencia (kg CO₂eq)	0,000872	0,000052

Tabla 8. Comparación de desempeño computacional entre métodos (medido con CodeCarbon).

Este resultado tiene una implicación práctica importante: aunque el costo de entrenamiento de U-Net es sustancialmente mayor, en escenarios de producción donde el modelo se entrena una sola vez y se aplica repetidamente sobre nuevas imágenes, la eficiencia de inferencia de U-Net representa una ventaja operativa significativa frente al flujo clásico.




Figura 8. Ejemplos de predicción del método SLIC + Random Forest sobre dos teselas del conjunto de prueba.




Figura 9. Ejemplos de predicción del método U-Net (experimento RGB) sobre dos teselas del conjunto de prueba.

La comparación cualitativa entre las Figuras 8 y 9 ilustra visualmente las diferencias geométricas capturadas por el *Boundary F1*: mientras el método SLIC + *Random Forest* produce bordes angulares y fragmentados propios de la segmentación por superpíxeles, U-Net genera contornos espacialmente más continuos y coherentes con los límites reales de las coberturas. Esta diferencia es especialmente evidente en zonas de transición entre construcción y vegetación, donde la predicción clásica tiende a sobre-segmentar generando manchas de clase errónea, mientras U-Net mantiene regiones más homogéneas.

5. DISCUSIÓN

5.1 Respuesta a la pregunta de investigación

Los resultados obtenidos permiten responder afirmativamente la pregunta de investigación: bajo un protocolo de evaluación espacialmente controlado y con datos multifuente de muy alta resolución, la arquitectura U-Net con codificador *ResNet34* preentrenado supera al flujo clásico SLIC + *Random Forest* en todas las dimensiones de desempeño evaluadas. Sin embargo, la magnitud y naturaleza de esta superioridad varía según la dimensión considerada, lo que matiza la respuesta y enriquece su interpretación práctica.

En exactitud temática, las mejoras son consistentes pero moderadas: +0,038 en exactitud global, +0,031 en macro F1 y +0,056 en *mean IoU*. Estos valores indican que ambos métodos son capaces de clasificar correctamente las coberturas dominantes del área de estudio construcción, pavimento y fondo con desempeños relativamente próximos cuando se evalúan a nivel global. Esta proximidad es relevante porque sugiere que, bajo condiciones de alta heterogeneidad urbana y validación espacialmente rigurosa, un flujo clásico bien diseñado puede aproximarse al desempeño temático de una arquitectura profunda preentrenada, al menos en las clases con mayor representación.

Donde la ventaja de U-Net se vuelve sustancial es en la exactitud geométrica de la segmentación. El *Boundary F1* multiclase aumentó en 0,194 puntos (de 0,168 a 0,362) y el *Boundary F1*

específico para la clase construcción aumentó en 0,310 puntos (de 0,252 a 0,561), representando en ambos casos más del doble del valor alcanzado por el método clásico. Este hallazgo es el más relevante del estudio desde una perspectiva aplicada: en contextos de actualización catastral y cartografía base urbana, la precisión posicional de los objetos segmentados es un criterio de calidad tan importante como la exactitud temática, y es precisamente en esta dimensión donde la capacidad de U-Net para aprender representaciones espacialmente continuas a nivel de píxel ofrece una ventaja estructural sobre la segmentación por superpíxeles.

La hipótesis sobre la eficiencia computacional se confirma solo parcialmente. U-Net demanda un costo de entrenamiento aproximadamente 77 veces mayor que SLIC + *Random Forest* en tiempo y energía, lo que representa una barrera real para su adopción en contextos con recursos computacionales limitados. Sin embargo, el comportamiento se invierte durante la inferencia: U-Net completó la predicción sobre el conjunto de prueba en 18,8 segundos frente a los 317,1 segundos del flujo clásico, una diferencia de 17 veces favorable a la arquitectura profunda. Este resultado contraintuitivo tiene implicaciones prácticas importantes: en escenarios de producción donde el modelo se entrena una sola vez y se aplica repetidamente sobre nuevas imágenes, el mayor costo inicial de entrenamiento de U-Net se amortiza rápidamente frente a su eficiencia en inferencia.

Finalmente, la comparación entre el experimento control *RGB* y el experimento multifuente confirma que la incorporación de los canales NIR y *HEIGHT (nDSM)* como entradas adicionales produjo mejoras consistentes en validación (*val_mean_iou* de 0,674 a 0,689) y en el conjunto de prueba (OA de 0,878 a 0,904, *Boundary F1* construcción de 0,460 a 0,561). Esto valida la estrategia de fusión temprana por concatenación de canales como mecanismo efectivo para integrar información espectral y altimétrica en arquitecturas encoder-decoder, y es coherente con la importancia dominante que los atributos altimétricos mostraron en el análisis de importancia de variables del *Random Forest*.

5.2 Comparación con estudios previos

Los resultados de este estudio son consistentes con la tendencia general reportada en la literatura de teledetección urbana que muestra ventajas del aprendizaje profundo sobre métodos clásicos en tareas de segmentación semántica multiclase, aunque con matices importantes que los estudios previos no siempre capturan.

La superioridad de U-Net en exactitud geométrica confirma y extiende los hallazgos de Audebert et al. (2018), quienes demostraron que las arquitecturas encoder-decoder con fusión multimodal espectral y altimétrica mejoran sistemáticamente el desempeño en clasificación urbana de muy alta resolución. La presente investigación avanza sobre ese trabajo al introducir una evaluación explícita de la calidad de los contornos mediante *Boundary F1*, dimensión que Audebert et al. (2018) no consideraron, y al operar en un contexto urbano latinoamericano de alta heterogeneidad constructiva no representado en los benchmarks europeos *ISPRS* Vaihingen y Potsdam. En este sentido, los resultados refuerzan la advertencia de Wurm et al. (2019) sobre la transferibilidad limitada de los modelos entrenados en entornos urbanos europeos hacia contextos tropicales: las métricas obtenidas bajo partición espacial bloqueada son más conservadoras que las que se reportaron bajo partición aleatoria, lo que sugiere que los valores de desempeño publicados en muchos estudios comparativos podrían estar sobreestimados por fuga espacial.

La vigencia del flujo clásico SLIC + *Random Forest* documentada en este estudio es coherente con los argumentos de Hossain & Chen (2019), quienes señalan que los enfoques orientados a objetos mantienen relevancia cuando se diseñan cuidadosamente con variables espectrales, altimétricas y geométricas complementarias. El macro F1 de 0,685 y el *mean IoU* de 0,594

alcanzados por SLIC + *Random Forest* en condiciones de validación espacialmente rigurosa representan un desempeño competitivo para un método de bajo costo computacional, especialmente considerando que su exactitud temática se aproxima a la de U-Net en las clases dominantes. Este resultado apoya la posición de Persello et al. (2022), quienes argumentan que el debate en teledetección no debería centrarse en si el aprendizaje profundo funciona, sino en bajo qué condiciones y con qué costo real frente a alternativas clásicas bien diseñadas.

La dominancia de los atributos altimétricos en el análisis de importancia de variables del *Random Forest* con los cinco primeros atributos pertenecientes a la familia HEIGHT es consistente con los resultados de Guo et al. (2019) y Zhang et al. (2021), quienes reportan que el *nDSM* presenta los mayores valores de importancia relativa en clasificadores clásicos para coberturas urbanas, superando a las bandas espectrales individuales. Este patrón refuerza el argumento metodológico de que la incorporación de datos altimétricos es una decisión de alto impacto en la separabilidad entre clases con ambigüedad radiométrica, independientemente del paradigma de clasificación utilizado.

La incapacidad de ambos métodos para recuperar la clase agua con F1 prácticamente nulo en U-Net y de 0,064 en SLIC + *Random Forest* es un resultado esperado dado el nivel de desbalance extremo de esta clase, y es coherente con la literatura sobre desbalance de clases en segmentación semántica de muy alta resolución (Buda et al., 2018). Estrategias más agresivas de balance, como sobremuestreo sintético (*SMOTE*) a nivel de superpíxel o funciones de pérdida focales (*focal loss*) con ponderación adaptativa, podrían mejorar el desempeño en clases minoritarias en experimentos futuros. Complementariamente, sería valioso comparar el flujo U-Net con arquitecturas más recientes como *DeepLabv3+* (Chen et al., 2018), *SegFormer* o redes basadas en transformadores de visión, que han demostrado mejoras sustanciales en segmentación de escenas complejas y podrían ofrecer ganancias adicionales en exactitud geométrica sobre el mismo conjunto de datos. La evaluación mediante *Boundary F1* introducida en este estudio proporciona un protocolo de comparación más informativo que el IoU estándar para futuros trabajos en este dominio (Cheng et al., 2021).

5.3 Ventajas y limitaciones

El principal aporte metodológico de este estudio reside en el diseño del protocolo comparativo: la adopción de una partición espacial bloqueada sin fuga, la evaluación simultánea de exactitud temática y geométrica, y la medición del impacto computacional y ambiental mediante *CodeCarbon* constituyen un conjunto de prácticas que, tomadas en conjunto, no han sido implementadas de forma integrada en estudios comparativos previos entre métodos clásicos y profundos para clasificación urbana de alta resolución en contextos latinoamericanos. Esta combinación permite que las conclusiones del estudio sean metodológicamente sólidas y reproducibles, y que la línea base establecida sea directamente utilizable para comparaciones futuras sobre el mismo conjunto de datos.

El uso de datos de muy alta resolución espacial (~6 cm/píxel) con cuatro bandas espectrales y *LiDAR* de alta densidad (6,63 pts/m²) en un contexto urbano andino de alta heterogeneidad representa una contribución al conjunto de evidencias disponibles sobre clasificación urbana en ciudades latinoamericanas, donde la mayoría de estudios comparativos se realizan sobre datos de resolución media o sobre los benchmarks europeos *ISPRS*. La derivación del *nDSM* como variable estructural y su integración explícita en ambos paradigmas como atributo en *Random Forest* y como canal de entrada en U-Net permite una comparación más equitativa que estudios donde la información altimétrica se incorpora sólo en uno de los métodos.

No obstante, el estudio presenta limitaciones que deben considerarse al interpretar sus resultados. En primer lugar, la clase agua no fue recuperada de forma significativa por ninguno de los dos métodos, lo que indica que las estrategias de balance adoptadas *class_weight = balanced* en *Random Forest* y *WeightedRandomSampler* en U-Net fueron insuficientes para compensar el desbalance extremo de esta clase ($< 1\%$ del área total). En segundo lugar, el experimento se desarrolla con un subconjunto de 106 ha del municipio de Tunja, lo que limita la evaluación de la capacidad de generalización de los modelos hacia otras zonas del mismo municipio o hacia otros contextos urbanos colombianos con diferentes patrones constructivos y condiciones de iluminación. En tercer lugar, el flujo SLIC + *Random Forest* no fue sometido a una búsqueda exhaustiva de hiperparámetros, lo que podría subestimar marginalmente su desempeño potencial, aunque esta decisión fue intencional para priorizar la comparabilidad entre métodos. En cuarto lugar no se documenta de manera explícita el tratamiento de casos especiales como sombras profundas, oclusiones por vegetación o errores residuales del etiquetado. Estos factores deben reconocerse como fuentes potenciales de error, en especial para clases minoritarias o de difícil delimitación. Finalmente, el estudio no incluyó arquitecturas de aprendizaje profundo más recientes como *DeepLabv3+* o modelos basados en transformadores de visión, cuyo desempeño en tareas de segmentación urbana ha demostrado superar al de U-Net estándar en varios benchmarks, lo que deja abierta la pregunta sobre el límite superior alcanzable con datos multifuente de esta resolución en el área de estudio.

6. CONCLUSIÓN

Este estudio demostró que una arquitectura U-Net con codificador *ResNet34* preentrenado y entrada multifuente (RGB+NIR+nDSM) supera a un flujo clásico SLIC + *Random Forest* en la clasificación de coberturas urbanas a partir de imágenes aéreas de muy alta resolución en Tunja, Colombia, bajo un protocolo de evaluación espacialmente controlado. La ventaja más significativa no reside en la exactitud temática global donde las diferencias son moderadas (+0,038 en OA, +0,056 en *mean IoU*) sino en la precisión geométrica de los contornos predichos, donde el *Boundary F1* para la clase construcción más que se duplicó (de 0,252 a 0,561), resultado de especial relevancia para aplicaciones de actualización catastral y cartografía base urbana. El análisis computacional reveló un resultado contraintuitivo: aunque U-Net demanda un costo de entrenamiento aproximadamente 77 veces mayor, su tiempo de inferencia es 17 veces inferior al del flujo clásico, lo que favorece su adopción en escenarios de producción de alto volumen. La incapacidad de ambos métodos para recuperar la clase agua evidencia que el desbalance extremo de clases minoritarias constituye el principal reto no resuelto del experimento, y motiva el desarrollo de estrategias de muestreo sintético y funciones de pérdida adaptativas en trabajos futuros. Los resultados establecen una línea base metodológica y cuantitativa reproducible para la clasificación urbana de alta resolución en contextos latinoamericanos, y abren rutas de investigación hacia la evaluación de arquitecturas más recientes como *DeepLabv3+* o modelos basados en transformadores de visión sobre el mismo conjunto de datos.

7. BIBLIOGRAFÍA

Achanta et al. (2012)

Achanta, R., Shaji, A., Smith, K., Lucchi, A., Fua, P., & Süsstrunk, S. (2012). SLIC superpixels compared to state-of-the-art superpixel methods. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 34(11), 2274–2282. <https://doi.org/10.1109/TPAMI.2012.120>

Audebert et al. (2018)

Audebert, N., Le Saux, B., & Lefèvre, S. (2018). Beyond RGB: Very high resolution urban remote sensing with multimodal deep networks. *ISPRS Journal of Photogrammetry and Remote Sensing*, 140, 20–32. <https://doi.org/10.1016/j.isprsjprs.2017.11.011>

Ronneberger et al. (2015)

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. En N. Navab, J. Hornegger, W. Wells & A. Frangi (Eds.), *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015* (Lecture Notes in Computer Science, vol. 9351, pp. 234–241). Springer. https://doi.org/10.1007/978-3-319-24574-4_28

Zhu et al. (2017)

Zhu, X. X., Tuia, D., Mou, L., Xia, G.-S., Zhang, L., Xu, F., & Fraundorfer, F. (2017). Deep learning in remote sensing: A comprehensive review and list of resources. *IEEE Geoscience and Remote Sensing Magazine*, 5(4), 8–36. <https://doi.org/10.1109/MGRS.2017.2762307>

Ma et al. (2019)

Ma, L., Liu, Y., Zhang, X., Ye, Y., Yin, G., & Johnson, B. A. (2019). Deep learning in remote sensing applications: A meta-analysis and review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 152, 166–177. <https://doi.org/10.1016/j.isprsjprs.2019.04.015>

Zhong et al. (2023)

Zhong, M., Li, X., Zhang, J., & Liu, Y. (2023). A hybrid linear clustering framework for superpixel decomposition applied to semantic segmentation in traffic scenes. *IEEE Transactions on Intelligent Transportation Systems*, 24(3), 3112–3125. <https://doi.org/10.1109/TITS.2022.3224451>

Kattenborn et al. (2022)

Kattenborn, T., Schiefer, F., Frey, J., Feilhauer, H., Mahecha, M. D., & Dormann, C. F. (2022). Spatially autocorrelated training and validation samples inflate performance assessment of convolutional neural networks. *ISPRS Open Journal of the Geo-Information*, 1(1), 100–120. <https://doi.org/10.1016/j.ophoto.2022.100018>

Wurm et al. (2019)

Wurm, M., Stark, T., Zhu, X. X., Weigand, M., & Taubenböck, H. (2019). Semantic segmentation of slums in satellite images using transfer learning on fully convolutional neural networks. *ISPRS Journal of Photogrammetry and Remote Sensing*, 150, 59–69. <https://doi.org/10.1016/j.isprsjprs.2019.02.006>

Persello et al. (2022)

Persello, C., Wegner, J. D., Hänsch, R., Tuia, D., Ghamisi, P., Koeva, M., & Camps-Valls, G. (2022). Deep learning and earth observation to support the sustainable development goals: Current approaches, open challenges, and future opportunities. *IEEE Geoscience and Remote Sensing Magazine*, 10(2), 172–200. <https://doi.org/10.1109/MGRS.2021.3136100>

Chen et al. (2024)

Chen, Z., et al. (2024). Overcoming the uncertainty challenges in detecting building changes from remote sensing images. *ISPRS Journal of Photogrammetry and Remote Sensing*, 208, 103751. <https://doi.org/10.1016/j.isprsjprs.2024.103751>

Hossain & Chen (2019)

Hossain, M. D., & Chen, D. (2019). Segmentation for object-based image analysis (OBIA): A review of algorithms and challenges from remote sensing perspective. *ISPRS Journal of Photogrammetry and Remote Sensing*, 150, 115–134.
<https://doi.org/10.1016/j.isprsjprs.2019.02.009>

Zhang et al. (2021)

Zhang, Z., et al. (2021). Three-dimensional urban land cover classification by prior-level fusion of LiDAR point cloud and optical imagery. *Remote Sensing*, 13(23), 4928.
<https://doi.org/10.3390/rs13234928>

Wadoux et al. (2021)

Wadoux, A. M. J.-C., Heuvelink, G. B. M., de Bruin, S., & Brus, D. J. (2021). Spatial cross-validation is not the right way to evaluate map accuracy. *Ecological Modelling*, 457, 109692.
<https://doi.org/10.1016/j.ecolmodel.2021.109692>

ISPRS (2024)

ISPRS. (2024). *ISPRS 2D semantic labeling benchmark* [Dataset]. International Society for Photogrammetry and Remote Sensing.
<https://www.isprs.org/education/benchmarks/UrbanSemLab/>

Toth, C., & Józków, G. (2016).

Remote sensing platforms and sensors: A survey. *ISPRS Journal of Photogrammetry and Remote Sensing*, 115, 22–36. <https://doi.org/10.1016/j.isprsjprs.2015.10.004>

Guo, L., Chehata, N., Mallet, C., & Boukir, S. (2019).

Integrated airborne *LiDAR* data and imagery for suburban land cover classification using machine learning methods. *Remote Sensing*, 11(9), 1996. <https://doi.org/10.3390/rs11091996>

Blaschke, T. (2010).

Object based image analysis for remote sensing. *ISPRS Journal of Photogrammetry and Remote Sensing*, 65(1), 2–16. <https://doi.org/10.1016/j.isprsjprs.2009.06.004>

Belgiu, M., & Drăguț, L. (2016).

Random forest in remote sensing: A review of applications and future directions. *ISPRS Journal of Photogrammetry and Remote Sensing*, 114, 24–31. <https://doi.org/10.1016/j.isprsjprs.2016.01.011>

Strobl, C., Boulesteix, A.-L., Zeileis, A., & Hothorn, T. (2007).

Bias in random forest variable importance measures: Illustrations, sources and a solution. *BMC Bioinformatics*, 8, 25. <https://doi.org/10.1186/1471-2288-8-25>

Courty, B., et al. (2023). *CodeCarbon: Estimate and track carbon emissions from machine learning computing*. <https://doi.org/10.48550/arXiv.2002.05651>

Buda, M., Maki, A., & Mazurowski, M. A. (2018).

A systematic study of the class imbalance problem in convolutional neural networks. *Neural Networks*, 106, 249–259. <https://doi.org/10.1016/j.neunet.2018.07.011>

He, K., Zhang, X., Ren, S., & Sun, J. (2016).

Deep residual learning for image recognition. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 770–778). <https://doi.org/10.1109/CVPR.2016.90>

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009).

ImageNet: A large-scale hierarchical image database. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 248–255). <https://doi.org/10.1109/CVPR.2009.5206848>

Ioffe, S., & Szegedy, C. (2015).

Batch normalization: Accelerating deep network training by reducing internal covariate shift. En *Proceedings of the 32nd International Conference on Machine Learning (ICML)* (pp. 448–456). <https://doi.org/10.48550/arXiv.1502.03167>

Loshchilov, I., & Hutter, F. (2019).

Decoupled weight decay regularization. En *Proceedings of the 7th International Conference on Learning Representations (ICLR)*. <https://openreview.net/forum?id=Bkg6RiCqY7>

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... & Chintala, S. (2019).

PyTorch: An imperative style, high-performance deep learning library. En *Advances in Neural Information Processing Systems (NeurIPS 2019)*, 32, 8026–8037. <https://papers.nips.cc/paper/2019/hash/bdca288fee7f92f2bfa9f7012727740-Abstract.html>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <https://jmlr.org/papers/v12/pedregosa11a.html>

Chen et al. (2018) — DeepLabv3+: Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., & Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. En *Proceedings of ECCV 2018* (pp. 801–818). https://doi.org/10.1007/978-3-030-01234-2_49

ANEXOS:

Tabla comparativa final

	metrica	slic_rf	UNET_multifuente	UNET_menos_slc_rf
0	overall_acc	0.865507	0.903976	0.038469
1	macro_f1	0.684852	0.715829	0.030977
2	mean_iou	0.593707	0.649553	0.055846
3	f1_construccion	0.947879	0.959620	0.011741
4	iou_construccion	0.900922	0.922374	0.021452
5	boundary_f1_multiclass	0.167865	0.362221	0.194356
6	boundary_f1_construccion	0.251661	0.561411	0.309750
7	train_wall_time_sec	56.698058	4368.701700	4312.003642
8	train_energy_kwh	0.000828	0.065750	0.064922
9	train_emissions_kgco2eq	0.000150	0.011946	0.011796
10	test_wall_time_sec	317.083823	18.827658	-298.256165
11	test_energy_kwh	0.004802	0.000283	-0.004519
12	test_emissions_kgco2eq	0.000872	0.000052	-0.000820

Tabla 2. Parámetros del método SLIC

Parámetro	Valor ejecutado	Observación
-----------	-----------------	-------------

Algoritmo	SLIC	Segmentación por superpíxeles
Canales usados para SLIC	RGB	La variable HEIGHT no se usó para generar los superpíxeles
n_segments	500	Número esperado de segmentos por tesela
compactness	1.0	Controla la regularidad espacial del superpíxel
sigma	1.0	Suavizado previo
start_label	1	Etiquetado de segmentos desde 1
channel_axis	-1	Canales al final del arreglo
convert2lab	True	Aplicado por ser entrada RGB
enforce_connectivity	True	Mantiene conectividad espacial
HEIGHT dentro de SLIC	No	HEIGHT se usó como atributo posterior
NDVI dentro de SLIC	No	NDVI se usó como atributo posterior

Tabla 3. Configuración del Random Forest

Hiperparámetro	Valor ejecutado	Observación
Modelo	RandomForestClassifier	Clasificador supervisado usado sobre atributos por superpíxel.
n_estimators	300	Número de árboles del bosque.
max_depth	30	Profundidad máxima permitida para cada árbol.
min_samples_leaf	2	Número mínimo de muestras requeridas en una hoja.
max_features	sqrt	Número de variables consideradas en cada división.
class_weight	balanced	Manejo del desbalance entre clases.
random_state	42	Semilla usada para favorecer la reproducibilidad.
n_jobs	-1	Uso de todos los núcleos disponibles.

Variables predictoras	43	Atributos derivados por superpíxel.
-----------------------	----	-------------------------------------

Tabla 4. Distribución de clases a nivel de superpíxel

Clase	Train n	Train %	Val n	Val %
Fondo	212.127	33,51 %	53.412	33,08 %
Construcción	204.120	32,24 %	50.072	31,01 %
Pavimento	206.551	32,63 %	55.918	34,63 %
Vegetación	8.848	1,40 %	1.586	0,98 %
Agua	1.404	0,22 %	463	0,29 %


Tabla 5. Configuración general del modelo U-Net

Componente	Configuración RGB	Configuración multifuente
Arquitectura	U-Net	U-Net
Librería	segmentation_models_pytorch	segmentation_models_pytorch
Encoder	ResNet34	ResNet34
Pesos preentrenados	ImageNet	ImageNet adaptado
Canales de entrada	3	5
Variables de entrada	RGB	RGB + NIR + HEIGHT
Clases de salida	5	5
Activación final	None	None
Tamaño de parche	256 × 256	256 × 256
Batch size	8	8
Entrenamiento desde cero	No	No
Encoder preentrenado	Sí	Sí
Adaptación de primera convolución	No aplica	Sí, de 3 a 5 canales

Tabla 6. Hiperparámetros de entrenamiento de U-Net

Hiperparámetro	Valor
Función de pérdida	CrossEntropyLoss
ignore_index	255
Pesos de clase	Sí
Muestreo ponderado	WeightedRandomSampler
Optimizador	AdamW
Learning rate inicial	0,0001
weight_decay	0,0001
Scheduler	ReduceLROnPlateau
Métrica monitoreada	val_mean_iou
Early stopping	Sí
Paciencia early stopping	7 épocas
Épocas máximas	25
AMP	False

Matriz de confusion normalizada TEST



ESTO ES PARA LA EXPO.....IGNORAR

El diseño experimental adoptado garantiza que las diferencias observadas en desempeño entre el método clásico SLIC + *Random Forest* y el método de aprendizaje profundo U-Net sean atribuibles a los modelos y no a asimetrías en el protocolo de evaluación. Ambos métodos comparten: el mismo conjunto de insumos raster (ortofoto RGB+NIR y *nDSM*), el mismo esquema de clases semánticas e *ignore_index*, el mismo esquema de partición espacial bloqueada (70/15/15 sobre el eje x), el mismo teselado (256×256 px, *stride* = 256), y las mismas métricas de evaluación aplicadas sobre el mismo raster de prueba reconstruido a resolución de píxel.

Las únicas diferencias intencionales entre métodos son las inherentes a cada paradigma: el método clásico opera sobre atributos estadísticos por superpíxel e incorpora NDVI como variable adicional, mientras que U-Net opera directamente sobre tensores de píxeles sin extracción manual de características y no incorpora NDVI como canal de entrada. Estas diferencias son precisamente el objeto de comparación del estudio y no constituyen sesgos experimentales.

Esta estructura permite que el experimento funcione como una comparación controlada y reproducible, alineada con las recomendaciones metodológicas para estudios comparativos en teledetección que enfatizan la necesidad de protocolos de evaluación equivalentes para conclusiones válidas (Persello et al., 2022; Kattenborn et al., 2022). La Tabla 3 resume las principales decisiones metodológicas de ambos enfoques.