

Documento de control de cambios del proyecto

Autor: Sara Geraldine Alarcón Prieto

Programa: Maestría en Geomática

Proyecto: Modelo de aprendizaje profundo para la segmentación semántica de edificaciones

Versiones comparadas:

- Versión 1 (V1): Borrador inicial con idea de vectorización
- Versión 2 (V2): Ajuste con comparación CNN vs SVM
- Versión 3 (V3): Versión definitiva

1. Alcance general y título

V1

- Título centrado en:

“Modelo basado en Deep Learning para la identificación y vectorización de edificaciones mediante el uso combinado de imágenes aéreas y datos LiDAR.”
- Enfoque: identificación y vectorización de edificaciones, con énfasis en interferencia vegetal.

V2

- Título ajustado hacia:

“Modelo de deep learning basado en redes convolucionales (CNN) para la segmentación semántica de edificaciones a partir de imágenes aéreas y datos LiDAR.”
- Enfoque: comparación explícita entre CNN y una línea base clásica (SVM).

V3 (actual)

- Título final:

“Modelo de aprendizaje profundo para la segmentación semántica de edificaciones a partir de imágenes aéreas y datos LiDAR.”
- Enfoque: modelo de aprendizaje profundo que integra progresivamente:
 - (A) solo imágenes aéreas,
 - (B) imágenes + LiDAR,
 - (C) imágenes + LiDAR + atributos OBIA.

- Se elimina la comparación directa con SVM como objetivo central.

Motivo del cambio

Centrar el proyecto en un modelo profundo sólido y bien diseñado, con énfasis en el aporte incremental de LiDAR y OBIA, en lugar de dispersar el esfuerzo en comparar contra SVM.

2. Objetivos

V1 – Objetivos iniciales

- General: desarrollo de un modelo DL para identificación y vectorización de edificaciones con imágenes + LiDAR.
- Específicos:
 1. Seleccionar una arquitectura DL y realizar pruebas con imágenes + LiDAR.
 2. Desarrollar un flujo computacional para procesamiento, segmentación y vectorización.
 3. Evaluar exactitud y eficiencia computacional.

V2 – Objetivos intermedios

- General: modelo de DL basado en CNN para segmentación semántica de edificaciones.
- Específicos:
 1. Seleccionar y contrastar SVM (línea clásica) vs CNN (línea profunda) con imágenes + derivados LiDAR.
 2. Desarrollar un flujo computacional que integre óptico + altimétrico.
 3. Evaluar exactitud y eficiencia, incluyendo comparación CNN vs SVM y nociones de huella (tiempo, energía, CO₂e).

V3 – Objetivos finales

- **Objetivo general**

Desarrollar un modelo de aprendizaje profundo para la segmentación semántica de edificaciones a partir de imágenes aéreas, incorporando progresivamente información LiDAR y atributos derivados de OBIA.

- **Objetivos específicos**

1. Seleccionar arquitecturas de deep learning y realizar pruebas de segmentación semántica a partir de imágenes aéreas.
2. Diseñar e implementar un flujo computacional que integre progresivamente imágenes aéreas, información LiDAR y atributos derivados de OBIA.
3. Evaluar la exactitud y eficiencia computacional del modelo.

Motivo del cambio

- Se elimina la comparación explícita con SVM y se prioriza el análisis interno del modelo profundo bajo tres escenarios de entrada.
- Se incorpora explícitamente OBIA dentro de los objetivos.
- Se mantiene la evaluación de exactitud y eficiencia, pero como soporte al desarrollo del modelo, no como eje “Green AI” principal.

3. Área de estudio y datos

V1

- Área de estudio: Valledupar (Cesar), con alta cobertura vegetal.
- Datos: ortoimágenes y LiDAR de alta resolución, planteados de forma genérica (principalmente referencia a datos oficiales/IGAC).

V2

- Se mantiene la idea general (ciudad con vegetación e interferencia), sin consolidar aún el cambio de ciudad ni el origen real de los insumos.

V3 (actual)

- Área de estudio: ciudad de Tunja.
- Datos:
 - Ortoimagen de resolución ~10 cm,
 - Nube de puntos LiDAR y derivados (DTM, DSM, nDSM),
 - Cartografía básica 1:1 000 (huellas de edificaciones),
 - Todos estos insumos son proporcionados por la empresa GEOMÁTICA MONCALEANO SAEZ S.A.S.
- La vegetación ya no es el eje central del problema; la dificultad se asocia más a la complejidad del tejido urbano, oclusiones y geometrías, aunque pueda existir alguna cobertura vegetal.

4. Planteamiento del problema y justificación

V1

- Problema formulado en torno a edificaciones parcialmente cubiertas por vegetación, con fuerte énfasis en interferencia vegetal y ciudades tropicales.
- Justificación centrada en demostrar que la combinación de imágenes + LiDAR mejora la detección en contextos con vegetación.

V2

- Se añade el componente comparativo CNN vs SVM, y la idea de reportar también medidas de eficiencia y huella (tiempo, energía, CO₂e).

V3 (actual)

- El problema se reformula así (en esencia):
 - No se conoce con precisión en qué medida la incorporación progresiva de LiDAR y de atributos OBIA mejora la segmentación de edificaciones frente a usar solo la ortoimagen en una ciudad intermedia colombiana como Tunja.
- Justificación:
 - Relevancia científica: integración controlada de espectral + altimétrico + atributos de objeto en un mismo modelo profundo, con tres escenarios comparables.
 - Se mantiene el componente de eficiencia computacional, pero como complemento (no como objetivo comparativo SVM vs CNN).

Motivo del cambio

Concentrar la pregunta de investigación en el aporte incremental de cada fuente de datos (imágenes, LiDAR, OBIA) en un contexto colombiano concreto, sin dispersar el objetivo en demasiadas comparaciones.

5. Metodología (materiales y métodos)

V1

- Fases centradas en:
 1. Selección y prueba de una arquitectura DL.
 2. Desarrollo del flujo computacional (preprocesamiento, entrenamiento, segmentación).
 3. Vectorización de edificaciones.
 4. Evaluación de exactitud (comparando con y sin LiDAR).
- Área de estudio: Valledupar; datos IGAC genéricos; sin OBIA.

V2

- Metodología reorganizada para:
 - Comparar SVM vs CNN,
 - Enfatizar la evaluación de exactitud + eficiencia/huella,
 - Seguir usando ortofoto + derivados LiDAR, sin integrar todavía OBIA en el modelo.

V3 (actual)

Metodología reorganizada en 3 fases ligadas directamente a los objetivos:

- Fase 1 – Selección de arquitecturas (OE1)

- Pruebas de arquitecturas (U-Net, DeepLab, SegNet, etc.) con datasets de referencia y entorno controlado (incluyendo Docker).
 - El objetivo es elegir 1-2 arquitecturas viables para aplicar luego a Tunja, sin usar aún los datos del caso de estudio.
- Fase 2 – Flujo computacional con integración progresiva (OE2)
 - Preparación de datos de Tunja (ortoimagen, LiDAR, cartografía 1:1 000) y construcción de máscaras de edificaciones.
 - Derivación de productos LiDAR (DTM, DSM, nDSM).
 - Diseño y cálculo de atributos OBIA (forma, altura por objeto, textura, contexto) y su rasterización como canales adicionales.
 - Implementación de los tres escenarios:
 - A: solo imágenes,
 - B: imágenes + LiDAR,
 - C: imágenes + LiDAR + OBIA.
 - Desarrollo del pipeline completo en Docker (preprocesamiento, dataloaders, entrenamiento, registro de resultados).
- Fase 3 – Evaluación de exactitud y eficiencia (OE3)
 - Cálculo de IoU, F1, etc., para cada escenario (A, B y C) sobre el conjunto de prueba con particiones espaciales sin fuga.
 - Medición de tiempos de entrenamiento, inferencia y uso de memoria en la GPU NVIDIA T1 000 8 GB.
 - Análisis del aporte incremental de LiDAR y OBIA y recomendaciones sobre qué configuración usar según recursos y nivel de precisión requerido.
- Materiales y recursos actualizados
 - Hardware: PC de laboratorio de la universidad con GPU Intel UHD 770 y NVIDIA T1 000 8 GB.
 - Software: Python + librerías de DL, QGIS/otro SIG, herramientas OBIA y entorno ejecutado mediante contenedores Docker.

Motivo del cambio

- Integrar explícitamente la Fase 0 de preparación de datos dentro de la Fase 2 (flujo para Tunja), para que no quede “flotando”.
- Separar claramente:
 - la selección de arquitectura (más general, con datasets de referencia) y
 - la aplicación concreta a Tunja con integración de LiDAR y OBIA.
- Añadir Docker como elemento clave de reproducibilidad y portabilidad del experimento.

6. Resultados esperados

V1

- Modelo de segmentación que combine imágenes + LiDAR para edificaciones parcialmente cubiertas por vegetación.

- Flujo de trabajo automatizado.
- Capas vectoriales de edificaciones y evaluación de exactitud.
- Repositorio público con código y documentación.

V2

- Misma línea, pero incorporando comparación CNN vs SVM y reporte más detallado de eficiencia y huella computacional.

V3 (actual)

- Desarrollo de un modelo operativo de segmentación de edificaciones para Tunja, entrenado bajo tres escenarios (A, B, C).
- Evidencia cuantitativa clara del aporte de LiDAR y de OBIA frente al uso exclusivo de la ortoimagen.
- Pipeline reproducible implementado en Docker, con guías para replicar el experimento.
- Conjunto de productos geoespaciales (insumos procesados, segmentaciones y, cuando aplique, huellas vectorizadas).
- Documentación técnica y académica (tesis + guía técnica) que permita adaptar la metodología a otras ciudades intermedias colombianas.

Motivo del cambio

Dar más peso a la **metodología transferible y al modelo final** que a la sola evaluación; enfatizar la posibilidad de reutilizar el flujo en otros contextos similares.