

**Macroproceso: Formación**

**Proceso: Gestión Administrativa de apoyo a la Formación**

**Formato: Proyecto de Tesis de maestría investigación**

**Estudiante: Sara Geraldine Alarcón Prieto**



UNIVERSIDAD  
**NACIONAL**  
DE COLOMBIA

## **INFORMACIÓN DEL PROYECTO**

### **PROYECTO DE TESIS DE MAESTRÍA**

**TÍTULO:** “Modelo basado en Deep Learning para la identificación y vectorización de edificaciones mediante imágenes aéreas y datos LiDAR”

### **DESCRIPCIÓN DEL PROYECTO**

#### **1. Resumen del proyecto (inglés y español)**

El presente proyecto desarrollara un modelo de segmentación semántica basado en técnicas de Deep Learning para la identificación y vectorización de edificaciones que presentan interferencia de cobertura vegetal, utilizando de manera combinada imágenes aéreas y datos LiDAR. Esta investigación parte del reto que representa detectar construcciones parcialmente ocultas por vegetación, una limitante común en el análisis urbano y rural a partir de datos ópticos tradicionales. La metodología contempla, en primer lugar, la selección y prueba de una arquitectura de Deep Learning con reconocido desempeño en tareas de segmentación semántica. Posteriormente, se diseñará un flujo computacional que integre el preprocesamiento de imágenes aéreas y datos LiDAR, el entrenamiento del modelo con datos etiquetados y a partir de los resultados del modelo, se realizará la vectorización de las áreas segmentadas para obtener entidades espaciales georreferenciadas. Finalmente, se evaluará la exactitud comparando el desempeño con y sin la incorporación de datos LiDAR. Se espera que los resultados permitan demostrar que la integración de imágenes aéreas con datos LiDAR mejora significativamente la exactitud en la segmentación semántica de edificaciones en entornos con alta interferencia vegetal. El impacto del proyecto interviene en diferentes aspectos, desde un aporte de evidencias y metodologías replicables en el campo de la visión computacional aplicada a datos geoespaciales, la actualización catastral y la planificación territorial hasta optimizar el uso de tecnologías emergentes para la caracterización de

infraestructura física, reduciendo tiempos y costos frente a métodos tradicionales de levantamiento.

This project will develop a semantic segmentation model based on Deep Learning techniques for the identification and vectorization of buildings with vegetation cover interference, using a combination of aerial images and LiDAR data. This research is based on the challenge of detecting buildings partially hidden by vegetation, a common limitation in urban and rural analysis from traditional optical data. The methodology contemplates, first, the selection and testing of a Deep Learning architecture with recognized performance in semantic segmentation tasks. Subsequently, a computational flow will be designed that integrates the preprocessing of aerial images and LiDAR data, the training of the model with labeled data and from the results of the model, the vectorization of the segmented areas will be performed to obtain georeferenced spatial entities. Finally, accuracy will be evaluated by comparing the performance with and without the incorporation of LiDAR data. The results are expected to demonstrate that the integration of aerial images with LiDAR data significantly improves the accuracy in the semantic segmentation of buildings in environments with high vegetation interference. The impact of the project involves different aspects, from a contribution of evidence and replicable methodologies in the field of computer vision applied to geospatial data, cadastral updating and territorial planning to optimizing the use of emerging technologies for the characterization of physical infrastructure, reducing time and costs compared to traditional survey methods.

## **2. Introducción (Revisión de Literatura y marco teórico)**

### **2.1. Identificación y vectorización de edificaciones en entornos urbanos**

La identificación automatizada de edificaciones en entornos urbanos constituye una herramienta clave para abordar los desafíos asociados con la planificación territorial, la gestión del catastro y el monitoreo del crecimiento urbano. En ciudades que enfrentan procesos acelerados de transformación espacial, contar con información detallada y actualizada sobre las estructuras construidas permite tomar decisiones informadas en temas como movilidad, uso del suelo, gestión de servicios públicos y riesgo urbano. Según Biljecki et al. (2015), el modelado preciso de edificaciones contribuye al desarrollo de ciudades inteligentes, facilita

la interoperabilidad de bases de datos urbanas y fortalece la gobernanza espacial. En Colombia, entidades como el IGAC (2020) han enfatizado la necesidad de actualizar el catastro mediante metodologías automatizadas que aseguren cobertura, calidad y oportunidad de la información geoespacial.

## **2.2 Deep Learning en segmentación semántica de edificaciones**

El surgimiento de modelos basados en Deep Learning ha revolucionado la segmentación de imágenes geoespaciales, permitiendo abordar con alta exactitud tareas complejas como la identificación de edificaciones. Modelos como U-Net (Ronneberger et al., 2015) y DeepLabV3 han sido adaptados exitosamente para imágenes aéreas y satelitales, logrando buenos niveles de desempeño en la segmentación de techos urbanos. A diferencia de los enfoques tradicionales de clasificación supervisada, estas arquitecturas permiten aprender jerarquías de características espaciales y asignar etiquetas clase por píxel, una ventaja clave en contextos urbanos heterogéneos (Zhu et al., 2017; Li et al., 2020). Las métricas más comunes para evaluar su rendimiento incluyen la intersección sobre la unión (IoU), precisión, recall y la F1-score, utilizadas ampliamente en literatura científica y en desafíos internacionales de teledetección.

## **2.3 Limitaciones de los modelos de Deep Learning en presencia de vegetación**

A pesar del éxito de estos modelos, su desempeño tiende a disminuir en entornos con alta interferencia visual provocada por vegetación. En áreas tropicales, la cobertura arbórea puede ocultar parcial o totalmente las cubiertas de edificaciones, dificultando su detección. Este problema se traduce en ambigüedad espectral, ya que el color y textura del follaje pueden confundirse con los materiales constructivos, especialmente en imágenes RGB. Además, la pérdida de bordes definidos y la fragmentación estructural afectan negativamente los resultados de segmentación (Audebert et al., 2018). Estudios como el de Kampffmeyer et al. (2016) demuestran que, en estos escenarios, los modelos tradicionales presentan altos niveles de falsos positivos y negativos, lo cual compromete la confiabilidad de los mapas resultantes.

## **2.5 Datos LiDAR en modelos de segmentación**

El uso de sensores LiDAR (Light Detection and Ranging) ha demostrado ser una alternativa efectiva para mejorar la detección de edificaciones en áreas con cobertura vegetal. Este tipo de sensor permite capturar información

tridimensional precisa, útil para distinguir elementos estructurales elevados como techos de vegetación circundante, incluso cuando ambos presentan características espectrales similares. A través de la generación de modelos digitales de superficie (DSM), modelos digitales del terreno (DTM) y modelos de altura del dosel (CHM), es posible incorporar una dimensión altimétrica al análisis espacial (Lin et al., 2019; Qi et al., 2017). Según Chen et al. (2021), la inclusión de datos LiDAR mejora significativamente los resultados de segmentación semántica en entornos complejos, al aportar información estructural adicional que complementa los datos espectrales.

## **2.6 Modelos multibanda y multientrada: integración RGB + LiDAR**

La integración de múltiples fuentes de datos en modelos de Deep Learning ha dado lugar al desarrollo de arquitecturas multibanda o multientrada, donde imágenes RGB y datos LiDAR se procesan de forma conjunta. Esta fusión puede realizarse en etapas tempranas (entrada conjunta al modelo) o en capas profundas (fusión de características), dependiendo del diseño de la red. En el caso de la segmentación de edificaciones, estos enfoques permiten que el modelo aproveche tanto la información espectral como la altimétrica para generar resultados más robustos en presencia de vegetación (Audebert et al., 2018; Chen et al., 2021). Investigaciones recientes en el contexto colombiano (Reyes et al., 2023) han demostrado que los modelos híbridos con entrada multibanda superan en exactitud a aquellos entrenados únicamente con imágenes RGB.

## **2.7 Evaluación del desempeño de modelos en segmentación**

La validación del desempeño de los modelos entrenados debe realizarse mediante métricas cuantitativas que permitan evaluar su exactitud y aplicabilidad en distintos tipos de cobertura. El uso de IoU (Intersection over Union), F1-score, precision y recall (Sensibilidad/ Tasa de Verdaderos Positivos) permite medir la correspondencia entre las segmentaciones generadas y las referencias de verdad de campo. Además, es fundamental diferenciar el análisis en zonas con y sin interferencia vegetal, con el fin de identificar fortalezas y limitaciones del modelo en escenarios reales de implementación (Rodríguez & Gómez, 2021; Chen et al., 2021). Esta evaluación crítica permite establecer criterios metodológicos aplicables al diseño de soluciones automatizadas en catastro, planificación urbana y monitoreo territorial en Colombia.

### 3. Planteamiento del problema

La identificación automatizada de edificaciones a partir de imágenes se ha consolidado como una herramienta fundamental para la planificación urbana, el catastro, y el monitoreo del desarrollo territorial. En este contexto, los métodos basados en Deep Learning especialmente los enfoques de segmentación semántica y detección de objetos han demostrado un desempeño sobresaliente en entornos urbanos densos y homogéneos (Zhu et al., 2017; Li et al., 2020). Sin embargo, su efectividad disminuye significativamente en escenarios donde existe interferencia visual generada por vegetación, como ocurre en ciudades tropicales con cobertura arbórea moderada. La presencia de dicha vegetación en zonas urbanas pueden provocar obstrucción parcial de las cubiertas, ambigüedad espectral y pérdida de bordes claros, lo que afecta la exactitud de la captura (Audebert et al., 2018; Kampffmeyer et al., 2016).

En Países como Colombia, donde muchas ciudades intermedias combinan crecimiento urbano con vegetación natural, este problema se vuelve particularmente crítico. Pese a ello, existe una escasez de estudios que evalúen de manera sistemática cómo la interferencia vegetal afecta la exactitud de los modelos de Deep Learning en contextos urbanos tropicales. Esta brecha limita tanto la aplicabilidad práctica de dichos modelos como el diseño de estrategias metodológicas adaptadas a entornos con alta heterogeneidad visual.

Este proyecto se enfoca en el desarrollo de un modelo de Deep Learning para la identificación y vectorización de edificaciones en ciudades tropicales colombianas, incorporando como entrada tanto fotografías aéreas como datos LiDAR. Esta integración busca enriquecer la representación espacial y estructural de las edificaciones, especialmente en entornos urbanos con alta interferencia visual causada por cobertura vegetal.

### 4. Justificación

La creciente necesidad de información espacial precisa ha llevado a adoptar métodos automatizados para la detección y vectorización de edificaciones en entornos urbanos con aplicaciones en diferentes campos (Biljecki et al., 2015). Los modelos de Deep Learning, especialmente aquellos basados en segmentación semántica como U-Net (Ronneberger et al., 2015), FCN (Long et al., 2015), y DeepLabv3+ (Chen et al., 2018) y por último la idea de reemplazar

completamente las redes convolucionales está el transformer (Vaswani et al., 2017) han demostrado un desempeño notable en ciudades con estructuras compactas, bordes definidos y baja interferencia visual (Zhu et al., 2017; Li et al., 2020).

Sin embargo, su eficacia se reduce considerablemente en entornos urbanos tropicales donde la vegetación interfiere visualmente con las cubiertas edificadas. Este fenómeno genera ambigüedad espectral, pérdida de continuidad estructural y falsos positivos o negativos en la segmentación (Audebert et al., 2018; Kampffmeyer et al., 2016). En estos escenarios, los árboles pueden ocultar techos parcial o totalmente, dificultando la identificación precisa incluso en imágenes de alta resolución (Chen et al., 2021). En Colombia, esta situación es crítica debido a la presencia de ciudades intermedias con abundante vegetación natural integrada al entorno urbano (DANE, 2022; IDEAM, 2020).

A pesar de la disponibilidad de datos satelitales y modelos preentrenados, la literatura evidencia una escasez de estudios que evalúen de manera sistemática el efecto de la cobertura vegetal sobre la exactitud de modelos de segmentación y detección en contextos urbanos tropicales (Reyes et al., 2023; Rodríguez & Gómez, 2021). Esta brecha limita la aplicabilidad de estas metodologías en proyectos de catastro multipropósito o monitoreo territorial en zonas con alta heterogeneidad visual.

En este contexto, la integración de datos altimétricos provenientes de sensores LiDAR representa una oportunidad significativa para enriquecer la entrada de los modelos, al proporcionar información tridimensional que permite diferenciar estructuras verticales como edificaciones y vegetación (Lin et al., 2019; Qi et al., 2017). Al combinar imágenes aéreas ortorrectificadas con datos LiDAR procesados como el modelo digital de elevación y el de terreno, es posible entrenar modelos de segmentación más robustos y adaptados al contexto colombiano. Este proyecto propone el entrenamiento de un modelo basado en Deep Learning multientrada (Imágenes aéreas + LiDAR), con el objetivo de mejorar la identificación y vectorización de edificaciones bajo condiciones de interferencia vegetal.

## 5. Pregunta de Investigación

¿En qué medida la combinación de datos LiDAR y fotografías aéreas incrementa la exactitud en la segmentación semántica y vectorización de edificaciones mediante un modelo de Deep Learning?

## 6. Objetivos

General:

Desarrollar un modelo basado en Deep Learning para la identificación y vectorización de edificaciones mediante el uso combinado de imágenes aéreas y datos LiDAR.

Específicos:

1. Seleccionar una arquitectura Deep Learning y realizar pruebas de segmentación semántica a partir de imágenes aéreas y datos LiDAR.
2. Desarrollar un flujo computacional para el procesamiento de datos, segmentación semántica y vectorización de las edificaciones.
3. Evaluar la exactitud y eficiencia computacional del modelo.

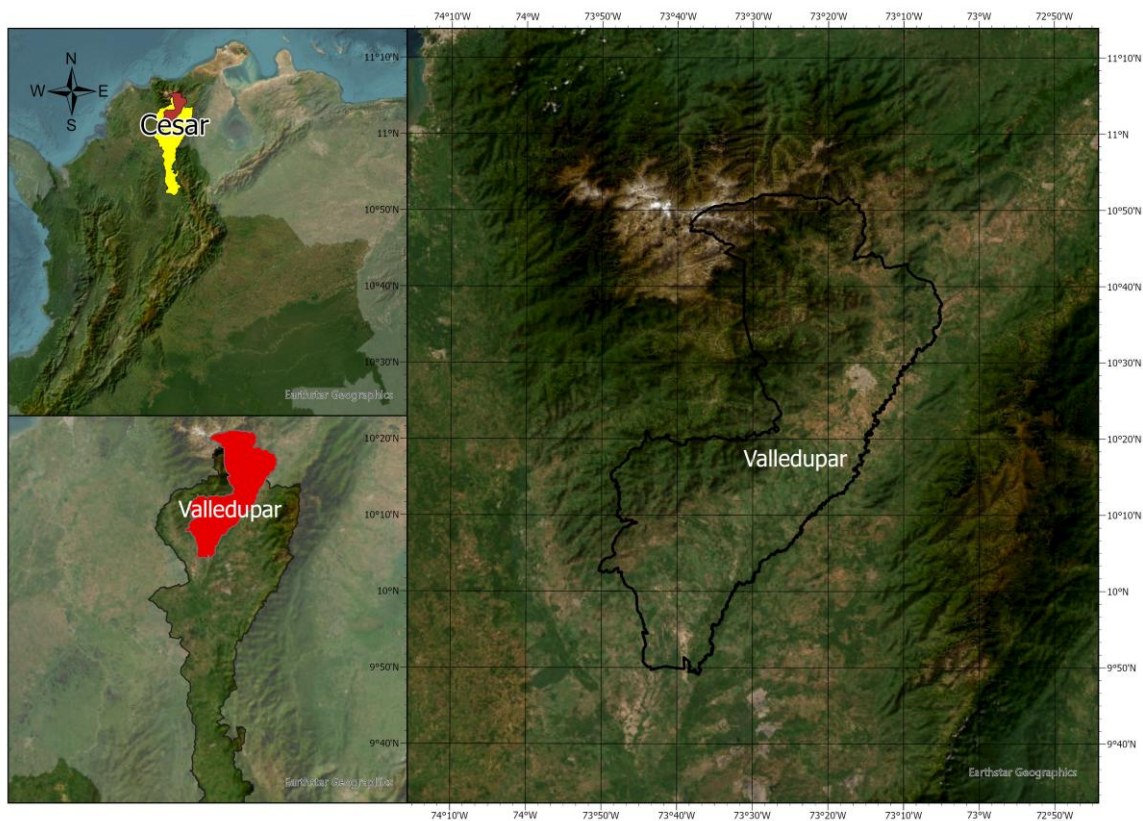
## 7. Materiales y Métodos

### 7.1 Enfoque metodológico

Esta investigación adopta un enfoque cuantitativo aplicado, de tipo experimental y exploratorio-comparativo, orientado a evaluar la eficacia de modelos de segmentación semántica basados en Deep Learning (DL) para la identificación de edificaciones parcialmente cubiertas por vegetación, utilizando datos combinados de imágenes aéreas y datos LiDAR.

### 7.2 Área de estudio

La zona de estudio corresponde a la ciudad de Valledupar, seleccionada por su alta densidad de edificaciones y presencia de cobertura vegetal. Esta zona cuenta con datos LiDAR de alta resolución y ortoimágenes aéreas recientes, indispensables para el entrenamiento del modelo.



**Figura 1.** *Zona de estudio ciudad de Valledupar Departamento del Cesar*

### 7.3 Materiales y datos

Para el desarrollo del presente estudio se emplearan diversos materiales y datos esenciales para la implementación del modelo de segmentación semántica. Los datos utilizados incluyen ortoimágenes las cuales permiten identificar con alta exactitud los detalles constructivos del área de estudio. Asimismo, se utilizaran nubes de puntos LiDAR, las cuales proporcionan información altimétrica detallada y tridimensional, útil para diferenciar edificaciones del entorno natural. Como base para la validación, se integraran capas catastrales o planos de referencia existentes, que permitirán evaluar la exactitud de la segmentación generada. El procesamiento y análisis se llevaron a cabo utilizando software especializado, como QGIS para el manejo SIG, Global Mapper para la manipulación de datos LiDAR, y entornos de desarrollo como Python 3.11 con bibliotecas de aprendizaje profundo (TensorFlow o PyTorch). Las actividades de programación y experimentación se realizaron en Jupyter Notebooks y Visual Studio Code. En cuanto al hardware, se contara con una estación de trabajo personal equipada con GPU dedicada para acelerar el entrenamiento de redes neuronales, así como servicios de almacenamiento en la nube para la gestión y respaldo de los datos.



Adicionalmente, se realizara un proceso de etiquetado manual asistido para generar las máscaras de entrenamiento, utilizando plugins específicos de QGIS.

- **Datos:**

- Ortoimágenes RGB con resolución  $\leq 10$  cm.
- Nubes de puntos LiDAR.
- Vectores de construcciones.

- **Software:**

- QGIS, LAStools, CloudCompare
- Python 3.11, TensorFlow o PyTorch
- Entornos Jupyter y VSCode

- **Hardware:**

- Estación de trabajo personal con GPU dedicada.
- Almacenamiento en nube.

- **Otros insumos:**

- Etiquetado manual asistido mediante plugins QGIS.

## 7.4 Procedimiento metodológico

La metodología se organiza en cuatro fases, alineadas con los objetivos específicos:

**Objetivo 1** Seleccionar una arquitectura Deep Learning y realizar pruebas de segmentación semántica a partir de imágenes aéreas y datos LiDAR.

### Fase 1: Selección y prueba de la arquitectura Deep Learning

- Revisión bibliográfica sobre arquitecturas DL para segmentación semántica.
- Selección inicial de una arquitectura robusta entre U-Net y DeepLabV3.
- Modificación para entrada multientrada: fusión de bandas RGB y datos derivados de LiDAR.
- Ajustes de hiperparámetros iniciales: tasa de aprendizaje, batch size, optimizador.

**Objetivo 2** Desarrollar un flujo computacional para el procesamiento de datos, segmentación semántica y vectorización de las edificaciones.

Fase 2: Desarrollo del flujo computacional

- **Preprocesamiento de datos:**
  - Registro y alineación entre LiDAR y ortoimágenes.
  - Generación de capas derivadas.
  - Etiquetado manual o semiautomático de edificaciones para entrenar el modelo.
- **División del dataset:** Entrenamiento (70%), validación (15%), test (15%).
- **Entrenamiento del modelo:**
  - Uso de augmentación de datos (rotación, ruido, escalado).
  - Entrenamiento en múltiples iteraciones (épocas).
  - Registro de métricas de pérdida y exactitud por época.

Fase 3: Vectorización de edificaciones

- Postprocesamiento de resultados de segmentación.
- Conversión de raster a vectores mediante contornos y simplificación topológica.
- Filtrado por tamaño y forma para eliminar falsos positivos.
- Asignación de atributos espaciales desde LiDAR

**Objetivo 3** Evaluar la exactitud y eficiencia computacional del modelo.

Fase 4: Evaluación de la exactitud

- Comparación con datos de referencia (vectores contrucciones)
- Cálculo de métricas de evaluación
- Evaluación comparativa:
  - Modelo entrenado solo con ortoimágenes.
  - Modelo entrenado con ortoimágenes + LiDAR.
- Análisis estadístico de resultados para validar hipótesis.

## 8. Resultados Esperados

Este proyecto tiene como principal resultado el desarrollo de un modelo de segmentación semántica que combine imágenes aéreas y datos LiDAR para identificar edificaciones que estén parcialmente cubiertas por vegetación. Se espera que este modelo sirva de insumo por empresas dedicadas a la cartografía o sistemas de información geográfica (SIG).

Además, se espera construir un flujo de trabajo automatizado que permita procesar los datos y entrenar el modelo de manera reproducible. Este flujo estará documentado y podrá ser reutilizado por investigadores, estudiantes y desarrolladores que trabajen con inteligencia artificial y análisis espacial.

También se obtendrán capas vectoriales, es decir, mapas digitales donde estarán representadas las edificaciones identificadas por el modelo, incluyendo información como el tamaño y la forma de cada una. Otro resultado importante será la evaluación de exactitud del modelo, para conocer qué tan bien funciona en zonas con vegetación. Esto se hará mediante métricas y comparaciones con información de referencia, y será útil para la comunidad académica.

Finalmente, todo el trabajo quedará documentado a través de un repositorio público que incluirá el código, una guía y memoria técnica para posterior uso.

## 9. Cronograma de Actividades

Actividad	Tiempo en Meses											
	1	2	3	4	5	6	7	8	9	10	11	12
Fase 1: Selección y prueba de arquitectura DL	X	X	X	X								
Revisión bibliográfica	X											
Selección de arquitectura (U-Net / DeepLabV3)	X											
Adaptación multientrada (RGB + LiDAR)				X	X	X						
Ajustes iniciales de hiperparámetros				X	X	X						
Fase 2: Desarrollo del flujo						X	X	X	X			

computacional												
Registro y alineación de datos						X						
Generación de capas derivadas						X						
Etiquetado manual/semi-automático						X						
División del dataset						X						
Entrenamiento preliminar del modelo						X	X	X	X			
Augmentación de datos						X	X	X	X			
Iteraciones de entrenamiento / validación						X	X	X	X			
Registro de métricas									X			
Fase 3: Vectorización de edificaciones									X	X	X	
Postprocesamiento de la segmentación									x	X		
Conversión raster → vector									X			
Filtrado (forma / tamaño)									X			
Fase 4: Evaluación de la exactitud y eficiencia											X	X
Comparación con datos de referencia											X	X
Cálculo de métricas (IoU, precisión, recall, etc.)											X	X
Evaluación comparativa modelos											X	X
Análisis estadístico												X
Redacción informe final												X

## 10 Presupuesto

Tabla 1. Presupuesto global de la propuesta por fuentes de financiamiento (en miles de \$)

Rubros	Fuentes		Total
	Contrapartida UN	Cofinanciación	

Personal	Tiempo director	Tesista	\$27.800.000
Servicios Técnicos	Etiquetado manual		\$1.500.000
Equipos	Almacenamiento nube, alquiler		\$1.000.000
Materiales y Suministros	Disco externo, licencias		\$2.500.000
Viáticos y Gastos de Viaje	NA		\$0
Impresos y Publicaciones	Entregables finales		\$1.000.000
Patentes	NA		\$0
<b>TOTAL</b>			<b>\$33.800.000</b>

#### DETALLE DE RUBROS

**Tabla 2. Personal (Contrapartida UN)**

Investigadores	Valor
Tesista	\$7.800.000
Profesor tutor	\$20.000.000
<b>TOTAL:</b>	<b>\$27.800.000</b>

**Tabla 3. Servicios Técnicos**

Descripción	Contrapartida UN	Cofinanciación	Total
Etiquetado manual asistido		\$1.500.000	\$1.500.000
<b>TOTAL</b>			<b>\$1.500.000</b>

**Tabla 4. Equipos**

Descripción	Contrapartida UN	Cofinanciación	Total
Almacenamiento nube/alquiler		\$1.000.000	\$1.000.000
<b>TOTAL</b>			<b>\$1.000.000</b>

**Tabla 5. Materiales y Suministros**

Descripción	Contrapartida UN	Cofinanciación	Total
Disco externo y licencias		\$2.500.000	\$2.500.000

<b>TOTAL</b>			<b>\$2.500.000</b>
--------------	--	--	--------------------

**Tabla 6. Viáticos y Gastos de viaje**

<b>Descripción</b>	<b>Contrapartida UN</b>	<b>Cofinanciación</b>	<b>Total</b>
NA			\$0
<b>TOTAL</b>			<b>\$0</b>

**Tabla 7. Impresos y Publicaciones**

<b>Descripción</b>	<b>Contrapartida UN</b>	<b>Cofinanciación</b>	<b>Total</b>
Entregables y revisiones tesis		\$1.500.000	\$1.500.000
<b>TOTAL</b>			<b>\$1.500.00</b>

## **11. Bibliografía citada**

Altamirano P, L. (2021). Deep Learning aplicado a la Segmentación Semántica de Imágenes aéreas. Universidad de Valparaíso, Chile.

Audebert, N., Le Saux, B., & Lefèvre, S. (2018). Beyond RGB: Very high resolution urban remote sensing with multimodal deep networks. ISPRS Journal of Photogrammetry and Remote Sensing, 140, 20–32.  
<https://doi.org/10.1016/j.isprsjprs.2017.04.009>

Audebert, N., Le Saux, B., & Lefèvre, S. (2018). Beyond RGB: Very high resolution urban remote sensing with multimodal deep networks. ISPRS Journal of Photogrammetry and Remote Sensing, 140, 20–32.  
<https://doi.org/10.1016/j.isprsjprs.2017.04.009>

Audebert, N., Le Saux, B., & Lefèvre, S. (2018). Beyond RGB: Very high resolution urban remote sensing with multispectral and height data using deep learning. ISPRS Journal of Photogrammetry and Remote Sensing, 140, 20–32.  
<https://doi.org/10.1016/j.isprsjprs.2017.05.013>

Biljecki, F., Ledoux, H., & Stoter, J. (2015). Improving the consistency of multi-scale digital surface models. *ISPRS Annals of Photogrammetry, Remote Sensing and Spatial Information Sciences*, II-3/W5, 13–20.

Chen, H., Wang, W., Xu, Y., & Liu, H. (2021). Improving building segmentation accuracy using multisource remote sensing data and hybrid deep learning architectures. *Remote Sensing*, 13(2), 248.

Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., & Adam, H. (2018). Encoder Decoder with Atrous Separable Convolution for Semantic Image Segmentation. In *Proceedings of the European Conference on Computer Vision (ECCV)*. Recuperado de <https://arxiv.org/abs/1802.02611>

DANE. (2022). Ciudades intermedias y ruralidad en Colombia: Análisis territorial. Bogotá, Colombia.

Girshick, R. (2014). Rich feature hierarchies for accurate object detection and semantic segmentation. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 580–587.

He, K., Gkioxari, G., Dollár, P., & Girshick, R. (2017). Mask R-CNN. *Proceedings of the IEEE International Conference on Computer Vision*, 2961–2969. <https://doi.org/10.1109/ICCV.2017.322>

Jensen, J. R. (2007). *Remote Sensing of the Environment: An Earth Resource Perspective*.

Kampffmeyer, M., Salberg, A. B., & Jenssen, R. (2016). Semantic segmentation of small objects and modeling of uncertainty in urban remote sensing images using deep convolutional neural networks. *CVPR Workshops*, 1–9. <https://doi.org/10.1109/CVPRW.2016.77>

Kampffmeyer, M., Salberg, A. B., & Jenssen, R. (2016). Semantic segmentation of small objects and modeling of uncertainty in urban remote sensing images using deep convolutional neural networks. *CVPR Workshops*, 1–9. <https://doi.org/10.1109/CVPRW.2016.77>

Li, W., Fu, H., Yu, L., & Cracknell, A. (2020). Deep learning based classification of hyperspectral data. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 13, 1–15.

Li, X., Cheng, G., Bu, S., & Yao, X. (2020). Building extraction from remote sensing images with edge-enhanced convolutional neural network. *Remote Sensing*, 12(8), 1247.

Lin, Y., Hyypä, J., & Jaakkola, A. (2019). Mini-UAV-borne LiDAR for fine-scale mapping. *Remote Sensing*, 11(13), 1569.

Liu, Y., et al. (2020). Building footprint extraction from high-resolution satellite images using deep learning. *Remote Sensing*.

Long, J., Shelhamer, E., & Darrell, T. (2015). Fully convolutional networks for semantic segmentation. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 3431–3440.

Maggiori, E., Tarabalka, Y., Charpiat, G., & Alliez, P. (2017). Convolutional neural networks for large-scale remote-sensing image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 55(2), 645–657.  
<https://doi.org/10.1109/TGRS.2016.2612821>

Martha, T. R., et al. (2011). Object-oriented approach for landslide detection using remote sensing and GIS. *IEEE Transactions*.

Qi, C. R., Su, H., Mo, K., & Guibas, L. J. (2017). PointNet: Deep learning on point sets for 3D classification and segmentation. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 652–660.

Reyes Quintana, N. M. (2024). Modelo de segmentación semántica de imágenes satelitales basado en redes neuronales convolucionales para la clasificación de cobertura de la tierra en páramos [Tesis de maestría, Universidad Nacional de Colombia]. Repositorio Institucional UNAL.  
<https://repositorio.unal.edu.co/handle/unal/86362>

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical Image*



Computing and Computer-Assisted Intervention (pp. 234–241). Springer.  
[https://doi.org/10.1007/978-3-319-24574-4\\_28](https://doi.org/10.1007/978-3-319-24574-4_28)

Vali, A., Comai, S., & Matteucci, M. (2020). Deep learning for land use and land cover classification based on hyperspectral and multispectral earth observation data: A review. Remote Sensing, 12(15), 2495.  
<https://doi.org/10.3390/rs12152495>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. In Advances in Neural Information Processing Systems (Vol. 30). <https://arxiv.org/abs/1706.03762>

"Wang, X., et al. (2020). Automatic building extraction in aerial scenes using CNN-based instance segmentation. ISPRS Journal.

Zhang, C., Sargent, I., Pan, X., Li, H., Gardiner, A., Hare, J., & Atkinson, P. M. (2019). Joint deep learning for land cover and land use classification. Remote Sensing of Environment, 221, 173–187.  
<https://doi.org/10.1016/j.rse.2018.11.014>

Zhou, T., et al. (2019). Occlusion-aware deep learning framework for building segmentation. Remote Sensing.

Zhu, X. X., Tuia, D., Mou, L., Xia, G.-S., Zhang, L., Xu, F., & Fraundorfer, F. (2017). Deep Learning in Remote Sensing: A Comprehensive Review and List of Resources. IEEE Geoscience and Remote Sensing Magazine, 5(4), 8–36.  
<https://doi.org/10.1109/MGRS.2017.2762307>

**Reporte de originalidad (reporte creado por una herramienta de evaluación de la originalidad en la producción y en el manejo documental, a la cual se haya sometido el documento de Proyecto de Tesis. Este reporte debe contar con el aval del director propuesto.**