



Macroproceso: Formación

Proceso: Gestión Administrativa de apoyo a la Formación

Formato: Proyecto de Tesis de maestría investigación

Estudiante: Sara Geraldine Alarcón Prieto

INFORMACIÓN DEL PROYECTO

PROYECTO DE TESIS DE MAESTRÍA

TÍTULO: “Modelo de aprendizaje profundo para la segmentación semántica de edificaciones a partir de imágenes aéreas y datos LiDAR”

DESCRIPCIÓN DEL PROYECTO

1. Resumen del proyecto (inglés y español)

El presente proyecto tiene como objetivo desarrollar un modelo de aprendizaje profundo para la segmentación semántica de edificaciones en la ciudad de Tunja, a partir de una ortoimagen de alta resolución, información LiDAR y atributos derivados de análisis basado en objetos (OBIA). El modelo se entrenará y probará bajo tres configuraciones de entrada: (A) solo imágenes aéreas, (B) imágenes aéreas más derivados LiDAR (DTM, DSM, nDSM) y (C) imágenes aéreas más LiDAR y mapas de atributos OBIA, con el fin de cuantificar el aporte incremental de cada fuente de información en la delimitación de edificaciones a escala aproximada 1:1 000. La metodología adopta un enfoque cuantitativo aplicado, de tipo experimental, organizada en tres fases. En la primera, se seleccionan y prueban arquitecturas de deep learning ampliamente usadas en segmentación semántica entre las cuales están U-Net, DeepLab, SegNet en un entorno controlado en Docker, con el fin de elegir una arquitectura adecuada. En la segunda fase, se desarrolla el flujo computacional específico para Tunja en el que se normalizan y alinean ortoimagen y derivados LiDAR, se construyen máscaras de edificaciones a partir de cartografía 1:1 000, se generan atributos OBIA y se entrena el modelo bajo los tres escenarios definidos. En la tercera fase, se evalúa el modelo mediante métricas como IoU y F1, junto con indicadores de eficiencia computacional, comparando el desempeño entre los escenarios A, B y C. Se espera como resultado un modelo basado en deep learning de segmentación

semántica de edificaciones, un pipeline reproducible implementado en Docker y evidencia cuantitativa sobre el impacto de incorporar LiDAR y OBIA frente al uso exclusivo de la ortoimagen. En el plano científico, el proyecto aporta un marco metodológico transferible para integrar información espectral, altimétrica y de objetos en modelos profundos aplicados a ciudades intermedias colombianas. En el ámbito aplicado, los resultados pueden apoyar procesos de actualización cartográfica y análisis urbano, mejorando la exactitud y reduciendo tiempos y costos frente a métodos tradicionales de captura.

The objective of this project is to develop a deep learning model for the semantic segmentation of buildings in the city of Tunja, based on a high-resolution orthoimage, LiDAR information, and attributes derived from object-based analysis (OBIA). The model will be trained and tested under three input configurations: (A) aerial images only, (B) aerial images plus LiDAR derivatives (DTM, DSM, nDSM), and (C) aerial images plus LiDAR and OBIA attribute maps, in order to quantify the incremental contribution of each information source in the delimitation of buildings at an approximate scale of 1:1,000. The methodology adopts an applied quantitative, experimental approach, organized into three phases. In the first phase, deep learning architectures widely used in semantic segmentation, including U-Net, DeepLab, and SegNet, are selected and tested in a controlled environment in Docker in order to choose a suitable architecture. In the second phase, the specific computational flow for Tunja is developed, in which orthoimages and LiDAR derivatives are normalized and aligned, building masks are constructed from 1:1,000 cartography, OBIA attributes are generated, and the model is trained under the three defined scenarios. In the third phase, the model is evaluated using metrics such as IoU and F1, along with computational efficiency indicators, comparing performance between scenarios A, B, and C. The expected outcome is a deep learning-based model for semantic segmentation of buildings, a reproducible pipeline implemented in Docker, and quantitative evidence on the impact of incorporating LiDAR and OBIA compared to the exclusive use of orthoimagery. On a scientific level, the project provides a transferable methodological framework for integrating spectral, altimetric, and object information into deep models applied to medium-sized Colombian cities. In the applied field, the results can support cartographic updating and urban analysis processes, improving accuracy and reducing time and costs compared to traditional capture methods.

2. Introducción (Revisión de Literatura y marco teórico)

Para tener una idea clara y global de lo que se quiere trabajar en este proyecto se organizarán en torno a tres ejes que dialogan directamente con el objetivo general: (i) segmentación semántica de edificaciones con aprendizaje profundo, (ii) fusión de imágenes aéreas y datos LiDAR y (iii) análisis basado en objetos (OBIA/GEOBIA) aplicado a edificaciones. Cada eje aportará conceptos, métodos y evidencias que servirán para justificar las decisiones de diseño del modelo, los escenarios de entrada teniendo en cuenta solo imágenes, imágenes + LiDAR, imágenes + LiDAR + OBIA y el protocolo de evaluación.

En el primer eje se revisarán trabajos recientes sobre extracción de edificaciones y huellas de edificios con deep learning, con énfasis en arquitecturas tipo U-Net, DeepLab, SegNet y variantes encoder-decoder aplicadas a imágenes aéreas y satelitales de muy alta resolución (Audebert, 2017). Revisiones y estudios comparativos muestran que estos modelos han alcanzado resultados competitivos en conjuntos de datos de referencia, y que siguen apareciendo propuestas que refinan la representación multiescala, la delineación de bordes y la eficiencia computacional (Yuan, Shi, & Gao, 2025). En particular, se estudiarán trabajos que analizan el desempeño de distintas arquitecturas sobre datasets como Vaihingen, Potsdam o similares, así como estudios de caso donde U-Net y variantes han sido empleadas con éxito para segmentar edificios en imágenes de alta resolución. (Alsabhan & Alotaiby, 2022) Esta literatura será la base para seleccionar un conjunto reducido de arquitecturas candidatas, entender sus requisitos de entrenamiento y definir las métricas principales que se utilizarán en la evaluación del modelo para Tunja.

En el segundo eje se revisarán aportes relacionados con la fusión de imágenes aéreas y datos LiDAR para la extracción de edificaciones. Numerosos estudios especialmente el de Audembert 2018 han mostrado que la incorporación de altura (a través de DSM, DTM y nDSM) mejora la separación entre edificaciones y otras coberturas, al introducir información geométrica y estructural que complementa la radiometría. (Jozdani & Chen, 2020) Trabajos más recientes exploran distintas estrategias de fusión por ejemplo, transformar la nube de puntos en imágenes de altura o derivar indicadores altimétricos específicos y evalúan su impacto en la calidad de la detección de edificios. (Mola Ebrahimi, Arefi, & Rasti Veis, 2017) A partir de esta literatura se definirán los derivados LiDAR que se incorporarán al

modelo, los criterios de coregistro y normalización espacial con la ortoimagen, y la forma de apilar estas bandas como canales adicionales en el escenario “imágenes + LiDAR” del experimento.

El tercer eje se centrará en el análisis de imágenes basado en objetos (OBIA/GEOBIA) y su aplicación a la extracción de edificaciones. Los trabajos fundacionales en OBIA y las revisiones recientes coinciden en que este enfoque ha alcanzado un alto nivel de madurez, especialmente cuando se trabaja con imágenes de muy alta resolución y se requiere aprovechar información de forma, textura y contexto además de la radiometría. (Blaschke, 2010) En el ámbito específico de edificaciones, existen métodos basados en segmentación en objetos y diseño de atributos que logran resultados robustos utilizando clasificadores supervisados tradicionales. (Attarzadeh & Momeni, 2010) La revisión de esta línea permitirá identificar qué atributos de nivel objeto son más relevantes para distinguir techos de otras superficies urbanas, y cómo pueden ser traducidos a mapas de atributos rasterizables que se integren como canales adicionales en el escenario “imágenes + LiDAR + OBIA”. En lugar de tratar OBIA solo como un pipeline independiente, la propuesta busca apoyarse en esta literatura para diseñar atributos que alimenten explícitamente al modelo profundo.

De manera complementaria, la literatura sobre extracción de edificaciones sigue fragmentada en tres grandes líneas: modelos que trabajan principalmente con imágenes RGB o multispectrales, enfoques que explotan solo LiDAR y soluciones basadas en OBIA/GEOBIA con clasificadores tradicionales. En el primer grupo, las arquitecturas de segmentación semántica tipo U-Net, DeepLab o modelos encoder-decoder afines aplicadas a imágenes de muy alta resolución han demostrado altos niveles de exactitud en la delimitación de edificaciones y otros objetos urbanos, apoyándose casi exclusivamente en la información espectral y textural de las ortofotos (Zhu et al., 2017; Liu et al., 2020; Zhang et al., 2019; Li et al., 2024). En paralelo, existe una línea de trabajo que emplea únicamente datos LiDAR ya sea nubes de puntos o derivados como DSM/DTM para segmentar o detectar edificios, explotando la geometría y la altura pero con un uso limitado de la radiometría (Rottensteiner et al., 2004; Jamali et al., 2019). Un tercer grupo corresponde a los enfoques OBIA/GEOBIA, que combinan imágenes y en algunos casos LiDAR mediante segmentación en objetos, cálculo de atributos de forma, textura y contexto, y clasificadores supervisados clásicos como árboles de decisión o SVM (Blaschke, 2010; Attarzadeh & Momeni, 2010; Chen et al., 2018). Sin embargo, las revisiones recientes sobre segmentación semántica en

teledetección señalan que, aunque se han explorado esquemas de fusión multimodal por ejemplo, imágenes+LiDAR, son todavía muy escasos los trabajos que integran simultáneamente información espectral, altimétrica y atributos OBIA como canales de entrada dentro de un único modelo de aprendizaje profundo, y menos aún bajo protocolos de validación espacialmente conscientes (Neupane et al., 2021; Lv et al., 2023; Li et al., 2024).

De forma transversal a los tres ejes, la revisión incluirá trabajos sobre validación espacialmente consciente (“spatially-aware validation”) y sobre los efectos de la fuga espacial en la evaluación de modelos de aprendizaje automático geoespacial. Diversos estudios han mostrado que la validación aleatoria convencional tiende a sobreestimar el desempeño cuando las muestras de entrenamiento y prueba están espacialmente próximas, y recomiendan particiones por bloques, “spatial cross-validation” o variantes que separen explícitamente unidades geográficas contiguas (Roberts et al., 2017; Valavi et al., 2019). Esta evidencia respalda la decisión metodológica de trabajar con particiones espaciales sin fuga como manzanas o bloques urbanos no contiguos para entrenamiento, validación, prueba y de documentar claramente cómo se definen y verifican dichas particiones en el caso de Tunja.

Es muy importante mencionar en concordancia con los objetivos de este proyecto se abordará la literatura sobre reproducibilidad, diseño experimental y eficiencia en modelos de extracción de edificaciones, así como las revisiones recientes de métodos de deep learning para este problema. Estas revisiones subrayan la necesidad de protocolos comparables (división de datos, métricas comunes, documentación de hiperparámetros) y destacan tendencias como el aprovechamiento eficiente de datos, la fusión multisource y la generación de salidas vectoriales a partir de segmentaciones raster como se ha evidenciado en algunas literaturas (Yuan, Shi, & Gao, 2025). Este cuerpo de trabajo servirá para estructurar el diseño experimental del proyecto: uso de particiones espaciales sin fuga entre entrenamiento, validación y prueba; selección de métricas; y registro sistemático de configuraciones, tiempos y consumo de recursos, de manera que el modelo desarrollado para la ciudad de Tunja pueda situarse dentro de las buenas prácticas internacionales y resultar

En conjunto, la revisión de literatura no se limitará a describir trabajos previos, sino que se utilizará de manera instrumental para: (i) justificar la elección de arquitecturas de aprendizaje profundo y de métricas de evaluación; (ii)

fundamentar el diseño de los tres escenarios de entrada (A, B y C) que permiten aislar el aporte incremental de LiDAR y OBIA; (iii) definir criterios de segmentación y diseño de atributos de nivel objeto acordes con buenas prácticas de GEOBIA; y (iv) alinear el caso de estudio con las demandas del contexto colombiano en materia de catastro y planificación urbana. Desde esta perspectiva, la investigación aspira a llenar un vacío específico: aportar evidencia rigurosa y un flujo reproducible sobre cómo se comporta un modelo de aprendizaje profundo para segmentación de edificaciones cuando integra progresivamente información espectral, altimétrica y de objetos en una ciudad intermedia colombiana, utilizando datos locales de cartografía básica a escala 1:1 000.

3. Planteamiento del problema

La delimitación precisa de edificaciones a partir de imágenes aéreas de muy alta resolución es un insumo clave para la planificación urbana, la actualización catastral, la gestión del riesgo y el ordenamiento territorial. En la última década, los modelos de aprendizaje profundo para segmentación semántica han mostrado mejoras claras en la detección de edificaciones frente a enfoques tradicionales, especialmente en entornos urbanos densos y relativamente homogéneos. En ciudades tropicales, la presencia de vegetación inserta en el tejido urbano introduce oclusiones parciales de las cubiertas, sombras intensas y variaciones espectrales que dificultan separar techos y vegetación en las ortofotos. Estudios recientes en segmentación urbana (Wang et al., 2025) señalan que la exactitud de los modelos profundos disminuye cuando las clases presentan oclusiones o alta heterogeneidad, pero la mayoría de experimentos se ha realizado en contextos donde la interferencia vegetal es limitada, por lo que la respuesta en escenarios tropicales sigue poco documentada.

La literatura ha mostrado que la combinación de imágenes aéreas con datos LiDAR por ejemplo, a través de DSM o nDSM puede mejorar la extracción de edificaciones al incorporar información de altura y estructura geométrica, ayudando a distinguir techos de vegetación u otras coberturas como lo dice Audembert 2018. De forma complementaria, el análisis de imágenes basado en objetos (GEOBIA/OBIA) permite trabajar con objetos segmentados y utilizar atributos de forma, textura y contexto, lo que ha demostrado ser eficaz en aplicaciones urbanas y en la caracterización de edificaciones a partir de imágenes y LiDAR (Chen, Weng, Hay, & He, 2018).

No obstante, la mayoría de estos enfoques se ha desarrollado como soluciones parciales: por un lado, modelos profundos que operan principalmente sobre imágenes; por otro, flujos OBIA y esquemas de fusión óptico-LiDAR. Son escasos los estudios que analizan, de manera controlada, el aporte incremental de cada tipo de información con imágenes aéreas, LiDAR y atributos OBIA cuando se integran dentro de un mismo modelo de aprendizaje profundo para segmentación de edificaciones. Esta brecha es especialmente relevante en el contexto colombiano, donde muchas ciudades intermedias combinan crecimiento urbano fragmentado, tipologías constructivas diversas y una presencia importante de vegetación dentro del tejido urbano.

En consecuencia de todo lo anterior se entiende que en entornos urbanos tropicales con interferencia vegetal, no se conoce con claridad cómo cambia la precisión de la segmentación semántica de edificaciones cuando un modelo de aprendizaje profundo se apoya únicamente en imágenes aéreas, frente a cuando incorpora adicionalmente información LiDAR y atributos derivados de análisis por objetos (OBIA). Esta falta de evidencia limita el diseño de flujos de trabajo robustos y reproducibles para la generación de cartografía de edificaciones y reduce el potencial de estas tecnologías para fortalecer la gestión y planificación del territorio en el país.

4. Justificación

Resolver La delimitación automatizada de edificaciones a partir de imágenes aéreas y datos auxiliares se ha convertido en un pilar para la planificación urbana, la actualización catastral, la gestión del riesgo y el ordenamiento territorial. En los últimos años, los modelos de aprendizaje profundo para segmentación semántica han mostrado mejoras claras frente a métodos clásicos en la detección de edificaciones y otras clases urbanas, gracias a su capacidad para aprender representaciones complejas directamente a partir de imágenes de alta resolución. (Lv et al., 2023) Este avance ha motivado aplicaciones en mapeo de huellas de edificios, monitoreo de cambios y generación de insumos para análisis espaciales de mayor complejidad. No obstante, buena parte de la evidencia disponible se ha generado en contextos urbanos relativamente homogéneos y con condiciones de observación favorables. En ciudades intermedias como Tunja, la morfología urbana combina edificaciones de diversas alturas y materiales, fuertes variaciones

topográficas, presencia localizada de vegetación y solapes entre construcciones, lo que puede dificultar la separación nítida de techos frente a su entorno cuando solo se dispone de información espectral. En este tipo de escenarios, la integración de datos LiDAR por ejemplo, a través de modelos digitales de superficie y de altura normalizada (DSM/nDSM) ha demostrado aportar información geométrica y de altura que mejora la extracción de edificaciones al complementar la radiometría de las imágenes aéreas (Sohn & Dowman, 2007). Paralelamente, el análisis geográfico basado en objetos (GEOBIA/OBIA) se ha consolidado como un enfoque eficaz para el mapeo urbano, al segmentar la escena en objetos coherentes e incorporar atributos de forma, textura y contexto, además de la información espectral (Chen et al., 2018). Varios trabajos han demostrado que, al combinar imágenes aéreas y LiDAR dentro de marcos OBIA, es posible extraer huellas de edificaciones y otras estructuras con alta precisión. Sin embargo, estos enfoques suelen implementarse como flujos paralelos a los modelos profundos: o se entrena una red neuronal con canales espectrales y altimétricos, o se diseñan reglas y clasificadores a nivel de objeto, pero son escasos los estudios que utilizan explícitamente productos OBIA como insumos adicionales dentro de un mismo modelo de aprendizaje profundo para segmentación de edificaciones.

Desde el punto de vista científico-técnico, la presente investigación se justifica porque propone integrar de manera progresiva tres fuentes de información imágenes aéreas, datos LiDAR y atributos derivados de OBIA dentro de un modelo de aprendizaje profundo, evaluando su desempeño bajo configuraciones de entrada comparables. Esto permite cuantificar el aporte incremental de cada fuente de datos en la segmentación semántica de edificaciones, en un entorno urbano real, y contribuye a cerrar una brecha identificada en la literatura sobre fusión de información espectral, altimétrica y basada en objetos para esta tarea (Amirgan & Erener, 2024). En términos institucionales y sociales, el trabajo se alinea con los esfuerzos nacionales en torno al catastro multipropósito y al fortalecimiento de la infraestructura de datos geoespaciales, liderados por el Instituto Geográfico Agustín Codazzi (IGAC) y otras entidades del Sistema Nacional de Información. Colombia dispone de ortoimágenes, modelos de elevación y lineamientos técnicos que habilitan la construcción de flujos reproducibles de análisis espacial, los cuales son fundamentales para mejorar la calidad y oportunidad de la información predial y urbana. Un procedimiento metodológico claro, que documente la preparación de datos, la integración de fuentes, el entrenamiento del modelo y la evaluación con métricas estándar,

puede ser transferible a instituciones públicas y proyectos académicos que requieran cartografía de edificaciones confiable para soportar decisiones sobre uso del suelo, infraestructura y gestión del riesgo (Dorado, D. (Comp.). (2022)).

Finalmente, desde la perspectiva del desarrollo territorial, utilizar a Tunja como caso de estudio permite mostrar la aplicabilidad de modelos de aprendizaje profundo en una ciudad colombiana concreta, con disponibilidad de información geoespacial y necesidades reales de actualización y análisis urbano.

5. Pregunta de Investigación

¿En qué medida la incorporación progresiva de información LiDAR y de atributos derivados de OBIA mejora la precisión y el desempeño computacional de un modelo de aprendizaje profundo para la segmentación semántica de edificaciones, en comparación con el uso de datos de imágenes multiespectrales?

6. Objetivos

General:

Desarrollar un modelo de aprendizaje profundo para la segmentación semántica de edificaciones a partir de imágenes aéreas, incorporando progresivamente información LiDAR y atributos derivados de OBIA.

Específicos:

1. Seleccionar arquitecturas de deep learning y realizar pruebas de segmentación semántica a partir de imágenes aéreas.
2. Desarrollar un flujo computacional que integre progresivamente imágenes aéreas, información LiDAR y atributos derivados de OBIA
3. Evaluar la exactitud y eficiencia computacional del modelo.

7. Materiales y Métodos

7.1 Enfoque metodológico

Esta investigación adopta un enfoque cuantitativo aplicado, de tipo experimental y exploratorio-comparativo, orientado a evaluar la eficacia de modelos de segmentación semántica basados en Deep Learning (DL) para la identificación de

edificaciones parcialmente cubiertas por vegetación, utilizando datos combinados de imágenes aéreas y datos LiDAR e integrando datos OBIA.

7.2 Área de estudio

El estudio se desarrollará en el área urbana del municipio de Tunja, capital del departamento de Boyacá, ubicada en la Cordillera Oriental de los Andes, con una altitud promedio cercana a los 2800–2820 m s.n.m. y un clima frío de alta montaña Tunja presenta un tejido urbano compacto, con variación topográfica es decir, cuenta con planicies, mesetas y colinas y una mezcla de edificaciones de distintas alturas y tipologías, junto con presencia localizada de vegetación y zonas en consolidación urbana.




Figura 1. *Zona de estudio municipio de Tunja, nube de puntos y vectores de construcciones.*

7.3 Datos geoespaciales y recursos

Para el desarrollo de la investigación se utilizarán insumos geoespaciales suministrados por la empresa GEOMÁTICA MONCALEANO SAEZ S.A.S., provenientes de un levantamiento en el área urbana de Tunja. Estos insumos incluyen:

- **Ortoimagen de alta resolución:** ortofoto urbana con resolución espacial aproximada de 10 cm, generada a partir de vuelos fotogramétricos realizados por la empresa. Esta ortoimagen constituye la base espectral principal para la segmentación semántica de edificaciones.
- **Nube de puntos LiDAR:** nube de puntos densa en formato LAS/LAZ, producto del mismo levantamiento, a partir de la cual se derivarán los modelos digitales de terreno (MDT/DTM), de superficie (MDS/DSM) y el modelo de altura normalizada (nDSM). Estos derivados se emplearán como canales altimétricos adicionales en el modelo de aprendizaje profundo.
- **Cartografía básica a escala 1:1 000:** información vectorial de detalle como huella de edificaciones y demás capas para el área de estudio. Las huellas de edificaciones se utilizarán como referencia para construir las máscaras de entrenamiento y evaluación del modelo.

En caso de encontrar vacíos, inconsistencias geométricas o topológicas en la cartografía de referencia, se contempla realizar una edición manual complementaria por ejemplo, ajuste de huellas o corrección de geometrías en QGIS con el fin de garantizar un conjunto de datos de referencia suficiente y coherente para el entrenamiento, validación y prueba del modelo.

7.4 Recursos computacionales

El procesamiento se realizará en un equipo de escritorio perteneciente a uno de los laboratorios de la universidad, el cual cuenta con:

- GPU integrada Intel UHD Graphics 770, utilizada principalmente para tareas de escritorio y visualización general.
- GPU dedicada NVIDIA T1000 8 GB, basada en arquitectura Turing, con aproximadamente 896 núcleos CUDA y 8 GB de memoria GDDR6, adecuada para cargas profesionales de visualización y entrenamiento de modelos de tamaño moderado.

El entorno de desarrollo considerará:

- Sistema operativo de escritorio (Windows y/o Linux, según la configuración del laboratorio).
- Lenguaje Python 3.x y librerías de aprendizaje profundo, como PyTorch o TensorFlow, para implementar y entrenar las arquitecturas de segmentación semántica.
- Software SIG de escritorio, principalmente QGIS (y, si es necesario, ArcGIS), para la inspección de la ortoimagen y de los derivados LiDAR, la edición de datos vectoriales y la generación de insumos para el análisis basado en objetos (OBIA).
- Herramientas para análisis basado en objetos (OBIA/GEObIA), ya sea mediante módulos de segmentación y cálculo de atributos en QGIS/Orfeo Toolbox, o mediante implementación propia en Python (segmentación y extracción de atributos por objeto).

Adicionalmente, el desarrollo y la ejecución del flujo computacional se apoyarán en el uso de Docker como plataforma de contenedores. El empleo de Docker en este proyecto se justifica porque:

- Permite empaquetar el entorno de ejecución (versiones de Python, librerías de deep learning, dependencias de SIG y utilidades de procesamiento) en una imagen reproducible, reduciendo problemas de incompatibilidad entre equipos o sistemas operativos.
- Facilita la reproducibilidad de los experimentos, ya que las configuraciones de entrenamiento, las dependencias y los scripts pueden ejecutarse en diferentes máquinas.
- Mejora la portabilidad del flujo metodológico, de modo que otros investigadores o instituciones puedan replicar el proceso de segmentación semántica utilizando la misma imagen de Docker, sin necesidad de reinstalar manualmente todas las dependencias.
- Permite separar, si es necesario, contenedores orientados a tareas específicas por ejemplo, uno para el preprocesamiento geoespacial y otro para el entrenamiento del modelo, manteniendo una organización clara del entorno computacional.

7.5 Procedimiento metodológico

La metodología se organiza en tres fases que corresponden directamente a los objetivos específicos:

- **Fase 1:** selección de arquitecturas y pruebas
- **Fase 2:** desarrollo del flujo computacional
- **Fase 3:** evaluación

Fase 1. Selección de arquitecturas y pruebas con datasets de referencia

OE1: Seleccionar arquitecturas de deep learning y realizar pruebas de segmentación semántica a partir de imágenes aéreas.

En esta fase no se utilizan aún los datos de Tunja. El objetivo es comprender el comportamiento de distintas arquitecturas de segmentación semántica trabajando con datasets de referencia asociados a repositorios y artículos por ejemplo, conjuntos de datos urbanos como Vaihingen, Potsdam u otros provistos en los propios códigos de ejemplo, y así elegir una o dos arquitecturas adecuadas para trasladarlas posteriormente al caso de estudio.

F1.1. Revisión y selección de arquitecturas candidatas

- Revisión de la literatura y de repositorios consolidados de segmentación semántica aplicada a imágenes aéreas.
- Selección preliminar de arquitecturas candidatas, tales como:
 - U-Net y variantes encoder-decoder.
 - DeepLabv3+.
 - SegNet u otras redes totalmente convolucionales usadas en teledetección urbana.
- Consideración de arquitecturas que ya se han trabajado en ejercicios previos (por ejemplo, SegNet y UNetFormer) para aprovechar experiencia y código existente.

F1.2. Configuración del entorno experimental en Docker

- Definición de una o varias imágenes Docker que incluyan:
 - Python 3.x,
 - librerías de deep learning (PyTorch o TensorFlow),

- dependencias requeridas por los repositorios seleccionados.
- Clonado y adaptación mínima de los repositorios elegidos (rutas, configuración de GPUs, etc.), de manera que los experimentos de referencia puedan ejecutarse de forma reproducible dentro de contenedores Docker.
- Documentación de los comandos de construcción y ejecución de los contenedores (Dockerfile / docker-compose), que luego servirán como base para la Fase 2.

F1.3. Reproducción de experimentos con datasets de referencia

- Ejecución de los scripts de entrenamiento y validación provistos en los repositorios, utilizando los datasets de referencia asociados a cada arquitectura.
- Ajuste leve de hiperparámetros solo cuando sea necesario para que los modelos se entrenen correctamente en la GPU NVIDIA T1000 8 GB (por ejemplo, reducción del batch size).
- Registro de:
 - métricas reportadas en los experimentos (IoU, mIoU, F1, etc.),
 - tiempo de entrenamiento aproximado,
 - uso de memoria,
 - estabilidad de las curvas de pérdida y precisión.

F1.4. Análisis comparativo y selección de arquitectura para Tunja

- Comparación cualitativa y cuantitativa de las arquitecturas probadas, considerando:
 - complejidad del modelo como profundidad, número de parámetros,
 - facilidad de entrenamiento y estabilidad,
 - resultados obtenidos en datasets de referencia,
 - requisitos de hardware y tiempo de cómputo.
- Selección de una arquitectura principal que será adaptada al caso de estudio de Tunja en la Fase 2.
- Síntesis de ventajas y limitaciones de cada arquitectura, como insumo conceptual para el capítulo de metodología.

Producto fase 1 :

Arquitecturas de segmentaciones semánticas seleccionadas y probadas en datasets de referencia, con un entorno Docker funcional y una comprensión clara de sus requerimientos y desempeño. Estas arquitecturas se usarán como base para el diseño del modelo aplicado a Tunja en la Fase 2.

Fase 2. Desarrollo del flujo computacional

OE2: Desarrollar un flujo computacional que integre progresivamente imágenes aéreas, información LiDAR y atributos derivados de OBIA.

En esta fase se trabaja ya con el caso de estudio de Tunja.

F2.1. Organización y preparación de datos de Tunja

- Estructuración de insumos:
 - Ortoimagen urbana de Tunja (10 cm)
 - Nube de puntos LiDAR.
 - Cartografía básica 1:1000 huellas de edificaciones y capas asociadas.
- Organización de carpetas y uso de control de versiones para scripts y configuraciones.
- Verificación de consistencia entre fechas de adquisición y productos derivados.

F2.2. Normalización geoespacial y derivados LiDAR

- Unificación de sistema de referencia
- Generación de derivados a partir de la nube de puntos:
 - DTM (Modelo Digital del Terreno).
 - DSM (Modelo Digital de Superficie).
 - nDSM (altura normalizada = DSM - DTM).
- Re-muestreo y coregistro de DTM, DSM y nDSM para asegurar alineación con la ortoimagen.
- Inspección visual y control básico de calidad detección de artefactos, huecos, valores extremos.

F2.3. Construcción del conjunto de referencia

- Revisión y corrección de las huellas de edificaciones:
 - corrección de geometrías no válidas,
 - eliminación de duplicados,
 - revisión de solapes y topología.
- Rasterización de las huellas sobre la malla de la ortoimagen para obtener máscaras binarias “edificación / no edificación”.
- Almacenamiento de estas máscaras alineadas con todos los canales (ortofoto, nDSM y otros derivados).

F2.4. Teselado y partición espacial para el modelo de Tunja

- División del área urbana en tiles de tamaño fijo coherente con la resolución de 10 cm.
- Definición de particiones espaciales sin fuga:
 - entrenamiento, validación y prueba
 - asegurando que los conjuntos no compartan edificaciones ni manzanas contiguas, para evaluar generalización espacial.

F2.5. Generación de atributos OBIA

- Realización de una segmentación de la escena para obtener objetos que representen unidades homogéneas.
- Cálculo de atributos por objeto, tales como:
 - estadísticos espectrales (media, desviación estándar por banda),
 - estadísticas de altura (mínimo, máximo, rango, percentiles sobre nDSM),
 - métricas de textura como GLCM,
 - atributos de contexto
- Proyección a raster: cada atributo se convierte en una banda raster donde cada píxel hereda los valores de su objeto. Esto genera un conjunto de “mapas de atributos OBIA” alineados con la ortoimagen y los derivados LiDAR.

F2.6. Definición de escenarios de entrada (A, B y C)

Tomando la arquitectura seleccionada en la Fase 1, se definirán tres configuraciones de entrada:

1. **Escenario A – Solo imágenes aéreas**
 - Canales: bandas espectrales de la ortoimagen RGB o multiespectral.
2. **Escenario B – Imágenes aéreas + LiDAR**
 - Canales: ortoimagen (RGB) + nDSM
 - Permite evaluar el aporte de la información de altura y estructura.
3. **Escenario C – Imágenes aéreas + LiDAR + atributos OBIA**
 - Canales: ortoimagen (RGB) + nDSM + un subconjunto de bandas OBIA.
 - Busca integrar explícitamente información de nivel objeto en el modelo profundo.

Las particiones train/val/test definidas en F2.4 se reutilizarán en los tres escenarios para garantizar comparabilidad.

F2.7. Implementación del flujo en Docker y entrenamiento del modelo de Tunja

- Adaptación de la arquitectura seleccionada (Fase 1) a los tres escenarios A, B y C, ajustando solo el número de canales de entrada.
- Implementación del flujo completo dentro de uno o varios contenedores Docker:
 - scripts de preprocesamiento
 - definición de dataloaders,
 - configuración de entrenamiento (optimizador, tasa de aprendizaje, funciones de pérdida),
 - registro automático de métricas y tiempos.
- Entrenamiento del modelo para cada escenario, respetando la misma lógica de entrenamiento:
 - hiperparámetros comparables,
 - uso de la GPU NVIDIA T1000 8 GB como acelerador principal.
- Documentación detallada de las configuraciones y comandos de ejecución (incluyendo versiones de imagen Docker), para asegurar reproducibilidad.

Salida esperada de la Fase 2:

Flujo computacional específico para Tunja implementado y documentado en Docker, con los tres escenarios de entrada (A, B y C) entrenados.

Fase 3. Evaluación

OE3: Evaluar la exactitud y eficiencia computacional del modelo.

F3.1. Métricas de exactitud

Sobre el conjunto de prueba (test) de Tunja se calcularán, para cada escenario (A, B y C):

- IoU (Intersection over Union) para la clase “edificación” (métrica principal).
- mIoU, si se consideran otras clases adicionales.
- Precisión, recobrado (Recall) y F1 para edificaciones.

Se podrán aplicar técnicas de remuestreo (por ejemplo, bootstrap sobre tiles) para estimar intervalos de confianza sencillos de estas métricas.

F3.2. Medición de eficiencia computacional

En coherencia con la GPU NVIDIA T1000 8 GB y el entorno en Docker:

- Registro del tiempo de entrenamiento por época y total en cada escenario.
- Medición del tiempo de inferencia por tile y por escena completa.
- Monitoreo del uso de memoria (VRAM) y tamaño de los modelos.
- Estimación de un indicador relativo de consumo energético.

F3.3. Comparación y análisis entre escenarios

- Comparación de métricas de exactitud entre:
 - Escenario A vs. Escenario B → aporte de LiDAR.
 - Escenario B vs. Escenario C → aporte adicional de atributos OBIA.
- Análisis espacial de los resultados:
 - zonas donde la altura (nDSM) ayuda a separar edificaciones del entorno,
 - zonas donde los atributos OBIA reducen errores como techos contiguos o formas irregulares.
- Discusión del balance calidad–costo computacional:
 - cuánto mejora IoU y F1 al pasar de A→B→C,
 - qué incremento en tiempo y memoria implica cada escenario,
 - recomendaciones sobre qué configuración es más razonable según recursos y necesidades.

F3.4. Presentación y síntesis de resultados

- Elaboración de:
 - Tablas comparativas de métricas (IoU, F1, tiempos) para los tres escenarios.
 - Gráficos que resuman la evolución de calidad y costo computacional.
 - Mapas de segmentación y mapas de error sobre sectores representativos de Tunja.
- Formulación de conclusiones sobre:
 - el aporte incremental de LiDAR y OBIA en modelos de aprendizaje profundo,
 - la pertinencia de cada escenario para aplicaciones de planificación urbana,
 - la posible transferencia de la metodología a otras ciudades intermedias colombianas.

Salida esperada de la Fase 3:

Desarrollo y caracterización final de un modelo de aprendizaje profundo para la segmentación semántica de edificaciones en Tunja, entrenado bajo tres escenarios de entrada (A, B y C).

8. Resultados Esperados

Se espera como resultado central el desarrollo de un modelo de aprendizaje profundo para la segmentación semántica de edificaciones en la ciudad de Tunja, entrenado y probado bajo tres configuraciones de entrada: (A) solo imágenes aéreas, (B) imágenes aéreas más información LiDAR derivada (nDSM y productos asociados) y (C) imágenes aéreas más LiDAR y atributos derivados de OBIA. Este modelo debe producir mapas de edificaciones con calidad suficiente para su análisis a escala aproximada 1:1 000, de modo que puedan servir como insumo en tareas de análisis urbano, apoyo catastral y futuros estudios comparativos.

De manera complementaria, se espera obtener evidencia cuantitativa y cualitativa sobre el aporte de la información LiDAR y de los atributos OBIA al desempeño del modelo. Esto incluye comparar métricas como IoU y F1 entre los tres escenarios, usando particiones espaciales sin fuga, e identificar en qué medida la incorporación de altura y atributos de objeto mejora la delimitación de

edificaciones frente al uso exclusivo de la ortoimagen, así como discutir si las ganancias de exactitud justifican el mayor costo computacional.

Otro resultado esperado es un flujo computacional reproducible, implementado y documentado en Docker, que integre el preprocesamiento geoespacial, la derivación de productos LiDAR, la generación de atributos OBIA, la preparación de los conjuntos de datos, el entrenamiento del modelo y su evaluación. Este flujo irá acompañado de los insumos geoespaciales procesados para el caso de estudio (ortoimagen alineada, DTM, DSM, nDSM y mapas de atributos OBIA), de las salidas del modelo (segmentaciones raster y, cuando sea pertinente, huellas vectorizadas) y de una documentación técnica y académica completa: la tesis de maestría y una guía de uso del código y de los contenedores Docker, de forma que la metodología pueda adaptarse a otras ciudades intermedias colombianas con condiciones de datos similares.

9. Cronograma de Actividades

Actividad	Tiempo en Meses											
	1	2	3	4	5	6	7	8	9	10	11	12
Fase 1: Selección de arquitectura	x	x	x	x								
1.1 Revisión de literatura y criterios para selección de arquitecturas	x	X										
1.2 Configuración de entorno (Python, librerías, Docker, repositorio)	x	x	X									
1.3 Implementación y pruebas de arquitecturas en datasets de referencia			x	X								
1.4 Selección de arquitectura(s) base y documentación de configuración				x								
Fase 2: Desarrollo flujo computacional	x	x	x	x	x	x	x	x				
2.1 Ingesta y organización de datos de Tunja (orto, LiDAR, vectores)				x	x							
2.2 Preprocesamiento geoaltimétrico (CRS, resampleo, DTM/DSM→nDSM, QA)					x	x						
2.3 Construcción de máscaras,						x	x					

teselado y particiones espaciales (train/val/test)												
2.4 Generación de atributos OBIA y rasterización como canales adicionales						x	x					
2.5 Implementación de escenarios A/B/C y entrenamientos principales					x	x	x	x				
Fase 3: Evaluación de exactitud y eficiencia								x	x	x	x	
3.1 Inferencia en conjunto de prueba y cálculo de métricas								x	x			
3.2 Evaluación de eficiencia computacional (tiempos, VRAM, consumo aprox.)									x			
3.3 Redacción y ajuste del documento final, guía técnica y artículo					x	x	x	x	x	x	x	

10 Presupuesto

Tabla 1. Presupuesto global de la propuesta por fuentes de financiamiento (en miles de \$)

Rubros	Fuentes		Total
	Contrapartida UN	Cofinanciación	
Personal	Tiempo director	Tesista	\$27.800.000
Servicios Técnicos		Etiquetado y edición manual de máscaras (huellas, ajustes OBIA)	\$1.500.000
Equipos	Uso estación de trabajo de laboratorio (CPU + GPU)		\$1.000.000
Materiales y Suministros		Disco externo y posibles licencias	\$2.500.000

		menores (software de apoyo, papelería básica)	
Viáticos y Gastos de Viaje			\$0
Impresos y Publicaciones		Entregables finales y revisiones de tesis (impresos / encuadernación)	\$1.000.000
Patentes			\$0
TOTAL			\$33.800.000

DETALLE DE RUBROS

Tabla 2. Personal (Contrapartida UN)

Investigadores	Valor
Tesista	\$7.800.000
Profesor tutor	\$20.000.000
TOTAL:	\$27.800.000

Tabla 3. Servicios Técnicos

Descripción	Contrapartida UN	Cofinanciación	Total
Etiquetado y edición manual asistida de máscaras (huellas de edificaciones, ajustes de referencia para OBIA y validación)		\$1.500.000	\$1.500.000
TOTAL			\$1.500.000

Tabla 4. Equipos

Descripción	Contrapartida UN	Cofinanciación	Total
Uso de estación de trabajo de laboratorio (CPU + GPU	Incluido como infraestructura	\$1.000.000	\$1.000.000

NVIDIA T1000 8GB)	de la UN (sin costo directo)		
TOTAL			\$1.000.000

Tabla 5. Materiales y Suministros

Descripción	Contrapartida UN	Cofinanciación	Total
Disco externo para respaldo de datos y licencias menores / papelería de apoyo		\$2.500.000	\$2.500.000
TOTAL			\$2.500.000

Tabla 6. Viáticos y Gastos de viaje

Descripción	Contrapartida UN	Cofinanciación	Total
NA			\$0
TOTAL			\$0

Tabla 7. Impresos y Publicaciones

Descripción	Contrapartida UN	Cofinanciación	Total
Entregables finales y revisiones de tesis (impresión, encuadernación, copias)		\$1.500.000	\$1.500.000
TOTAL			\$1.500.00

11. Bibliografía citada

Amirgan, B., & Erener, A. (2024). Semantic segmentation of satellite images with different building types using deep learning methods. Remote Sensing Applications: Society and Environment, 34, 101176. <https://doi.org/10.1016/j.rsase.2024.101176>

Alsabhan, W., & Alotaiby, T. (2022). Automatic building extraction on satellite images using U-Net and ResNet50. Computational Intelligence and Neuroscience, 2022, 1938554. <https://doi.org/10.1155/2022/1938554>

Attarzadeh, R., & Momeni, M. (2010, octubre). Building extraction from high resolution satellite imagery using object based image analysis. En Proceedings of the 6th Iranian Conference on Machine Vision and Image Processing (MVIP).

Audebert, N., Le Saux, B., & Lefèvre, S. (2018). Beyond RGB: Very high resolution urban remote sensing with multimodal deep networks. ISPRS Journal of Photogrammetry and Remote Sensing, 140, 20–32. <https://doi.org/10.1016/j.isprsjprs.2017.04.009>

Biljecki, F., Ledoux, H., & Stoter, J. (2015a). Improving the consistency of multi-scale digital surface models. ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences, II-3/W5, 13–20.

Biljecki, F., Stoter, J., Ledoux, H., Zlatanova, S., & Çöltekin, A. (2015b). Applications of 3D city models: State of the art—A review. ISPRS International Journal of Geo-Information, 4(4), 2842–2889.

Blaschke, T. (2010). Object based image analysis for remote sensing. ISPRS Journal of Photogrammetry and Remote Sensing, 65(1), 2–16.

Chen, G., Weng, Q., Hay, G. J., & He, Y. (2018). Geographic object-based image analysis (GEOBIA): Emerging trends and future opportunities. GIScience & Remote Sensing, 55(2), 159–182. <https://doi.org/10.1080/15481603.2018.1426092>

Chen, H., Wang, W., Xu, Y., & Liu, H. (2021). Improving building segmentation accuracy using multisource remote sensing data and hybrid deep learning architectures. Remote Sensing, 13(2), 248.

Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., & Adam, H. (2018). Encoder-decoder with atrous separable convolution for semantic image segmentation. En Proceedings of the European Conference on Computer Vision (ECCV). <https://arxiv.org/abs/1802.02611>

Departamento Administrativo Nacional de Estadística (DANE). (2022). Ciudades intermedias y ruralidad en Colombia: Análisis territorial. DANE.

Dorado, D. (Comp.). (2022). El catastro multipropósito: Reflexiones alrededor de su potencialidad y aplicación. Escuela Superior de Administración Pública (ESAP).

Girshick, R. (2014). Rich feature hierarchies for accurate object detection and semantic segmentation. En Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 580–587).

Instituto Geográfico Agustín Codazzi (IGAC). (2020). Resolución 471 de 2020: Por la cual se establecen las especificaciones técnicas mínimas que deben tener los productos de la cartografía básica oficial de Colombia. IGAC.

Jamali, A., Kumar, P., & Abdul Rahman, A. (2019). Automated extraction of buildings from aerial LiDAR point clouds and digital imaging datasets. The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, XLII-4/W16, 303–310.

Jozdani, S., & Chen, D. (2020). On the versatility of popular and recently proposed supervised evaluation metrics for segmentation quality of remotely sensed images: An experimental case study of building extraction. ISPRS Journal of Photogrammetry and Remote Sensing, 160, 275–290. <https://doi.org/10.1016/j.isprsjprs.2020.01.002>

Kampffmeyer, M., Salberg, A. B., & Jenssen, R. (2016). Semantic segmentation of small objects and modeling of uncertainty in urban remote sensing images using deep convolutional neural networks. En Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW) (pp. 1–9). <https://doi.org/10.1109/CVPRW.2016.77>

Li, J., Cai, R., Deng, J., Yang, W., Li, S., & Du, P. (2024). A review of remote sensing image segmentation by deep learning. International Journal of Digital Earth, 17(1), 2328827.

Li, X., Cheng, G., Bu, S., & Yao, X. (2020). Building extraction from remote sensing images with edge-enhanced convolutional neural network. Remote Sensing, 12(8), 1247.

Lin, Y., Hyyppä, J., & Jaakkola, A. (2019). Mini-UAV-borne LiDAR for fine-scale mapping. Remote Sensing, 11(13), 1569.

Liu, P., Liu, X., Wu, W., Peng, D., & Li, L. (2019). Building footprint extraction from high-resolution satellite images using deep learning. Remote Sensing, 11(7), 830.

Lv, J., Peng, J., Li, L., & Liu, J. (2023). Deep learning-based semantic segmentation of remote sensing images: A review. Frontiers in Ecology and Evolution, 11, 1201125.

Mola Ebrahimi, S., Arefi, H., & Rasti Veis, H. (2017). Aerial imagery and LiDAR data fusion for unambiguous extraction of adjacent level-buildings' footprints. The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, XLII-4/W4, 179–183. <https://doi.org/10.5194/isprs-archives-XLII-4-W4-179-2017>

Neupane, B., Horanont, T., & Aryal, J. (2021). Deep learning-based semantic segmentation of urban features in satellite images: A review and meta-analysis. *Remote Sensing*, 13(4), 808.

Ojogbane, S. S., Abdullah, A. F., Pradhan, B., & Sulaiman, W. N. A. (2021). Automated building detection from airborne LiDAR and very high-resolution aerial imagery with deep neural network. *Remote Sensing*, 13(23), 4803.

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8), 913–929. <https://doi.org/10.1111/ecog.02881>

Rottensteiner, F., Trinder, J., Clode, S., & Kubik, K. (2004). Fusing airborne laser scanner data and aerial imagery for automatic building extraction. *ISPRS Journal of Photogrammetry and Remote Sensing*, 58(3–4), 187–197.

Sohn, G., & Dowman, I. (2007). Data fusion of high-resolution satellite imagery and LiDAR data for automatic building extraction. *ISPRS Journal of Photogrammetry and Remote Sensing*, 62(1), 43–63. <https://doi.org/10.1016/j.isprsjprs.2007.01.001>

Valavi et al. (2019) – spatial blocking
Valavi, R., Elith, J., Lahoz-Monfort, J. J., & Guillera-Arroita, G. (2019). BlockCV: An R package for generating spatially or environmentally separated folds for k-fold cross-validation of species distribution models. *Methods in Ecology and Evolution*, 10(2), 225–232. <https://doi.org/10.1111/2041-210X.13107>

Verdecchia, R., Sallou, J., & Cruz, L. (2023). A systematic review of Green AI: Practices and tools for measuring the energy consumption of deep learning experiments. *WIREs Data Mining and Knowledge Discovery*, 13(3), e1507.

Wang, Y., Shang, L., Liu, Y., Sun, Z., Lu, Y., Shi, X., Wang, T., & Liu, Y. (2025). Precise building semantic segmentation in remote sensing images via MR-DeepLabv3+ network. *Scientific Reports*, 15, 40100.

Yuan, Y., Shi, X., & Gao, J. (2025). Building extraction from remote sensing images with deep learning: A survey on vision techniques. *Computer Vision and Image Understanding*, 251, 104253. <https://doi.org/10.1016/j.cviu.2024.104253>

Zhang, C., Sargent, I., Pan, X., Li, H., Gardiner, A., Hare, J., & Atkinson, P. M. (2019). Joint deep learning for land cover and land use classification. *Remote Sensing of Environment*, 221, 173–187. <https://doi.org/10.1016/j.rse.2018.11.014>

Zhu, X. X., Tuia, D., Mou, L., Xia, G.-S., Zhang, L., Xu, F., & Fraundorfer, F. (2017). Deep learning in remote sensing: A comprehensive review and list of resources. IEEE Geoscience and Remote Sensing Magazine, 5(4), 8–36. <https://doi.org/10.1109/MGRS.2017.2762307>

Reporte de originalidad (reporte creado por una herramienta de evaluación de la originalidad en la producción y en el manejo documental, a la cual se haya sometido el documento de Proyecto de Tesis. Este reporte debe contar con el aval del director propuesto.