sensores

MDPI

Revisión

Una revisión de la investigación sobre la tecnología SLAM basada en la fusión de LiDAR y visión

Peng Chen 1, Xinyu Zhao 1, Lina Zeng 1,2,3, Luxinyu Liu 1, Shengjie Liu 1,2,3 b, Li Sun 1,2,3, Zaijin Li1,2,3,Hao Chen 1,2,Guojun Liu 1,2,3,Zhongliang Qiao 1,2,3(10), Yi Qu 1,2,3, Dongxin Xu 2, Lianhe Li 3 y Lin Li 1,2,3,*(10)

1Facultad de Física e Ingeniería Electrónica, Universidad Normal de Hainan, Haikou 571158,China;202206071306@hainnu.edu.cn(P.C.);202206071348@hainnu.edu.cn(X.Z.);zenglina@hainnu.edu.cn(L.Z.);202206071328@hainnu.edu.cn(L.L.);liushengjie@hainnu.edu.cn (S.L.);lisun@hainnu.edu.cn(L.S.);lizaijin@hainnu.edu.cn(Z.L.);chenhao@hainnu.edu.cn(H.C.);068006@hainnu.edu.cn (G.L.);qzhl060910@hainnu.edu.cn(Z.Q.);quyi@hainnu.edu.cn(Y.Q.)

2 Laboratorio clave de tecnología láser y materiales funcionales optoelectrónicos de la provincia de Hainan, Universidad Normal de Hainan, Haikou 571158, China; jilinchangchun@yeah.net

3Centro Internacional de Investigación Conjunta de Hainan para Láseres Semiconductores, Universidad Normal de Hainan, Haikou 571158,China;910335@hainnu.edu.cn

*Correspondence:lin.li@hainnu.edu.cn

Resumen: En los últimos años, la localización y el mapeo simultáneos con la fusión de LiDAR y la fusión de la visión han ganado una amplia atención en el campo de la navegación autónoma y la detección del entorno. Sin embargo, sus limitaciones en escenarios ambientales y entornos dinámicos con pocas características (baja textura, estructura repetitiva) han llevado a los investigadores a investigar el uso de la combinación de LiDAR con otros sensores, en particular la fusión efectiva con sensores de visión. Esta técnica ha demostrado ser muy eficaz en el manejo de una variedad de situaciones mediante la fusión del aprendizaje profundo con algoritmos adaptativos. LiDAR destaca en entornos complejos, por su capacidad para adquirir información espacial 3D de alta precisión, especialmente cuando se trata de entornos complejos y dinámicos con alta fiabilidad. Este artículo analiza el estado de la investigación, incluyendo los principales resultados y hallazgos de la investigación, o la tecnología SLAM de un solo sensor y la etapa actual de LiDAR y la fusión de visión SLAM. Las soluciones específicas para los problemas actuales (complejidad de la fusión de datos, carga computacional y rendimiento en tiempo real, procesamiento de datos en múltiples escenarios, etc.) se examinan categorizando y resumiendo el cuerpo de la literatura existente y, al mismo tiempo, dis Ali Khenchaf maldecir las tendencias y limitaciones de la investigación actual categorizando y resumiendo 2025 la bibliografía existente, así como espera con interés las futuras direcciones de investigación, entre ellas Fusión multisensor, optimización de algoritmos, mejora del rendimiento en tiempo real UARY 2025 y la expansión de los escenarios de aplicación. Esta revisión tiene como objetivo proporcionar directrices y puntos de vista 25 para el desarrollo de la tecnología SLAM para LiDAR y la fusión de la visión, con el fin de proporcionando una referencia para futuras investigaciones sobre la tecnología SLAM.

Buscar actualizaciones

Editor Académico:

Recibido: 14 Revisado20 de enero Aceptado: 24 febrero Castigado:27 Febrero

Cita: Chen, P.; Liu, L.; Liu, S.; Sol Liu,G.; Qiao, Z.; e Investigación sobre SLA en la fusión de L

Sensores 2025,25,1447.

https://doi.org/10.3390/s25051447

Derechos de autor:©2025 de los autores. Licenciatario MDPI, Basilea, Suiza.Este artículo es un artículo de acceso abierto distribuido bajo los términos y condiciones de la licencia Creative Commons Attribution (CC BY) (https://creativecommons.org/licenses/by/4.0/).

Palabras clave: LiDAR; sensores de visión; PORTAZO; fusión de datos; navegación autónoma; dinámico Entornos; aprendizaje profundo; Información semántica

1. Introducción

La aplicación de LiDAR y la fusión de visión en la tecnología SLAM (localización y mapeo simultáneos) se ha convertido en una importante dirección de investigación en el campo de la navegación autónoma y la percepción del entorno. Con el rápido desarrollo de sistemas autónomos, como robots móviles, vehículos no tripulados y UAV (vehículos aéreos no tripulados), la demanda de capacidades de detección del entorno y navegación autónoma

se ha vuelto más fuerte, y la combinación de LiDAR y sensores de visión traería nuevas oportunidades para el desarrollo de la tecnología SLAM. El rendimiento y la resistencia de los sistemas SLAM en situaciones complicadas se pueden mejorar en gran medida combinando los datos de los sensores de visión, que pueden proporcionar información rica sobre la textura del entorno, con lidar, que puede proporcionar información de distancia de alta precisión. En muchos sectores se han utilizado algunos algoritmos de marco sobresalientes, con un rendimiento sobresaliente en la etapa actual de los enfoques SLAM visuales [1], que es crucial para la navegación segura de vehículos autónomos en entornos urbanos intrincados [2]. Además, cuando se enfrentan a entornos desconocidos, la tecnología SLAM permite a los robots sincronizar la creación de mapas y la adquisición de sus propios datos de posición, logrando una navegación eficiente, una función crucial en situaciones donde las señales GPS son limitadas o inexistentes.

La idea fundamental detrás de la tecnología SLAM es usar sensores (como LiDAR y sensores de visión) para recopilar datos ambientales, un proceso que utiliza algoritmos de datos y actualiza la ubicación y el mapa del dispositivo en tiempo real. Las dos tareas simultáneas de localización y creación de mapas forman la base de la tecnología. Mientras que el mapeo es el proceso de crear un mapa del entorno, la localización es el proceso de estimar la posición del dispositivo en el entorno utilizando datos de sensores. El procesamiento de la entrada del sensor y la combinación de información es esencial para la implementación de SLAM. Hay tres tipos de SLAM: SLAM láser, SLAM de visión y una combinación de los dos, dependiendo de los sensores.

Dado que LiDAR es una herramienta de detección ambiental de alta precisión, el láser SLAM puede demostrar sus ventajas distintivas en entornos complejos con diferentes condiciones dinámicas y de iluminación. Sin embargo, sus limitaciones también son evidentes. Por ejemplo, su rendimiento se deteriorará en entornos con pocas características con poca textura y estructuras repetitivas. Debido a que los datos láser solo contienen información de distancia y no detalles de textura ambiental, será difícil crear mapas en áreas con pocas características. Sin embargo, el láser SLAM también depende en gran medida del entorno y sufrirá problemas de escasez de datos en situaciones complejas o dinámicas (como ciudades congestionadas). Del mismo modo, dará lugar a la pérdida de datos o a un mal juicio a la hora de identificar superficies muy reflectantes o claras. Además, los datos LiDAR suelen carecer de información semántica enriquecida, lo que dificulta la clasificación y el reconocimiento de objetos. La aplicación del láser SLAM se verá muy limitada debido a los enormes datos de nubes de puntos generados por la tecnología, que tiene altos requisitos para el procesamiento y el almacenamiento en tiempo real, especialmente en entornos dinámicos donde la demanda de rendimiento en tiempo real y recursos computacionales aumenta significativamente. Sin embargo, el SLAM visual es más sensible a los cambios en la iluminación y la textura, y funciona mal en escenas que son muy dinámicas o tienen bajos niveles de luz. Los objetos dinámicos pueden interferir con el SLAM visual en entornos dinámicos (por ejemplo, peatones, automóviles, etc.). Por lo general, este enfoque depende del modelo de movimiento (como la traslación y la rotación) de la cámara. El movimiento rápido o complejo puede hacer que la precisión del modelo disminuya, lo que podría afectar la precisión del posicionamiento y, en última instancia, resultar en fallas de seguimiento o errores de posicionamiento significativos; En escenas con poca luz, la fiabilidad de la extracción y la coincidencia de características disminuirá significativamente debido a la disminución significativa de la calidad de la imagen, lo que podría provocar un error de posicionamiento. Por otro lado, el SLAM visual es más asequible, tiene un mayor grado de adaptabilidad ambiental con una rica información de color espacial y alta resolución, y puede identificar y distinguir mejor objetos estáticos y dinámicos [3].

Por lo tanto, el uso combinado de LiDAR y sensores de visión supera sus limitaciones individuales y muestra una mayor precisión y una mayor adaptabilidad al entorno en la creación de mapas y las actividades de autolocalización para manejar escenarios de aplicación más difíciles. Específicamente, puede aumentar en gran medida la adaptabilidad y confiabilidad del sistema al manejar impedimentos de movimiento en escenarios intrincados y dinámicos [4]. Por ejemplo, el método SLAM de visión directa de Young-Sik Shin et al. (2018) que combina información de profundidad dispersa

muestra que la integración de LiDAR y los datos de la cámara de visión puede mejorar la precisión y el rendimiento en tiempo real [5].

En resumen, a medida que la tecnología SLAM continúa avanzando, la combinación de LiDAR y sensores de visión no solo avanza en la tecnología SLAM, sino que también avanza en campos de estudio relacionados y crea nuevas oportunidades para la navegación autónoma y la percepción del entorno [6]. La base teórica y la dirección práctica del sistema SLAM con una mayor eficiencia y resiliencia logradas por la fusión de las tecnologías LiDAR y SLAM de visión serán cruciales a la luz de los escenarios de aplicación actuales, cada vez más complicados.

2. La historia del desarrollo de la tecnología SLAM

Desde los primeros algoritmos simples hasta las tecnologías de fusión modernas y complicadas, la tecnología SLAM ha pasado por múltiples etapas de desarrollo, creando una amplia área de investigación. Al principio, el SLAM dependía principalmente de la estimación de la pose y de la coincidencia de puntos de características dispersas (Davison et al., 2007) [7]. Los investigadores han sugerido muchos marcos de algoritmos para maximizar el rendimiento de los sistemas SLAM a medida que ha aumentado la potencia de cálculo. Por ejemplo, la efectividad de los algoritmos SLAM se evalúa objetivamente mediante mediciones basadas en relaciones de pose relativas, corrigiendo así la información de pose y optimizando el mapa [8], evitando los inconvenientes de depender de un marco de referencia global. La combinación de datos multidimensionales recopilados por sensores adicionales para optimizar el sistema SLAM general ofrece más beneficios que la mejora de los algoritmos de pose relativa. Por ejemplo, la consistencia de la trayectoria global se optimiza combinando los beneficios de las características visuales y la información de escala del sensor de profundidad 3D para estimar simultáneamente la trayectoria de la cámara y crear un modelo 3D detallado del entorno [9]. Al mismo tiempo, también se han proporcionado marcos de algoritmos para evaluar el error de posición global de los sistemas SLAM y la deriva de los sistemas de odometría visual con el fin de facilitar las comparaciones objetivas entre varios algoritmos [10], como se muestra en la Figura 1. Antes del año 2000, LiDAR (Lidar) era la herramienta principal utilizada por la tecnología SLAM para la creación y el posicionamiento de mapas. El filtro de Kalman extendido (EKF) se empleó con frecuencia para la estimación del estado en los primeros algoritmos, que dependían principalmente de un solo sensor, especialmente los escáneres láser. Este enfoque funciona bien en entornos de pequeña escala, pero no es muy flexible en los de gran escala. A medida que la potencia de procesamiento aumentó entre 2000 y 2005, el algoritmo SLAM comenzó a desarrollarse progresivamente, incluidos los datos visuales, adoptó técnicas de optimización de gráficos y fusión de múltiples sensores, y aumentó la precisión y la resistencia del sistema. Entre 2005 y 2010, la tecnología SLAM avanzó rápidamente, y la investigación se concentró en el rendimiento adaptativo y en tiempo real. También se introdujo una variedad de marcos SLAM en tiempo real, junto con características dispersas (como SIFT y SURF) para la creación de mapas y métodos de optimización global (como el ajuste de paquetes) para aumentar la precisión. Desde 2010, la integración de láser y visión SLAM ha avanzado a un nuevo nivel debido a los avances en las tecnologías de aprendizaje profundo y big data. El rendimiento del sistema mejora en gran medida gracias a la extracción de características y la asociación de datos, lo que es posible gracias al aprendizaje profundo. Ha mejorado el nivel de inteligencia y ha mantenido un equilibrio saludable entre flexibilidad y rendimiento en tiempo real.

Los investigadores han comenzado a investigar técnicas SLAM basadas en información visual densa con el uso combinado de sensores visuales. Al modelar densamente el entorno, estas técnicas pueden mejorar aún más la consistencia y la calidad de la construcción del mapa [11]. Como resultado, LiDAR y la tecnología de fusión de visión han ganado popularidad de manera constante en la investigación de SLAM. La tecnología SLAM tradicional suele suponer un entorno estático, pero los objetos en movimiento, en realidad, pueden tener un impacto significativo en el posicionamiento. Esto la diferencia de la tecnología SLAM temprana, en que carece de robustez estable y tiene poca flexibilidad y precisión en el proceso de aplicación debido a la fuerte influencia de los factores ambientales. Por ejemplo, las circunstancias climáticas desfavorables (como la lluvia y la niebla) pueden producir más

ruido ambiental para el sistema SLAM, o no puede extraer características de manera confiable en situaciones de iluminación complejas, lo que puede resultar en una baja precisión del sistema. La combinación eficaz de LiDAR y los datos de los sensores visuales puede mejorar en gran medida el rendimiento general de SLAM, en particular su resistencia en situaciones de movimiento rápido e iluminación inadecuada [12]. Por lo tanto, la precisión del posicionamiento de los sistemas SLAM en entornos complejos se ha mejorado en gran medida gracias a los métodos de segmentación de escenas basados en la información semántica del entorno y la verificación de la consistencia de los objetos dinámicos; Se ha propuesto un marco SLAM basado en la fusión de LiDAR de bajo coste y sensores visuales (cámara RGB-D) [13] mediante la construcción de una nueva función de coste y la combinación de los datos de imagen escaneados, mejorando aún más la precisión del posicionamiento. Los investigadores han demostrado el potencial de los sensores visuales en situaciones complejas y han configurado una gama de sensores para lograr SLAM visual y visual-inercial de alta precisión [14], como se muestra en la Figura 2. El marco comprende tres pasos principales y se adhiere a la arquitectura SLAM tradicional: (a) Determinar los valores propios para estimar el escenario global, mediante la predicción de los valores propios del escenario global, el sistema SLAM puede lograr un compromiso sólido entre precisión y rendimiento en tiempo real; b) En la etapa original de procesamiento de datos, el procesamiento original de los datos ha aumentado el rendimiento del sistema SLAM en contextos complicados y dinámicos, además de mejorar la calidad y la fiabilidad de los datos; c) Creación de un mapa mundial y subsanación de las incoherencias de los datos. Resolver las incoherencias de los datos y crear un mapa global puede ayudar a aumentar la precisión y la coherencia del mapa, al tiempo que disminuye los efectos de los cambios ambientales y los errores de los sensores.

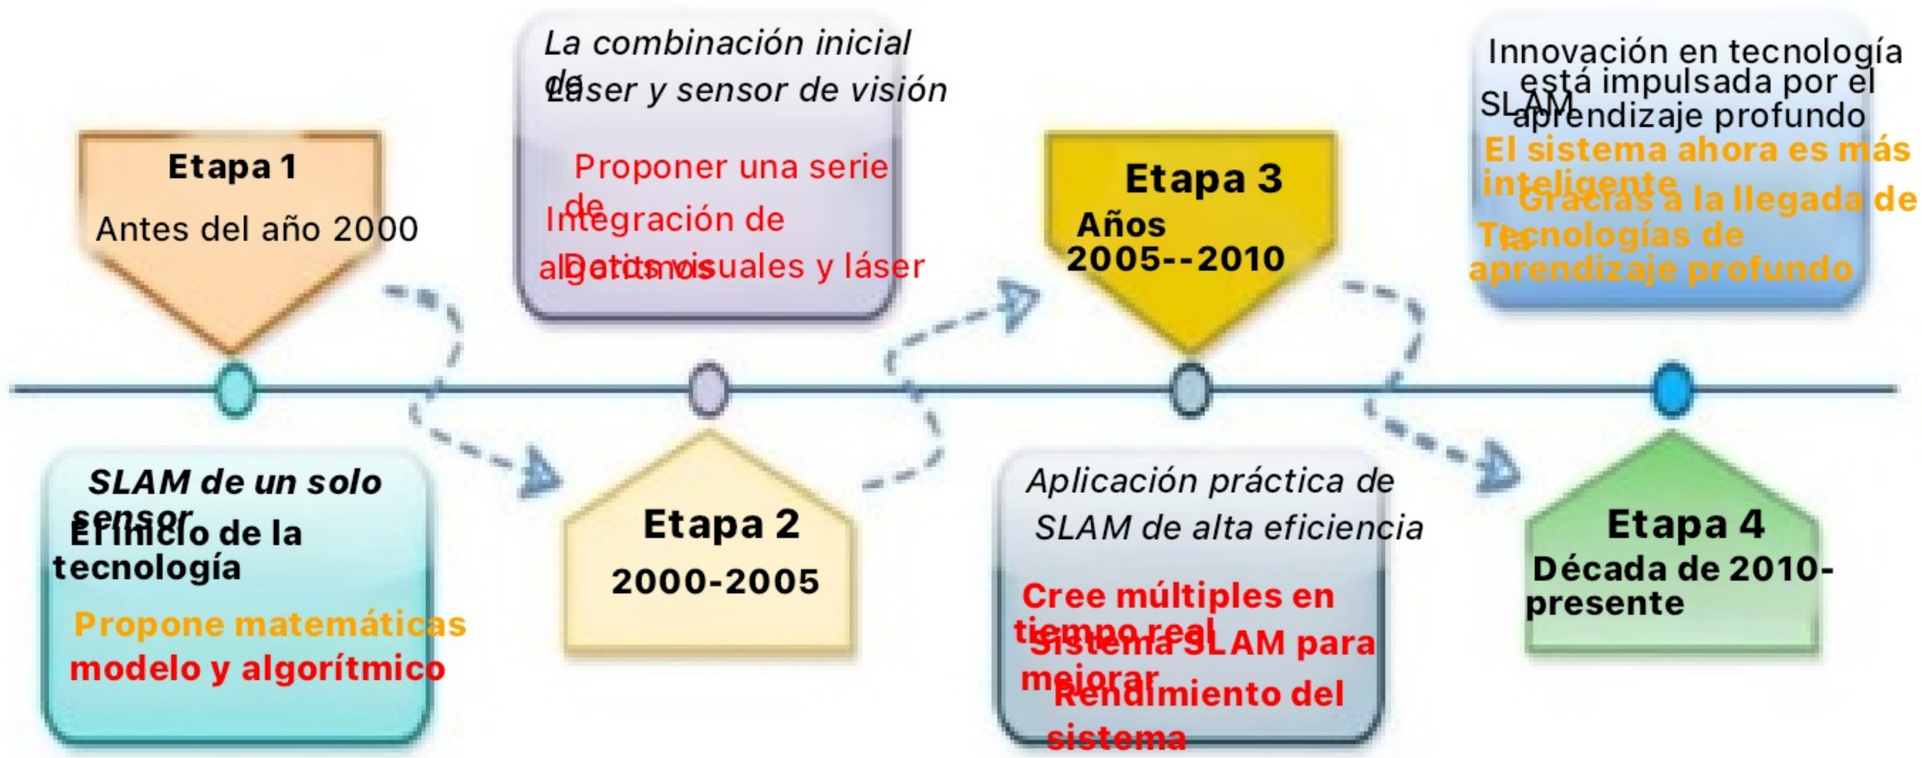

Figura 1. Resumen de los avances de la investigación SLAM.

Además, el láser SLAM junto con el aprendizaje profundo puede mejorar significativamente el rendimiento del sistema en la detección de bucle cerrado, mostrando así la promesa de la tecnología de fusión para aumentar la resistencia de los sistemas SLAM [15]. El rendimiento en situaciones complicadas puede mejorarse eficazmente mediante el empleo de redes neuronales recurrentes (RNN) y redes neuronales convolucionales (CNN) [16]. Además, el enfoque visual denso GS-SLAM con representación gaussiana en 3D puede equilibrar mejor la precisión y la eficiencia. El uso de la técnica GS-SLAM ha mejorado en gran medida la calidad y la consistencia de la construcción de mapas en comparación con el sistema SLAM denso en tiempo real anterior basado en surfels [17].

En resumen, a medida que la potencia de cómputo ha aumentado y la investigación continúa avanzando, la tecnología SLAM actual ha evolucionado hacia la fusión de datos multisensor, en particular el uso de la tecnología SLAM de fusión visual y radar láser, que también se investiga y mejora constantemente hacia la eficiencia, la precisión y la robustez [18]. Además de esbozar los beneficios y desventajas de la tecnología, en este documento se evalúa y resume el estado de la

investigación sobre la tecnología láser y de fusión visual SLAM y explica por qué son necesarios el láser radar y la fusión visual.

Figura 2. Los tres pasos principales del marco para la arquitectura SLAM tradicional: (a) la determinación del valor propio para estimar el escenario global; b) Etapa original de procesamiento de datos; c) Etapa de creación de mapas globales e inconsistencias de datos.

3. Las técnicas primarias para el estudio de la tecnología SLAM

Tanto la durabilidad del sistema como la precisión de la construcción de mapas han aumentado sustancialmente con la integración de LiDAR y sensores ópticos. Esta combinación maneja con éxito los cambios dinámicos en circunstancias complicadas y es crucial para las aplicaciones actuales [19]. Hoy en día, la tecnología SLAM que combina sensores ópticos y LiDAR ha evolucionado hacia una variedad de métodos. En este estudio se explican las características, beneficios y dificultades de cada técnica de fusión. Además, llama la atención sobre las similitudes entre estos enfoques y sugiere nuevas líneas de investigación para el avance de este sistema integrado SLAM.

3.1.Una técnica de fusión multimodal basada en datos

En la tecnología SLAM de fusión de láser y visión, la ruta técnica de la fusión de datos multimodal incluye múltiples pasos interrelacionados, como se muestra en la Figura 3. En primer lugar, el SLAM migratorio utiliza el conocimiento existente para adaptarse rápidamente al nuevo entorno y sienta las bases de todo el proceso. A continuación, la verificación de datos multimodal garantiza la coherencia entre los datos láser y visuales, proporcionando una entrada fiable para el posterior mapeo intercalado de inserción, lo que mejora los detalles del mapa. El flujo visual analiza el movimiento entre fotogramas adyacentes para proporcionar soporte para la extracción de características, que extrae puntos de características clave de los datos láser y visuales, sentando las bases para la integración de descriptores unificados en la etapa de salida de captura de características. Los datos láser proporcionan información geométrica de alta precisión para ayudar en la extracción de características. Posteriormente, la fusión de sensores integra datos de diferentes fuentes para mejorar la precisión general del posicionamiento, mientras que la fusión visual integra múltiples información de imagen para formar una representación ambiental consistente. A través de la cierbol

La conexión de estos pasos, la tecnología de fusión de datos multimodal mejora significativamente el rendimiento y la robustez de los sistemas SLAM en entornos complejos.

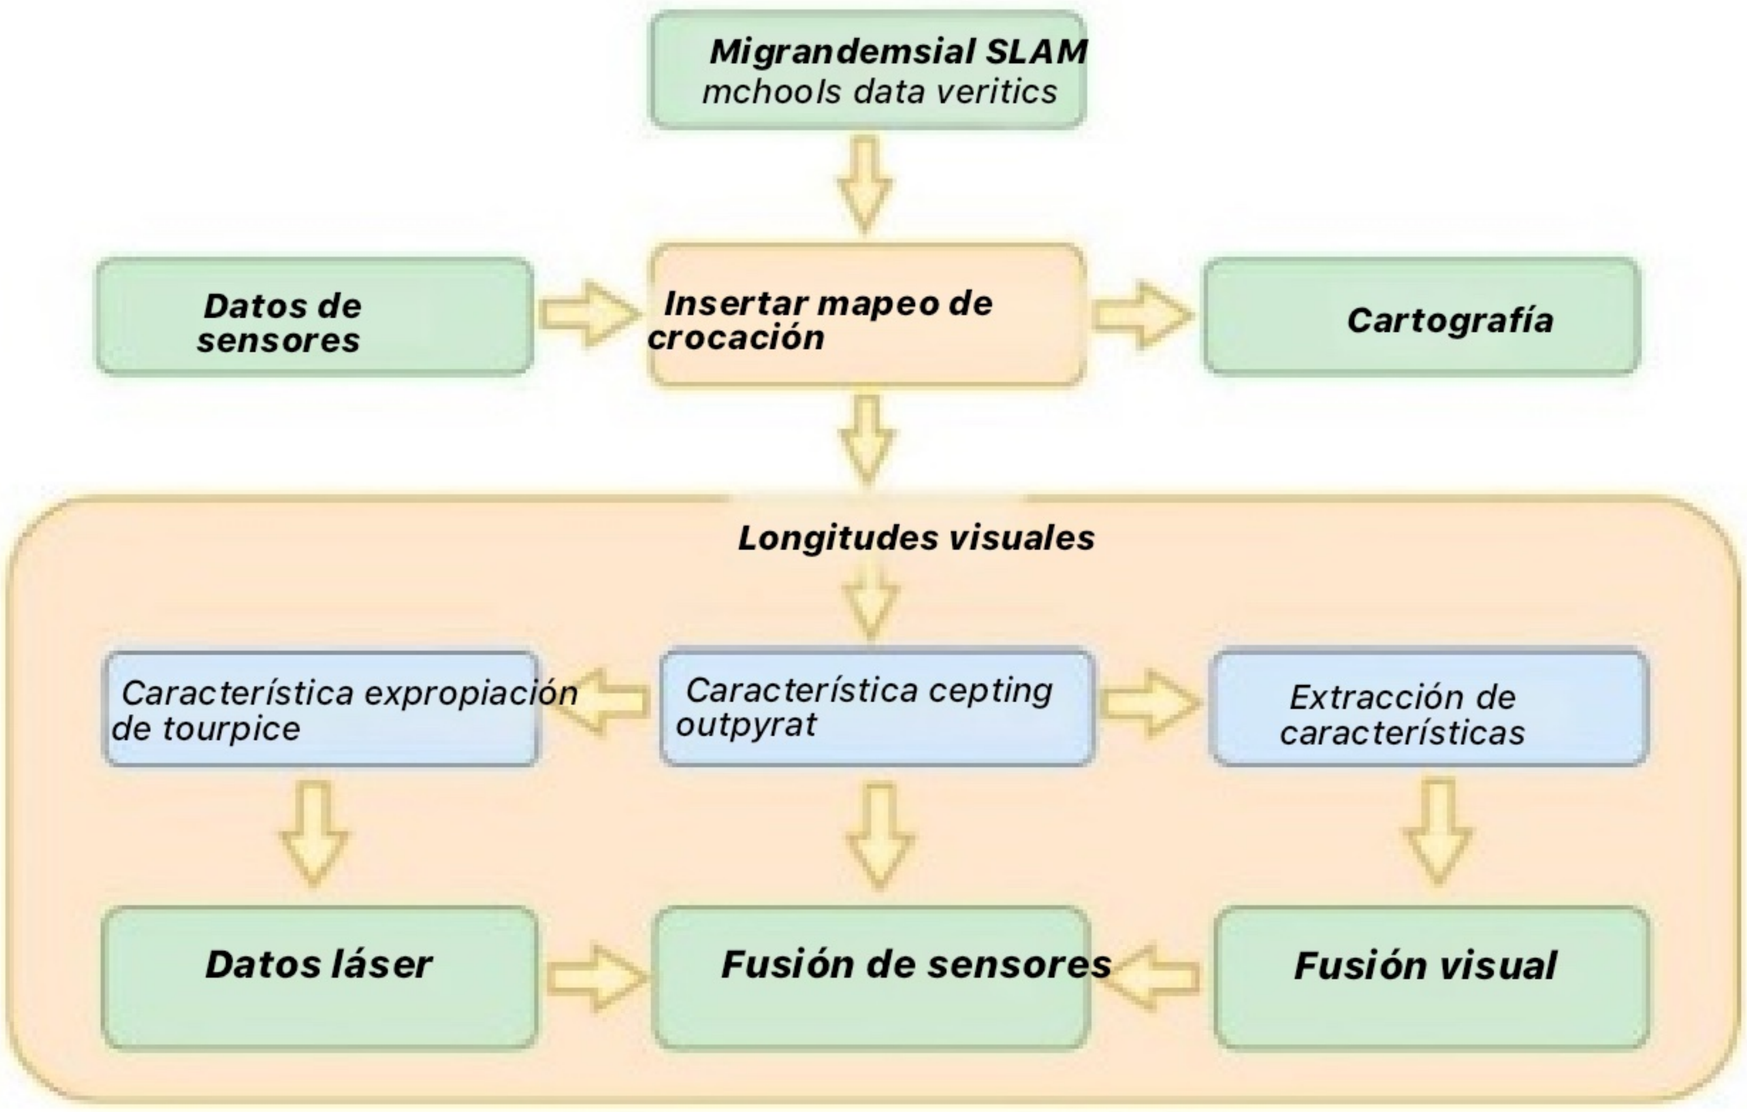

Figura 3. Diagrama del flujo de la tecnología de fusión de datos multimodal.

La fusión de varias entradas de sensores y la optimización del marco algorítmico son los temas principales de la investigación actual sobre técnicas SLAM multimodales. Según Kolar et al. (2020), que estudiaron una serie de estrategias de fusión en su investigación, la fusión de datos de LiDAR y sensores de visión puede mejorar en gran medida el rendimiento de la navegación autónoma [20]. Los subsistemas LIO (odometría láser-inercial) y VIO (odometría visual-inercial), que estiman conjuntamente el estado del sistema fusionando sus respectivas nubes de puntos láser o datos de visión con los datos de la IMU, también han sido propuestos por investigadores de algoritmos como parte del marco compacto FAST-LIVO. Emplean un método directo de minimización de errores fotométricos para evitar el lento proceso de extracción y coincidencia de características, lograr una estimación de estado y construcción de mapas de alta precisión, y mejorar la eficiencia computacional [21]. Un mejor rendimiento de la navegación autónoma en una variedad de situaciones ambientales sería posible gracias al marco de estimación óptima de restricciones múltiples desarrollado mediante la utilización de información LiDAR como características visuales que están estrechamente conectadas [22].

Además, al integrar estrechamente los datos de seguimiento de objetivos con el sistema SLAM, los investigadores han podido mejorar en gran medida el rendimiento general del sistema. El marco BEV-Fusion, propuesto por Liang et al. (2022), muestra cómo se puede fusionar la información de la visión y la LiDAR. Aborda la capacidad de la información de visión para continuar realizando la tarea por sí sola en caso de falla de LiDAR, lo cual es crucial para las aplicaciones del mundo real [23]. El método de campo de distancia simbólica truncada (TSDF), que tiene una tasa de convergencia mucho más rápida y puede aumentar en gran medida la precisión de la localización de la cámara y la reconstrucción 3D, así como proporcionar resultados de reconstrucción de mayor calidad, se utiliza para procesar los datos en escenarios SLAM densos mediante la combinación de la tecnología de campo de radiación neuronal (NeRF) más reciente con el sistema SLAM [24].

En consecuencia, la técnica SLAM multimodal, que combina varias entradas de sensores, puede aumentar la precisión del sistema SLAM, así como su adaptabilidad a situaciones difíciles. Por ejemplo, varias de las técnicas existentes, incluyendo ROVIO (robusto

odometría visual-inercial), VINS-Mono y LOAM (odometría y mapeo lidar), han demostrado un buen rendimiento y adaptabilidad. Para la odometría y la actualización de mapas, el método LOAM divide los datos de la nube de puntos en entidades terrestres y no terrestres, respectivamente. Mediante el uso de la coincidencia de características para la estimación de la postura, el procesamiento rápido de nubes de puntos y la optimización global, esta técnica emplea un enfoque de procesamiento jerárquico para aumentar la precisión del mapa. El algoritmo VINS-Mono es un sistema de navegación visual-inercial que integra datos de unidades de medición inercial (IMUs) y cámaras monoculares. Utilizando un filtro de modo deslizante (SMF) y optimización no lineal, puede realizar una estimación del estado, lo que permite el seguimiento en tiempo real de la posición de la cámara y el estado del movimiento. El algoritmo ROVIO, que combina el seguimiento visual de características y las mediciones de IMU para proporcionar precisión y robustez en situaciones dinámicas. En general, los algoritmos de fusión de datos multimodales exhiben una amplia aplicabilidad y una gran viabilidad, son más precisos en la extracción de características de múltiples sensores y el modelado ambiental, y pueden integrar datos de múltiples sensores para mejorar la robustez del sistema en entornos complejos. También funcionan bien en una variedad de escenarios de aplicación, como escenas naturales complejas, navegación en interiores y entornos urbanos. El enfoque de fusión de datos multimodal, por otro lado, se centra no solo en cómo recopilar y procesar datos de varios sensores, sino también en cómo crear un algoritmo que pueda combinar los datos de manera efectiva, lo que permite que el sistema aumente la precisión y tenga una capacidad de detección del entorno más fuerte para manejar escenas cada vez más complejas.

3.2. Métodos de fusión basada en características

Es una práctica común utilizar puntos de características para LiDAR y fusión de visión en algoritmos SLAM. Para una localización y creación de mapas más precisas, estas técnicas suelen basarse en puntos de características que se toman de los sensores. Li et al. (2020) afirmaron que la robustez del sistema en situaciones complicadas aumenta considerablemente mediante el uso del modelo HF-Net para extraer características locales (puntos clave y descriptores) y características globales (los descriptores de imagen y el color, la textura y otros atributos de los objetos se denominan descriptores de imagen). Estos atributos se pueden utilizar para resumir las cualidades generales de una imagen y son apropiados para el reconocimiento y la coincidencia de escenas), particularmente en términos de relocalización y detección de bucle cerrado [25]. Este método tiene la ventaja de poder hacer uso de la alta precisión y la riqueza de las características visuales de LiDAR, lo que permite un buen rendimiento continuo en escenarios desafiantes.

Además, la adquisición simultánea de datos de color y profundidad mediante sensores RGB-D aumenta significativamente la precisión y la densidad del mapa [26]. La combinación de RGB-D SLAM con LiDAR permite una extracción de características y un seguimiento de objetivos más eficientes en situaciones complicadas al optimizar la estimación de la trayectoria de la cámara utilizando la información precisa de LiDAR [27,28].

A través de una profunda integración de los datos del láser de profundidad y los atributos de la imagen, el enfoque de fusión profunda mejora considerablemente la precisión de la detección de objetos en 3D [29]. Al fusionar fotos panorámicas con datos LiDAR, el enfoque PVL-Cartographer de Zhang et al. (2023) aborda el problema de la ubicación de alta precisión y la creación de mapas en paisajes con pocas características [30], como se muestra en la Figura 4.

3.3. Técnica SLAM con asistencia a la información semántica

Los enfoques SLAM asistidos por información semántica aumentan la potencia de procesamiento de los objetos dinámicos mediante la incorporación de información de segmentación semántica. Este enfoque incluye principalmente la inteligencia artificial, identificando objetos en la escena para mejorar la flexibilidad del sistema SLAM a situaciones cambiantes [31]. Con el fin de evitar el problema de los hilos de seguimiento a la espera de información semántica y mantener el rendimiento en tiempo real del algoritmo.

mance, Liu et al. (2021) propusieron un algoritmo RDS-SLAM dinámico visual en tiempo real que selecciona fotogramas clave mediante la adición de hilos semánticos e hilos de optimización basados en semántica [32]. Esto permite que varios métodos de segmentación de velocidad obtengan la información semántica más reciente para un uso unificado. Este enfoque tiene la ventaja de poder crear mapas y realizar un seguimiento fiable en contextos dinámicos en tiempo real. El rendimiento general del sistema también se puede mejorar utilizando los beneficios de la representación implícita neuronal para identificar y procesar objetos dinámicos con información semántica.

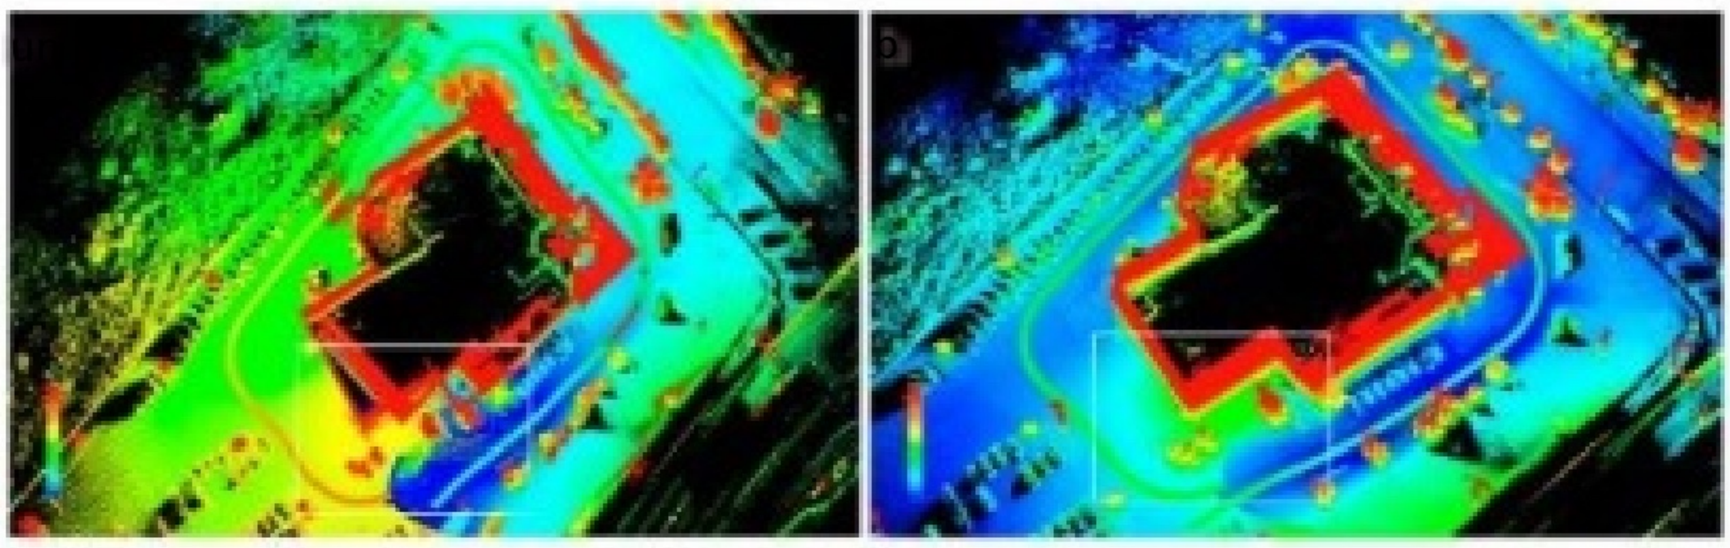

Figura 4. (a) La desalineación del sistema PVL-Cartographer se representa sin detección de bucle cerrado; b) los resultados tras la detección en bucle cerrado. En (a,b), la región donde se lleva a cabo la detección de cierre de bucle está encerrada por el rectángulo blanco. Con el fin de fusionar nubes de puntos LiDAR con fotos panorámicas, el sistema combina LiDAR montado en inclinación, cámaras panorámicas y sensores IMU. A continuación, utiliza datos internos y algoritmos para calcular la escala real del entorno sin necesidad de información posicional adicional. Incluso en entornos con características limitadas, puede funcionar de manera efectiva y confiable al lograr la integración perfecta de los datos de muchos sensores, lo que aumenta la precisión y confiabilidad de los resultados de posicionamiento y mapeo [30].

Lou et al. (2023) sugirieron una técnica SLAM basada en la combinación de LiDAR y visión monocular para superar los inconvenientes a los que se enfrenta un solo sensor en situaciones dinámicas. La técnica aumentó en gran medida la precisión de posicionamiento mediante el uso de subprocesos paralelos para procesar nubes de puntos 3D de baja resolución e imágenes semánticas. La eficiencia de LiDAR y la fusión de visión queda demostrada por los hallazgos experimentales, que muestran que el error de posicionamiento de este método se ha reducido en aproximadamente un 87% en varios conjuntos de datos. Esto sugiere que la tecnología tiene el potencial de aumentar la precisión de posicionamiento en escenas complicadas [33], como se muestra en la Figura 5. Como resultado, el enfoque SLAM asistido por información semántica ofrece numerosos beneficios, incluida una mayor resiliencia, una mejor precisión de posicionamiento y soporte para trabajos desafiantes.

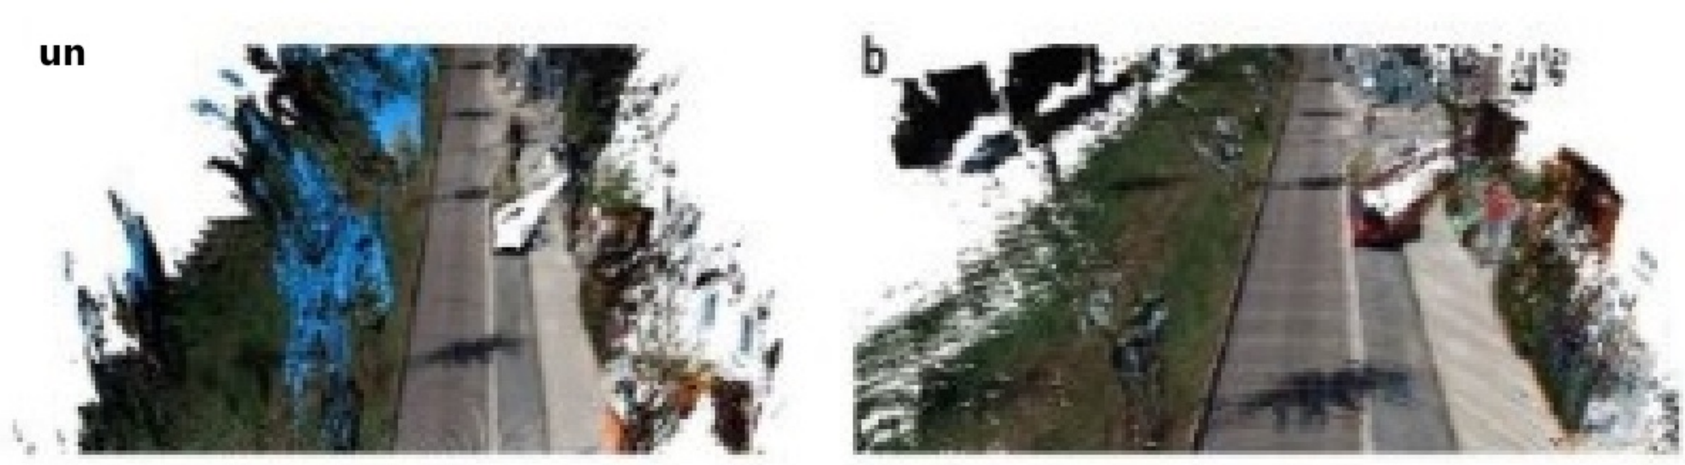

Figura 5. Comparación del esquema de Lou et al. y la calidad de la reconstrucción 3D utilizando técnicas de DynaSLAM: (a) reconstrucción de DynaSLAM, (b) reconstrucción de mnethod de Lou et al. [32].

Por lo tanto, el procesamiento del objetivo mediante el aprendizaje profundo es crucial para elevar el nivel de inteligencia de los sistemas SLAM y puede aumentar aún más la precisión del posicionamiento y la resistencia de los sistemas SLAM visuales. También ofrece nuevos conceptos para la extracción de características y la detección dinámica de objetos.

3.4. Método de fusión basado en el método directo

Al utilizar la información de píxeles de la imagen y predecir inmediatamente la pose a partir de los valores de brillo, esta técnica combina LiDAR y sensores visuales. El enfoque directo de la fusión funciona especialmente bien en contextos dinámicos, ya que puede gestionar mejor las alteraciones de la imagen.

Este método logra la fusión de LiDAR y sensores visuales mediante el uso de la información de píxeles de la imagen, estimando directamente la pose en función de los valores de brillo de la imagen y estimulando la pose minimizando las diferencias de brillo de la imagen. Específicamente, dada la imagen de fotograma actual y los valores de medición LiDAR, la relación entre los valores de brillo de la imagen y los datos LiDAR se utiliza para inferir la actualización de la pose de la cámara. Las condiciones de iluminación pueden tener un impacto significativo en la estimación de la pose en LiDAR y SLAM de fusión de sensores visuales. Por ejemplo, los cambios dinámicos de iluminación (como pasar de un entorno brillante a un área oscura) pueden provocar inconsistencias en el brillo de la imagen, lo que reducirá la fiabilidad del método directo. La iluminación desigual (como la coexistencia de sombras y luz directa) hace imposible que los valores de brillo reflejen eficazmente las características de la escena, lo que afectará aún más a la precisión de la coincidencia. Para abordar estos desafíos, la combinación de la tecnología de normalización de la iluminación con las características de invariancia de la iluminación sería una buena opción, lo que mejorará la solidez del algoritmo en entornos variables. Por lo tanto, los cambios en las condiciones de iluminación deben tenerse en cuenta en su totalidad en el método directo para optimizar la precisión y la estabilidad de la estimación de la pose. Al mismo tiempo, debido al mejor manejo de los cambios en la imagen por fusión directa de métodos, su rendimiento en entornos dinámicos es particularmente sobresaliente.

Para mejorar la precisión y robustez del sistema, Jakob Engel et al. (2018) propusieron un método de odometría visual directa y dispersa llamado odometría dispersa directa, o DSO. Este método puede optimizar de manera eficiente todos los parámetros del modelo y reconstruir todos los píxeles. Esto se logra optimizando el error fotométrico definido en los píxeles vecinos de cada punto en el procesamiento en tiempo real [34,35]. El método de fusión basado en el acoplamiento apretado no solo optimiza todos los parámetros del modelo, sino que también acelera el proceso de inicialización del sistema al agregar una cámara estéreo, minimizando así directamente el error fotométrico en la visión estéreo dinámica multivista, mejorando así la robustez y precisión del sistema [36].

Con el fin de aumentar la fiabilidad del sistema, Bescos et al. (2018) introdujeron el sistema DynaSLAM, que mejora el rendimiento de SLAM en entornos dinámicos al reparar el fondo y reconocer objetos dinámicos, lo que demuestra la eficiencia de la técnica directa en la gestión de obstáculos dinámicos [37]. A pesar de sus notables avances en el seguimiento y el mapeo en escenarios dinámicos, DynaSLAM todavía tiene limitaciones en lo que respecta a la complejidad del cómputo, la capacidad de actualización de mapas y la adaptación de la luz, particularmente exhibiendo una fragilidad considerable en entornos con variaciones de luz sustanciales. Además, es posible que el método no separe e identifique correctamente los objetos debido a la diferencia de luz entre los objetos dinámicos y los fondos estáticos, lo que podría comprometer la estabilidad de la estimación de la postura. Por lo tanto, es posible mejorar la adaptabilidad a la luz del sistema mediante la introducción de tecnología de aprendizaje profundo, la optimización de la estructura del algoritmo y la mejora del mecanismo de actualización de mapas para mejorar efectivamente el rendimiento de DynaSLAM y hacerlo más adaptable a aplicaciones prácticas en entornos dinámicos complejos. El potencial del método directo en entornos a gran escala se demuestra aún más con el enfoque LSD-SLAM (SLAM monocular directo a gran escala). Supera los inconvenientes de los enfoques directos actuales y construye un mapa ambiental consistente en entornos en tiempo real mediante el empleo de una técnica de seguimiento novedosa que corrige la deriva de la escala y aumenta la precisión de la estimación de la posición. La Figura 6 es un diagrama del marco del sistema. En la estimación de pose en tiempo real, la información de pose de alta precisión se obtiene mediante el método de alineación directa de la imagen, y el

El mapa de posición de los fotogramas clave y los mapas de profundidad semidensos asociados a estos fotogramas clave se generan reconstruyendo el entorno tridimensional en tiempo real. Al mismo tiempo, el mecanismo de seguimiento incorpora con éxito el ruido de los valores de profundidad pronosticados a través de enfoques probabilísticos, mejorando la capacidad del sistema para gestionar la incertidumbre de la estimación de la profundidad [38]. Sin embargo, todavía hay inconvenientes, incluido el texturizado inadecuado, el costo computacional excesivo y los problemas de asociación de datos, incluso con el sólido rendimiento de LSD-SLAM en SLAM monocular a gran escala. Por ejemplo, las habilidades de extracción y emparejamiento de características del LSD-SLAM se deterioran en superficies uniformes o de baja textura (como paredes o suelos en blanco), lo que da lugar a una estimación de la postura inestable. En estas situaciones, es un desafío para el algoritmo recopilar suficientes datos útiles para un posicionamiento preciso y un mapeo. Al agregar características invariantes de luz, integrar tecnología de aprendizaje profundo, aumentar la eficiencia computacional y mejorar la capacidad de procesamiento dinámico de objetos, la investigación futura puede aumentar con éxito el rendimiento de LSD-SLAM y hacerlo más resistente y adaptable en entornos complejos.

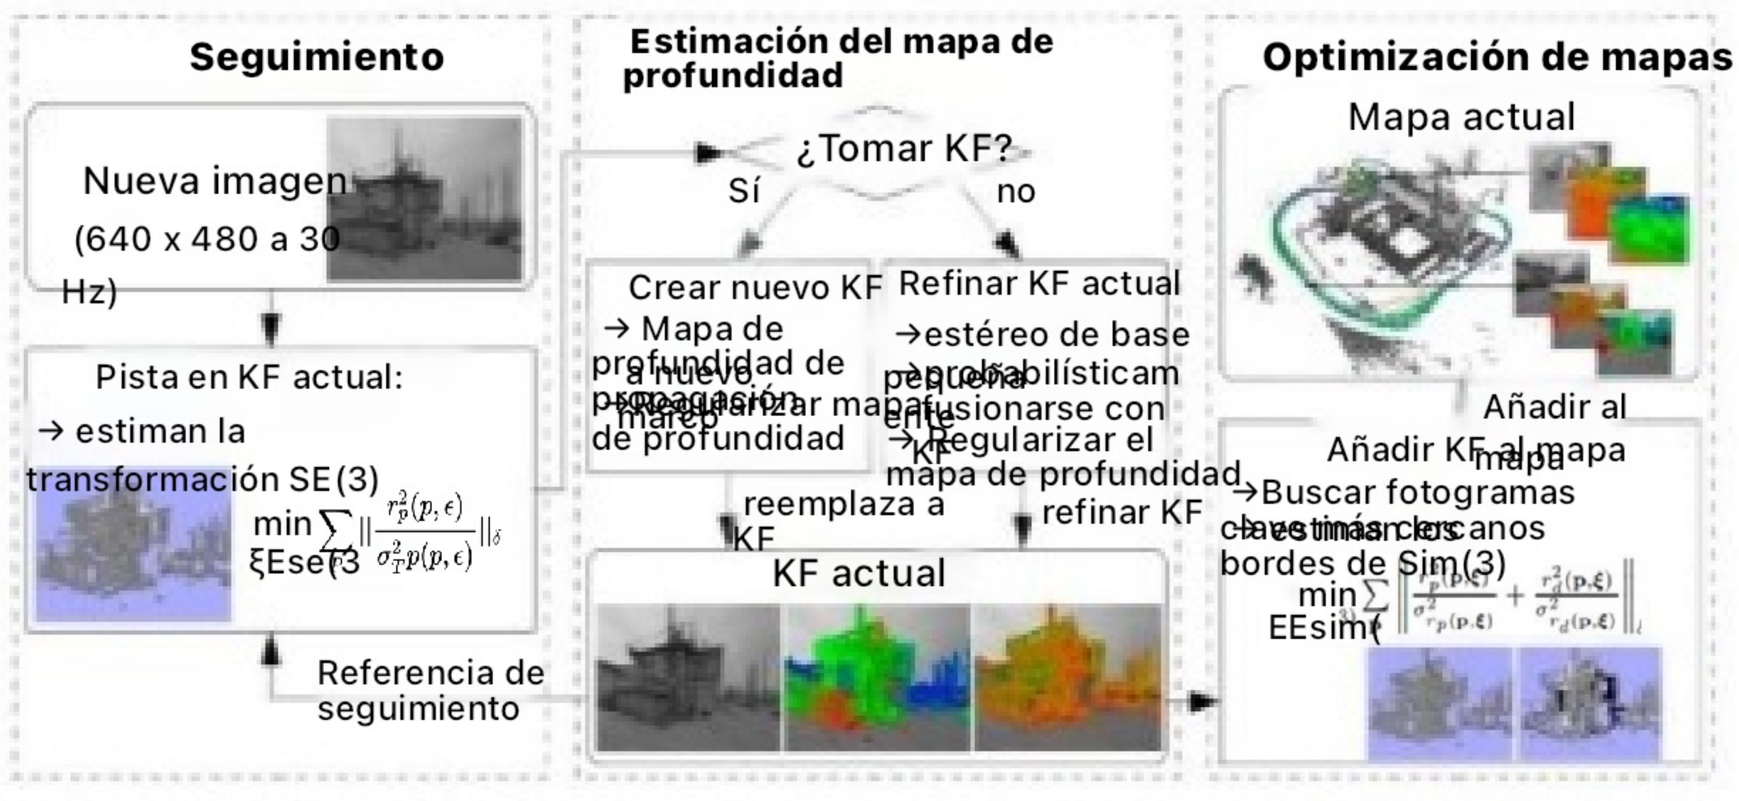

Figura 6. Todo el diagrama del sistema del algoritmo LSD-SLAM[38].

Por lo tanto, la capacidad de la técnica directa para gestionar la correlación entre varios tipos de datos de una manera más sistemática es su principal beneficio sobre el método convencional de fusión basado en características. Las aplicaciones con altos requisitos en tiempo real se benefician de la capacidad del método directo para ahorrar tiempo en la extracción y coincidencia de características mediante el uso de información de intensidad de píxeles directamente para la estimación de movimiento. Además, debido a que el método directo no se basa en la coincidencia de puntos de características, reduce la acumulación de errores causados por la pérdida o coincidencia incorrecta de puntos de características, lo que mejora la solidez del sistema y el rendimiento en tiempo real.

Estas técnicas trabajan juntas porque pueden mejorarse y complementarse entre sí para mejorar el rendimiento de SLAM:

(1) Además de ser complementarias, las técnicas de fusión de datos multimodales crean un marco amplio que puede ofrecer una plataforma integrada para muchos sensores. Esto incluye técnicas de ayuda semántica, directas y basadas en características, todas las cuales se pueden utilizar en SLAM multimodal para hacer uso de los beneficios de muchos sensores y mejorar el rendimiento del sistema;

(2) Los enfoques de fusión basados en características proporcionan una forma versátil de administrar puntos de características, proporcionando restricciones de posición adicionales a través de la coincidencia de características, que son útiles para fusionar con otros métodos para crear un SLAM más eficiente. Esta técnica ofrece un enfoque versátil para administrar puntos de entidad que forman parte del nivel de fusión de la capa de entidades. A través de la coincidencia de características, este grado de fusión puede ofrecer restricciones de pose adicionales,

mejorando así la precisión de posicionamiento del sistema SLAM y las capacidades de construcción de mapas en muchos contextos. Se puede utilizar con otras técnicas para producir un SLAM que sea más eficaz. La combinación de estas técnicas nos permite crear sistemas SLAM que son más robustos, adaptables y efectivos para una variedad de escenarios de aplicación y entornos con diversas necesidades. El algoritmo tiene más alternativas gracias a la fusión multimodal, lo que le ayuda a funcionar bien en una variedad de situaciones desafiantes. Al integrar estas metodologías, podemos crear sistemas SLAM más potentes, adaptables y eficientes para diversos tipos de entornos y escenarios de aplicación con diferentes necesidades. El algoritmo tiene más alternativas gracias a la fusión multimodal, lo que le ayuda a funcionar bien en una variedad de situaciones desafiantes;

(3) Al proporcionar información contextual de alto nivel, las técnicas SLAM asistidas por información semántica pueden ayudar al sistema a comprender la escena, especialmente en entornos complejos. También se pueden utilizar junto con técnicas directas y basadas en características para mejorar la precisión del posicionamiento y la estabilidad del sistema;

(4) Con el fin de crear un enfoque híbrido, la técnica directa combina características con información semántica. Al optimizar los datos originales utilizando estas técnicas sensatas y utilizando la información de profundidad del método directo para mejorar la coincidencia de características, aumenta la precisión y la resistencia del sistema SLAM en una variedad de entornos.

En conclusión, la tecnología SLAM, que combina visión y LiDAR, ha demostrado ser muy prometedora en el manejo de situaciones dinámicas y complejas. Estos experimentos ofrecen nuevos conceptos para las próximas aplicaciones en condiciones difíciles, además de demostrar que la combinación de LiDAR y visión es factible. El objetivo de la investigación sobre la integración de LiDAR y sensores de visión es mejorar la resistencia y versatilidad del sistema, que son cruciales en las aplicaciones modernas.

4. Principales logros de investigación y análisis de evaluación

La precisión, la resistencia, el rendimiento en tiempo real y la adaptabilidad de la tecnología SLAM de fusión láser y visual están siendo estudiadas por un número cada vez mayor de académicos a medida que avanza la investigación actual. Esto ayudará a avanzar en el uso de la tecnología en entornos complejos y aumentará significativamente su adaptabilidad. El aprendizaje profundo, por ejemplo, ha mejorado significativamente el rendimiento en una serie de áreas, incluida la estimación profunda, la comprensión semántica, la asociación de datos y la optimización. También ha hecho que la extracción y el emparejamiento de características sean más eficientes. Los resultados de la investigación también se pueden validar y evaluar en aplicaciones del mundo real, lo que avanza en la fusión multimodal y la investigación teórica al tiempo que mejora el rendimiento del láser y la fusión visual SLAM. At al mismo tiempo, ofrece nuevos enfoques a los problemas que enfrenta el láser y la fusión visual SLAM existente en entornos dinámicos.

4.1. Análisis de precisión y robustez

En primer lugar, la precisión se refiere al posicionamiento del sistema y a la precisión del mapeo, que es un componente crucial de la evaluación del sistema SLAM. Estudios recientes han demostrado que la combinación de varios sensores puede mejorar en gran medida la precisión de ubicación del sistema SLAM y la calidad de la reconstrucción del entorno [39]. Se analizaron y compararon los diversos sensores del sistema SLAM, y se descubrió que la calidad efectiva de la reconstrucción del entorno y la precisión de posicionamiento podían mantenerse en muchas situaciones, particularmente cuando se combinaban con sensores ópticos [40]. Al mismo tiempo, también se ha mejorado el algoritmo de trabajo de marcos del sistema SLAM. Además, la optimización puede aumentar en gran medida la precisión y la eficiencia del sistema. Por ejemplo, Zhou et al. (2020) presentaron una nueva técnica de extracción de áreas clave llamada ROI-cloud (nube de región de interés). Aumenta la robustez en contextos complicados, predice eficazmente la distribución

de áreas importantes, e introduce un enfoque de filtrado de partículas no paramétrico. Para aumentar la velocidad y la precisión del algoritmo de coincidencia, se eliminan las nubes de puntos redundantes y dinámicas [41]. Además, se introduce una estrategia de emparejamiento basada en valores de intensidad para incorporar la intensidad en la función de coste, lo que mejora en gran medida la precisión de la búsqueda correspondiente de puntos de borde y puntos de plano. [42]. Además, el análisis de escenas deformadas con la técnica DeSLAM (Deep SLAM) aumenta en gran medida la precisión. Al fusionar la forma de la plantilla y la tecnología de movimiento de la estructura no rígida, mejora la precisión al rastrear la pose de la cámara y la deformación del mapa de observación en tiempo real [43].

Además, Mostafa Ahmadi et al. (2023) realizaron un análisis exhaustivo de varios enfoques y propusieron un sistema basado en HDPV-SLAM (percepción profunda jerárquica para SLAM visual) que adopta un esquema de refinamiento adaptativo mejorado de dos etapas (PanoDARS) mediante la introducción de un módulo de estimación de profundidad y un módulo de correlación de profundidad. Esto mejora en gran medida el posicionamiento y la precisión de la construcción de mapas de los sistemas de cartografía móviles basados en cámaras oblicuas, multilínea, LIDAR y panorámicas [44]. Esta importante mejora del rendimiento demuestra no solo la eficacia del método de fusión, sino también su potencial para aplicaciones prácticas. Por lo tanto, el aumento de la precisión puede ayudar al sistema a realizar estimaciones de posición más precisas para sí mismo, lo que puede reducir eficazmente los errores de posicionamiento y la acumulación de errores, mejorando aún más la precisión y la coherencia del mapa para manejar situaciones cada vez más complicadas.

En segundo lugar, la robustez describe la consistencia con la que el sistema SLAM percibe su entorno a pesar de las interferencias o impedimentos. Maddern et al. (2011) introdujeron el sistema CAT-SLAM (SLAM de seguimiento autónomo colaborativo) para proporcionar la creación de mapas estables en varios entornos reales. Su filtrado local probabilístico mejora la robustez del sistema en entornos dinámicos al tiempo que mantiene la precisión [45]. Además, Zou et al. (2013) emplearon la técnica CoSLAM (SLAM cooperativo), que combina las trayectorias de los puntos de fondo estáticos con los puntos dinámicos de primer plano, para lograr eficazmente el SLAM visual en un entorno dinámico mediante la colaboración con muchas cámaras independientes. La resiliencia del sistema se incrementa a través de mapas de actitud y estimación [46]. Ballester et al. (2021) desarrollaron un sistema DOT que combina la segmentación de instancias con múltiples vistas como alternativa al uso de datos de muchas cámaras independientes para aumentar la fiabilidad del sistema. El seguimiento dinámico de objetos aprovecha la geometría y los atributos ORB [47]. Esta técnica puede aumentar en gran medida la precisión y la resistencia de SLAM en entornos dinámicos. Mientras la investigación de la tecnología de fusión continúa avanzando, los científicos también han hecho el descubrimiento inicial de la fusión actual de la cámara LiDAR. Al dividir las modalidades de LiDAR y de cámara en dos flujos separados, se aborda un inconveniente subestimado del método, a saber, su dependencia de la entrada LiDAR, lo que mejora en gran medida la robustez del sistema ante escenarios de falla de LiDAR. Pyojin Kim et al. (2023) desarrollaron una técnica SLAM lineal para manejar escenarios cada vez más complicados. Al agregar características de plano ortogonal al modelo global, el sistema logró de manera efectiva la predicción de la posición de la cámara en entornos dinámicos. Además de simplificar el problema de la optimización no lineal, este enfoque aumenta la robustez del sistema, lo que le permite funcionar bien en una variedad de configuraciones [48].

Como resultado, el aumento de la robustez del sistema SLAM no solo lo hace más adaptable en entornos complejos, sino que también maneja mejor los problemas de asociación de datos dentro del sistema, reduce los errores de coincidencia provocados por cambios ambientales o errores de sensores [49] y aumenta la adaptabilidad en entornos complejos.

4.2. Análisis en tiempo real y adaptabilidad

Una de las métricas clave para evaluar los sistemas SLAM es el rendimiento en tiempo real, especialmente en la configuración de aplicaciones donde es necesaria una reacción rápida. Con el fin de evaluar en tiempo real

rendimiento, Sturm et al. (2012) desarrollaron una prueba de referencia estandarizada para sistemas RGB-D SLAM desde el principio. Esta prueba proporcionó varias secuencias de datos reales con sincronización temporal [50]. Con el fin de actualizar el mapa y la información de posicionamiento, Ma et al. (2016) propusieron un sistema SLAM RGB-D en tiempo real que puede alinear y fusionar el fotograma actual (una imagen capturada en tiempo real) con fotogramas clave previamente almacenados (imágenes de referencia importantes). Además, el sistema puede alinear el marco actual con modelos de planos conocidos para mejorar la precisión del mapa y la comprensión del entorno circundante [51]. Al mismo tiempo, la capacidad de SLAM para adaptarse a entornos complicados también será crucial. Mediante la implementación de técnicas móviles de verificación de consistencia y segmentación semántica, el sistema DS-SLAM de Yu et al. (2018) mitigó eficazmente el efecto de los objetos dinámicos en la precisión de la ubicación [52]. A través de la cooperación de cinco hilos paralelos, el sistema gestionó con éxito el impacto de objetos dinámicos, logrando una predicción de trayectoria de alta precisión y exhibiendo una adaptabilidad significativa en entornos altamente dinámicos.

Fabian Blöchliger et al. (2018) propusieron un novedoso marco de mapa topográfico para reducir el tiempo de cálculo y mejorar la eficiencia de la planificación de rutas globales. Este marco convierte mapas SLAM visuales dispersos en mapas topológicos 3D, lo que reduce significativamente el tiempo de cálculo y mejora el rendimiento del sistema en tiempo real [53]. Esto hace que sea más fácil para los robots móviles navegar en entornos semiestructurados a gran escala. Tristan Laidlow et al. (2019) utilizaron el aprendizaje profundo para crear mapas de profundidad enriquecidos con el fin de garantizar la alta estabilidad del sistema SLAM en un entorno cambiante. Esto permitió la reconstrucción rápida de escenas intrincadas y mejoró aún más la resistencia y adaptabilidad del sistema [54]. Wasenmüller et al. (2023) propusieron un nuevo conjunto de datos de referencia RGB-D completo, CoRBS, para mejorar la robustez del sistema. Combina los puntos de referencia RGB-D SLAM con la profundidad real, los datos de color, las trayectorias de la cámara y la geometría de la escena. Esto permite una evaluación independiente de los componentes de posicionamiento y mapeo del sistema SLAM, lo que fomenta aún más la evaluación en tiempo real del sistema SLAM en entornos dinámicos [55].

Como resultado, la precisión, la adaptabilidad y la solidez de la investigación actual de SLAM se mejoran constantemente, y las nuevas técnicas también fomentan el crecimiento del campo hacia una mayor precisión y una mayor gama de escenarios de aplicación.

4.3. Evaluación del rendimiento de SLAM en entornos difíciles

4.3.1. Evaluación del rendimiento de SLAM en entornos dinámicos

Los investigadores han comenzado a estudiar las limitaciones de SLAM en entornos dinámicos como resultado de los avances en curso en la tecnología SLAM de lidar y fusión de visión [56]. Las suposiciones ambientales estáticas suelen ser la base de la tecnología SLAM tradicional. Al utilizar el conocimiento de objetos para el SLAM 3D, los primeros SLAM++ de Salas-Moreno et al. (2013) mejoraron en gran medida el rendimiento del sistema en situaciones complicadas. El sistema puede llevar a cabo con éxito la detección y el seguimiento de objetos en 3D en tiempo real mediante la introducción de la idea de un gráfico de objetos, lo que lleva a mejorar las capacidades de descripción y predicción en escenarios dinámicos [57]. Sin embargo, esta técnica debe ofrecer un modelo geométrico del objeto, crear una base de datos de objetos de antemano y solo detectar objetos que estén presentes en la base de datos. También requiere una estructura previa, que supone que la escena es estática y que todos los objetos están en el mismo plano (suelo). Ibragimov y Afanasyev (2017) examinaron la efectividad de varias técnicas visuales SLAM en entornos interiores uniformes, quienes descubrieron que la combinación de visión y lidar puede aumentar en gran medida la robustez en escenarios dinámicos [58]. Al mismo tiempo, al mezclar hábilmente los dos, la precisión de la ubicación del sistema en situaciones dinámicas también se puede aumentar en gran medida mediante el uso de datos de sensores, segmentación semántica y técnicas de verificación de consistencia de objetos dinámicos.

Además, la combinación de LiDAR y visión ofrece nuevos enfoques para los desafíos en entornos dinámicos. Para mejorar el rendimiento de los sistemas SLAM en situaciones dinámicas, los investigadores han comenzado recientemente a estudiar la integración del aprendizaje profundo y la información semántica. Por ejemplo, el sistema DynaSLAM, creado por Bescos et al. (2018), supera a las técnicas SLAM convencionales en términos de precisión mediante el uso de la detección dinámica de objetos y el relleno de fondo para mejorar la robustez de las escenas dinámicas y la función con configuraciones de cámara visual monocular, estéreo y RGB-D [59]. El sistema aún puede mantener la creación de mapas de alta precisión al tiempo que mejora la flexibilidad del sistema SLAM en situaciones complicadas mediante el uso de tecnología de aprendizaje profundo y geometría de vista múltiple para detectar objetos en movimiento. Los mapas producidos por el sistema ORB-SLAM original se muestran como se muestra en la Figura 7. El sistema ORB-SLAM puede crear un mapa preciso e ilustrar eficazmente los efectos perjudiciales de los elementos en movimiento en este entorno dinámico mediante el uso de la técnica sugerida por Sun et al. (2018) [60].

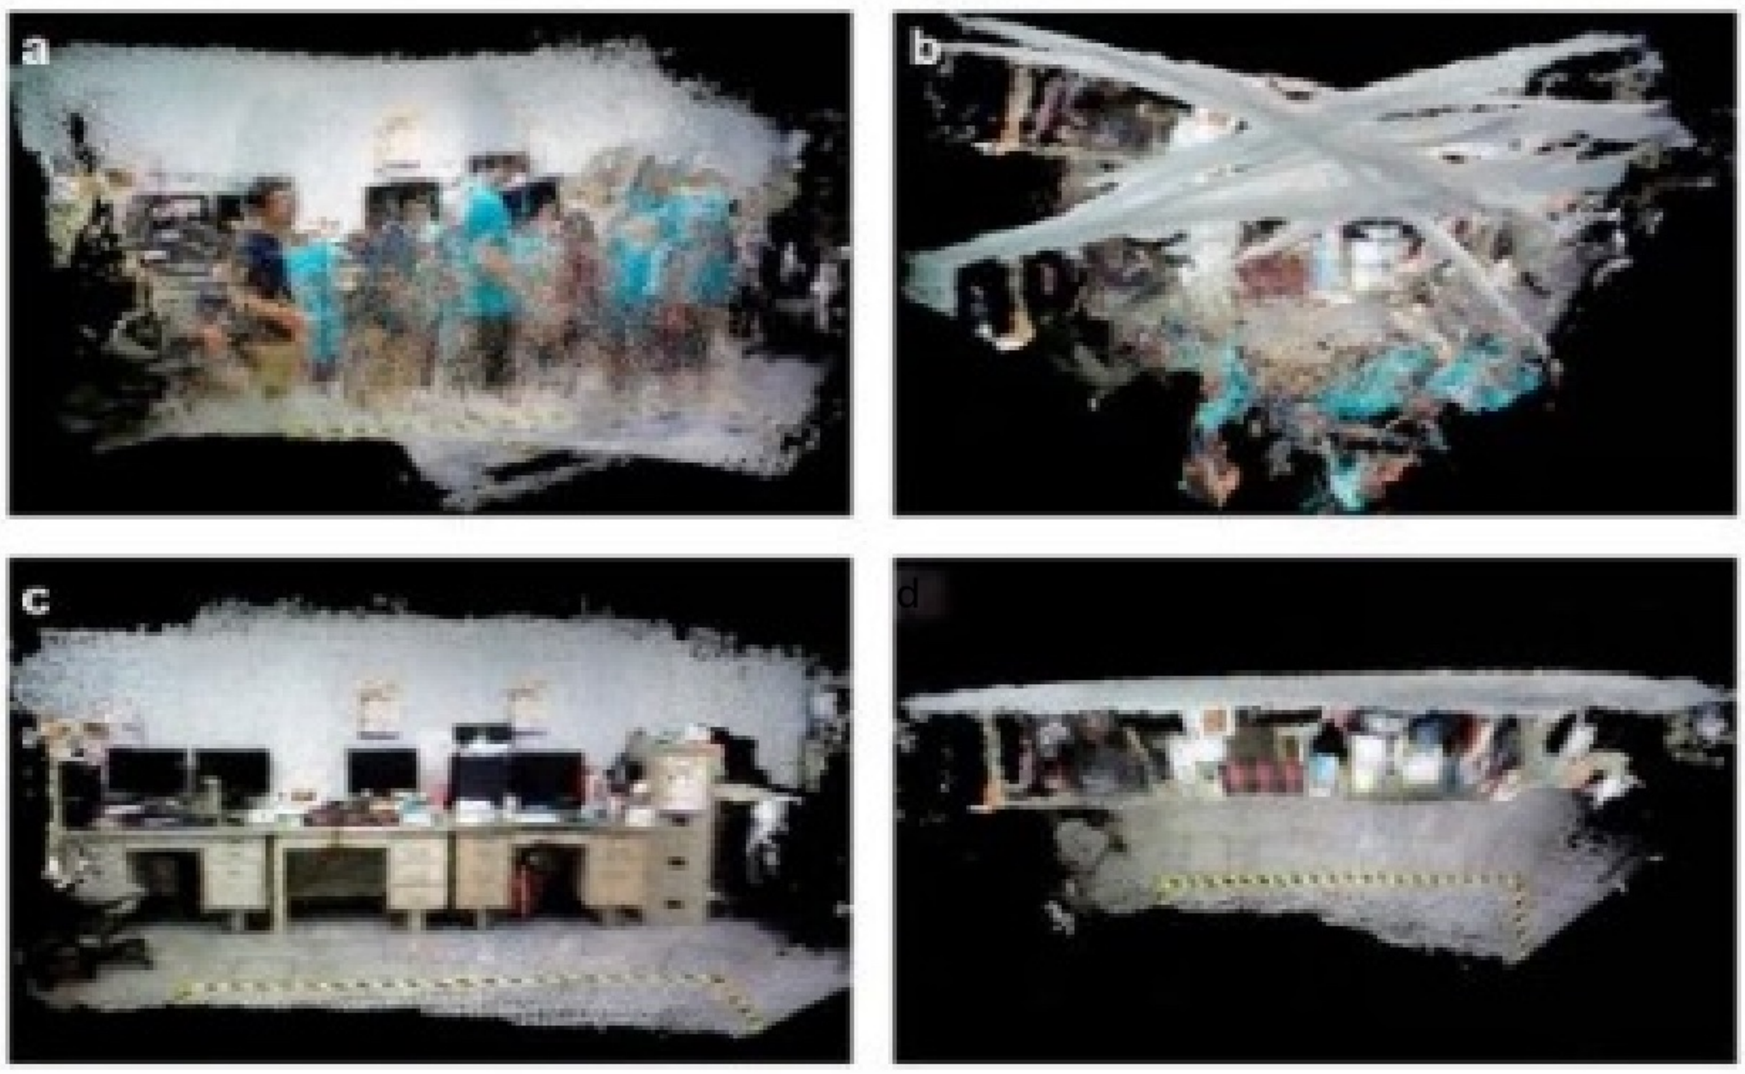

Figura 7. Los mapas producidos por el sistema ORB-SLAM original. a) Mapa generado por el sistema para la vista frontal de ORB-SLAM; b) Mapa generado por el sistema para la vista vertical ORB-SLAM; (c) ORB-SLAM con la vista frontal de aproximación de Sun et al.; (d) ORB-SLAM con la vista vertical de aproximación de Sun et al. [60].

Por ejemplo, en escenarios del mundo real, los automóviles que se mueven a gran velocidad pueden ser considerados como elementos de fondo en escenas callejeras urbanas por el ORB-SLAM original, lo que podría resultar en una estimación inexacta de la posición de la cámara. A través de la información de profundidad, el algoritmo mejorado puede determinar rápidamente las propiedades dinámicas de un automóvil, eliminándolo así de la coincidencia de características. Del mismo modo, en entornos interiores, el movimiento de una persona puede alterar el algoritmo inicial, lo que resulta en actualizaciones erróneas del mapa. Con el fin de preservar la estabilidad del entorno estático, el algoritmo mejorado puede reconocer la trayectoria de movimiento de esta persona y excluir la información pertinente durante la optimización de la postura.

Estos estudios demuestran que, para adaptarse a diversas circunstancias de aplicación, los sistemas SLAM para entornos dinámicos no solo deben tener en cuenta la eficacia del algoritmo, sino también lograr flexibilidad en el diseño del sistema. Al analizar flujos de imágenes RGB-D en tiempo real para crear modelos 3D implícitos específicos de la escena, la técnica iMAP utiliza eficazmente información dinámica para ilustrar el uso de perceptrones multicapa (MLP) en SLAM en tiempo real. Esta técnica de procesamiento de vanguardia demuestra la adaptabilidad y la promesa de los sistemas SLAM en entornos dinámicos.

En conclusión, el sistema LiDAR y SLAM de fusión de visión ha demostrado un buen rendimiento en situaciones dinámicas [61], particularmente el enfoque que combina LiDAR y SLAM de fusión de visión con reconstrucción semántica. No solo muestra cómo esta técnica puede aumentar en gran medida la precisión del posicionamiento en entornos complejos, sino que también elimina ampliamente la necesidad de integrar LiDAR y sensores de visión en entornos dinámicos.

4.3.2.Rendimiento de SLAM en situaciones con características limitadas

El rendimiento de LiDAR se ha visto muy afectado en situaciones dinámicas con pocas funciones. Por lo tanto, al incorporar el conocimiento del diseño de escenas, los investigadores han mejorado la estimación del estado y las capacidades de mapeo denso en entornos de baja textura, aumentando así la robustez en entornos de baja textura [62]. Deschaud (2018) mostró la promesa de LiDAR en situaciones dinámicas al demostrar un enfoque SLAM de baja deriva basado en el escaneo 3D que alcanzó una tasa de deriva del 0,40% (es decir, 16 m de deriva después de 4 km) sin cierre de bucle [63]. No obstante, para disminuir su dependencia de la suposición del mundo estático, estas técnicas deben tener en cuenta cómo cambian los datos LiDAR en situaciones dinámicas. Por ejemplo, mediante la combinación de información visual, Xu et al. (2018) presentaron una técnica SLAM basada en LiDAR que aumenta la precisión de la ubicación en situaciones de escasez de características [64]. Al combinar las características geométricas de puntos y líneas, Albert Pumarola et al. (2017) desarrollaron el método PL-SLAM, que puede realizar SLAM de manera eficiente en escenas de baja textura. Esto mejora la estimación del estado del sistema y las capacidades de mapeo denso en el mapeo[65].

En resumen, los avances en el radar láser y la tecnología SLAM de fusión visual han fomentado la modernización y el refinamiento de diferentes algoritmos de fusión en el estado actual de la tecnología SLAM multidominio. El desarrollo de SLAM multimodal, en particular la combinación de radar láser y tecnología SLAM visual, ha estimulado nuevas vías de investigación desde las primeras iteraciones de los algoritmos básicos de coincidencia de sensores. Si bien la tecnología SLAM actualmente es muy prometedora en entornos complejos, aún se requiere una investigación más exhaustiva para comprender completamente las limitaciones generales del sistema.

5. Limitaciones y tendencias en el desarrollo de la investigación actual

5.1. Las limitaciones de la investigación

Aunque ha habido ciertos avances en la tecnología SLAM que combinan LiDAR y visión, la tecnología existente aún enfrenta desafíos significativos en términos de adaptabilidad ambiental y asociación de datos, entre otros aspectos. Especialmente, todavía existen limitaciones significativas para lidiar con entornos complejos, consumir recursos informáticos y la adaptabilidad del entorno. La investigación futura debe centrarse en estos desafíos, y estas limitaciones también indican la dirección de la investigación futura.

(1) Manejo de entornos dinámicos

Si bien algunos estudios han propuesto soluciones para entornos dinámicos, como Dy-naSLAM II y DS-SLAM, la mayoría de los sistemas SLAM aún luchan por mantener una alta precisión y robustez en entornos altamente dinámicos, particularmente cuando se trata de escenas dinámicas a gran escala y objetos que se mueven rápidamente [66]. Incluso con avances importantes, algunas investigaciones señalan que la resiliencia de los sistemas SLAM en circunstancias ambientales particulares sigue siendo problemática. Al trabajar con entornos dinámicos, Tete Ji et al. (2021) observaron que es probable que los sistemas SLAM visuales actuales se vean limitados por los altos costos de procesamiento [67]. La efectividad de los enfoques existentes a menudo se ve influenciada por la interferencia de los objetos en movimiento en la percepción del entorno, lo que restringe su aplicación en entornos del mundo real y requiere un refinamiento adicional en escenas dinámicas a gran escala [68]. Detectar y separar eficazmente los objetos dinámicos de los fondos estáticos sigue siendo una dificultad apremiante en las aplicaciones del mundo real, a pesar de los intentos de varios investigadores de mejorar las capacidades de procesamiento de objetos dinámicos mediante la integración del aprendizaje profundo [69]. Los sistemas SLAM actuales son

todavía no es lo suficientemente robusto en situaciones dinámicas. Cuando se trata de objetos dinámicos desconocidos, la mayoría de los enfoques actuales sufren con frecuencia una reducción en la precisión del posicionamiento o una falla en la construcción del mapa.

(2) Dependencia de los sensores

Las características y limitaciones de los diferentes sensores afectarán el efecto de fusión. Cómo seleccionar el sensor adecuado en diferentes condiciones ambientales y optimizar su estrategia de fusión sigue siendo un desafío [70]. La mayoría de las investigaciones existentes se centran en el procesamiento de datos de un solo sensor, sin estrategias de fusión efectivas. Por ejemplo, Burgard et al. (2009) ya han comparado diferentes algoritmos SLAM y también han enfatizado la aplicación de estructuras de grafos, pero hay una falta de discusión en profundidad sobre la implementación específica de la fusión de datos de sensores [71].

La fusión y el procesamiento de datos multisensor son los principales desafíos en la aplicación de las tecnologías SLAM de fusión láser y visual. La dependencia de los datos en entornos complejos sigue siendo un problema importante, como demuestra LVI-SAM (lidar visual-inertial odometry via smoothing and mapping; T. Shan et al., 2021), que ha logrado una estrecha coincidencia entre LiDAR y la odometría visual-inercial, pero aún corre el riesgo de degradación del rendimiento en entornos con pocas características [72]. En cuanto a la dependencia de los datos, la mayoría de las técnicas SLAM se basan en datos de sensores de alta calidad y circunstancias ambientales favorables para funcionar bien. Sin embargo, en muchas circunstancias prácticas, la adquisición y el procesamiento de datos a menudo se enfrentan a problemas como el ruido, la oclusión y los cambios en la iluminación, lo que tendrá un impacto negativo en la estabilidad y confiabilidad del sistema SLAM [73].

(3) Complejidad del cálculo

A medida que aumenta la complejidad de los algoritmos, muchos sistemas SLAM de fusión se encuentran con un conflicto entre los recursos informáticos y la velocidad de procesamiento. La investigación actual se centra en cómo equilibrar ambos para obtener un rendimiento efectivo en tiempo real [74]. Las técnicas actuales de SLAM basadas en el aprendizaje profundo son bastante intensivas computacionalmente, lo que reduce significativamente su utilidad. Por ejemplo, el método iMAP (mapeo y posicionamiento incremental) de Edgar Sucar et al. de 2021 ha revolucionado la eficiencia, pero aún requiere un proceso de entrenamiento en tiempo real y una topología de red bastante compleja, lo que aumenta las demandas de procesamiento [75]. Sin embargo, en contextos complicados, la precisión de estos métodos también se verá afectada.

(4) Adaptabilidad al medio ambiente

La eficacia de los sistemas SLAM existentes se ve frecuentemente afectada por la interferencia de los objetos en movimiento en las características visuales, y no son muy flexibles en situaciones complicadas [76]. Los enfoques actuales suelen carecer de habilidades fiables de generación y ubicación de mapas [77]. Si bien el SLAM visual continúa experimentando dificultades en situaciones como el cambio de iluminación y la interferencia de objetos en movimiento, el SLAM basado en radar láser es limitado en algunos escenarios de aplicación debido a su costo y restricciones de equipo [78].

Además, el enfoque de fusión basado en características también tiene inconvenientes. La extracción y la coincidencia de puntos característicos son cruciales para este enfoque y, en situaciones complicadas, la extracción de puntos característicos puede resultar en un rendimiento reducido [79]. Según Yan et al. (2024), el VSLAM clásico utiliza principalmente características de escena, es decir, características de puntos, lo que podría conducir a fallos de mapeo en situaciones de textura escasa, ya que no hay suficiente información de características [80]. El rendimiento en tiempo real se verá afectado, especialmente cuando los recursos computacionales son escasos, por el proceso de extracción y coincidencia de puntos de características computacionalmente exigente.

Como resultado, en contextos complejos, la tecnología SLAM se enfrenta a dificultades con la adaptación del entorno sistémico. A pesar de que algunas investigaciones han intentado utilizar el aprendizaje profundo

y la segmentación semántica para mejorar el seguimiento y la detección de objetos dinámicos, sigue siendo crucial descubrir cómo incorporar con éxito la información semántica con los marcos SLAM convencionales [81].

5.2. Tendencias de la investigación

Han surgido nuevas oportunidades para mejorar el rendimiento del sistema debido al desarrollo continuo de tecnologías como la fusión de datos multimodal, el aprendizaje profundo y la integración de información semántica. Esto ha dado lugar a la aparición continua de nuevas tendencias y desafíos, particularmente en lo que respecta a la innovación tecnológica y la expansión de aplicaciones. La fusión de sensores multimodales, la optimización de algoritmos, la mejora del rendimiento en tiempo real y la expansión del escenario de aplicación son las cuatro áreas principales de las tendencias de investigación.

(1) Fusión de muchos sensores

Al combinar LiDAR con sensores ópticos, los investigadores han aumentado en gran medida la precisión de la ubicación. También han integrado comprobaciones de consistencia de movimiento y segmentación semántica en entornos dinámicos, lo que demuestra la utilidad de la tecnología de fusión en situaciones dinámicas. Con el fin de beneficiarse plenamente de ambos sensores, el rendimiento del sistema en entornos complicados se mejora mediante el uso de información de profundidad para aumentar la conciencia ambiental y las capacidades de construcción de mapas. Este enfoque de fusión aumenta en gran medida la capacidad de gestionar impedimentos dinámicos y, al mismo tiempo, aumenta la precisión en contextos complejos.

Con el fin de superar las limitaciones de los sensores tradicionales en situaciones particulares, los investigadores pueden investigar diferentes tipos de combinaciones de sensores en el futuro y fortalecer la fusión de nuevos sensores. Esto proporcionará a los sistemas SLAM más información de percepción, lo que mejorará el rendimiento general [82]. Por ejemplo, el sistema de percepción del entorno sugerido basado en LiDAR y visión ofrece una investigación preliminar de la fusión de múltiples sensores mediante el uso combinado de sensores LiDAR e infrarrojos, así como sensores de sonido [83], como se muestra en la Figura 8. Una investigación más profunda de las técnicas de fusión de datos de varios sensores puede conducir a una mejor precisión de posicionamiento y resistencia, así como a una comprensión más profunda del entorno [84].

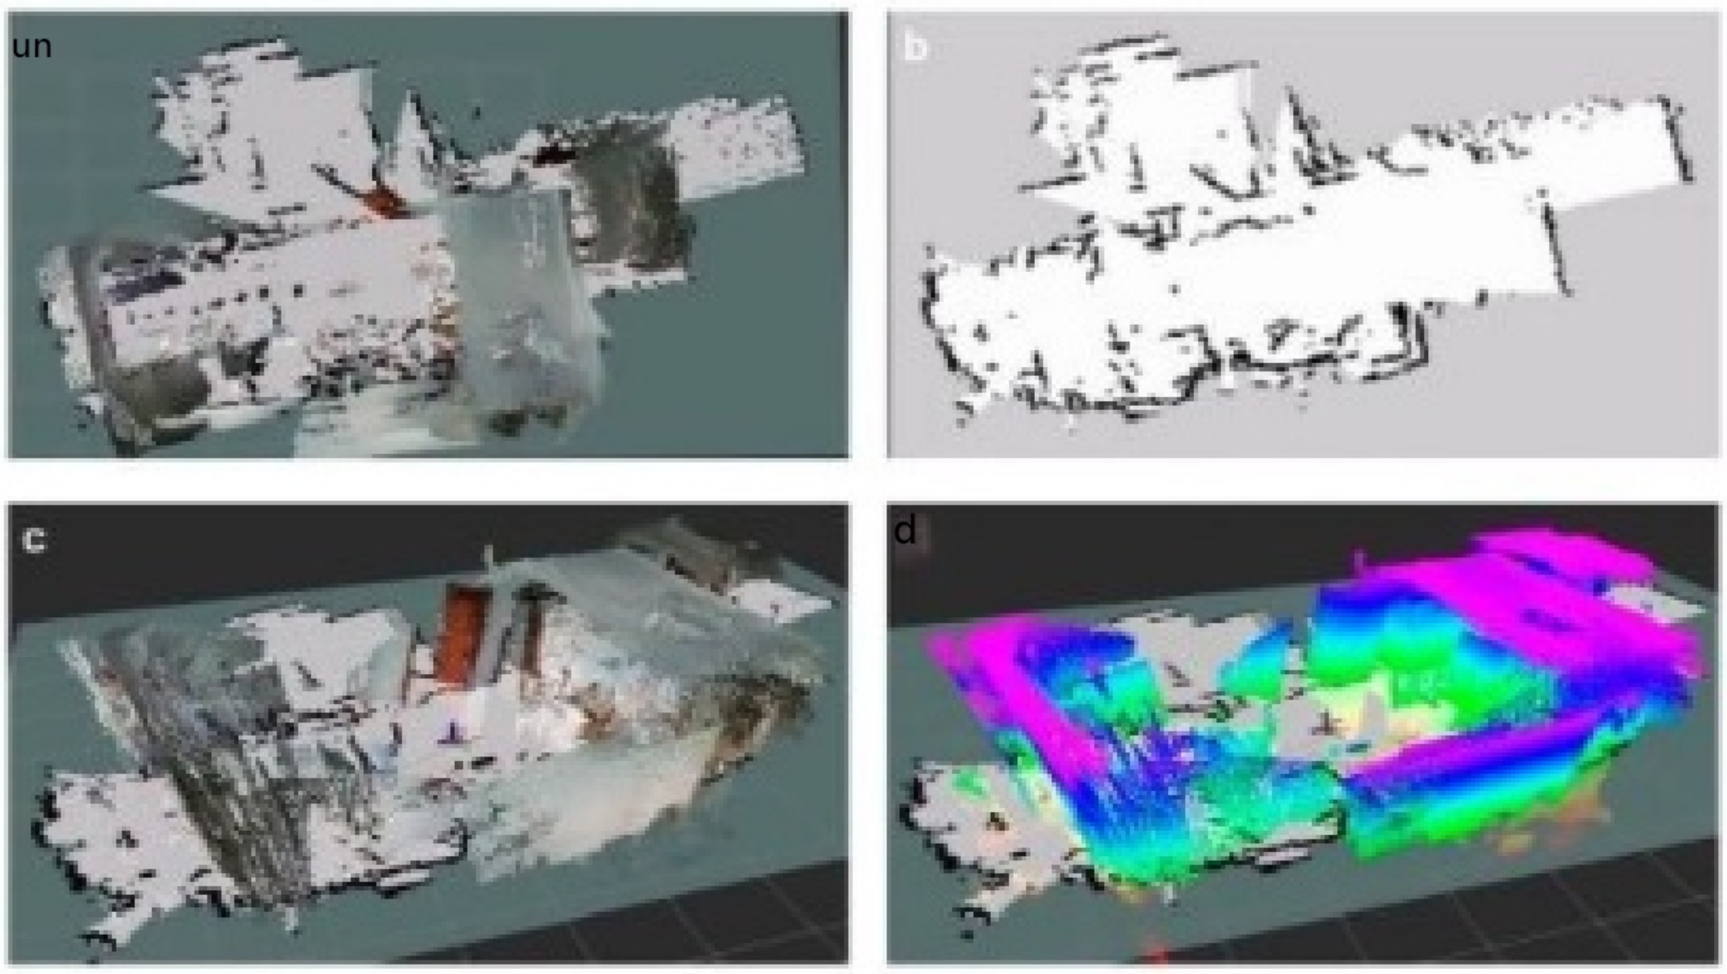

Figura 8. El sistema de percepción del entorno sugerido basado en LiDAR y visión. a) El mapa en perspectiva superior; b) Un mapa cuadriculado bidimensional de navegación; c) Vista lateral del mapa; (d)Mapa tridimensional de nubes de puntos; Ilustración de la tecnología SLAM mediante fusión multisensor.

Los siguientes son algunos de los beneficios del esquema de fusión. Los algoritmos de fusión se pueden utilizar para aumentar la precisión de la topografía cuando se realiza un seguimiento regular de la información láser y visual. La colocación de SLAM láser puede producir resultados continuos cuando el seguimiento visual no tiene éxito. Además, un láser bidimensional puede compensar el estrecho rango de visión de la cámara de profundidad, mejorando la seguridad de la navegación del sistema [83].

(2) Optimización de algoritmos

A medida que la tecnología de aprendizaje profundo avanza rápidamente, cada vez más algoritmos de sistemas SLAM incorporan modelos de aprendizaje profundo para mejorar el procesamiento de datos y la extracción de características [85], lo que aumenta la precisión de la creación y ubicación de mapas [86]. Por ejemplo, el uso de redes neuronales aumenta en gran medida la adaptabilidad ambiental de los sistemas SLAM al tiempo que mejora su rendimiento en circunstancias difíciles. Uno de ellos, el SLAM neuronal activo, fue propuesto por Devendra Singh Chaplot et al. (2020) e integra módulos de aprendizaje con la planificación tradicional de rutas [87]. El campo de SLAM se está moviendo hacia algoritmos más eficientes y sistemas modulares, como resultado de Chen et al. (2021), utilizando redes neuronales profundas para la detección de bucles en su OverlapNet [88] y DROID-SLAM (Z. Teed et al. 2021) utilizando un método iterativo recursivo para actualizar la posición de la cámara y la información de píxeles y profundidad [89]. Esto conduce a una comprensión más precisa [90] del entorno y a la generación de mapas [91] al aumentar la adaptabilidad del sistema a las modalidades de entrada y fortalecer la resiliencia de la estimación del estado del sistema.

La optimización de los algoritmos SLAM actuales puede ser el foco principal de futuros estudios. Por ejemplo, las técnicas actuales de LiDAR y SLAM visual utilizan principalmente un enfoque de acoplamiento flexible y no han aprovechado plenamente los beneficios de ambos. Con el fin de aumentar la precisión y la fiabilidad de las estimaciones de estado, los estudios futuros deben concentrarse en cómo obtener una fusión de sensores más cercana. Con el fin de aumentar la precisión y acelerar el cálculo, las redes neuronales también se combinan con algoritmos SLAM convencionales [92]. Además, la siguiente fase del estudio podría concentrarse en el desarrollo de algoritmos más eficaces que mejoren aún más el rendimiento en entornos complejos y logren un mejor equilibrio entre la precisión y el rendimiento en tiempo real [93] y, al mismo tiempo, mejoren la inteligencia y el aprendizaje mediante la integración de la tecnología de aprendizaje por refuerzo y la investigación de sistemas SLAM adaptativos que puedan modificar dinámicamente los parámetros del algoritmo en respuesta a los cambios en el entorno. aumentando la estabilidad y adaptabilidad del sistema [94].

(3) Mejora del rendimiento en tiempo real

Las tendencias actuales de investigación de SLAM apuntan a mejorar las capacidades de procesamiento en tiempo real para adaptarse a entornos cambiantes, además de aumentar la precisión y la robustez del algoritmo [95]. Por lo tanto, para aplicaciones en tiempo real en situaciones dinámicas, el ajuste efectivo del haz de datos (ajuste del haz) en los algoritmos SLAM es muy crucial [96]. Los investigadores se dedican a mejorar la eficiencia computacional de los algoritmos SLAM con el fin de satisfacer las demandas de las aplicaciones en tiempo real. Mediante el uso de técnicas de representación explícita del volumen, el marco SplaTAM creado por Nikhil Keetha et al. (2024) mejora el rendimiento en tiempo real del sistema SLAM al lograr una reconstrucción de alta fidelidad a partir de una sola cámara RGB-D no calibrada [97]. Para mejorar el rendimiento general del sistema, los estudios futuros pueden investigar cómo incluir algoritmos dinámicos de detección y seguimiento de objetos en SLAM en tiempo real. Para disminuir su impacto en la creación del mapa ambiental, será necesario identificar y modelar elementos dinámicos.

(4) Ampliación de los escenarios de aplicación

A medida que la tecnología se desarrolla, la gama de aplicaciones para el radar láser y la fusión visual SLAM sigue creciendo, desde entornos interiores convencionales hasta intrincados escenarios dinámicos al aire libre e incluso dominios de vanguardia como la conducción autónoma y aumentada

realidad. Los estudios futuros pueden concentrarse en la aplicación de la tecnología SLAMM a situaciones del mundo real, particularmente aquellas con mucho dinamismo y ambigüedad. Mejora la resiliencia y la interpretabilidad del sistema, al tiempo que refuerza la comprensión y la confianza de los usuarios en el proceso de toma de decisiones del sistema SLAM. Además, para que los sistemas SLAM manejen una variedad de escenarios de aplicación del mundo real, deben poseer una mayor adaptabilidad ambiental y capacidades de autoaprendizaje [98]. Para mantener capacidades efectivas de navegación y posicionamiento, por ejemplo, los sistemas SLAM deben ser capaces de adaptarse a los cambios ambientales en tiempo real en entornos dinámicos como la agricultura [99]. Además, en entornos dinámicos, los sistemas SLAM deben ser capaces de gestionar el impacto de los objetos dinámicos para mejorar el rendimiento del sistema.

6. Conclusiones

Para la fusión visual con LIDAR, al integrar los beneficios de los sensores multimodales, la tecnología SLAM compensa de manera eficiente las deficiencias de un solo sensor en entornos complejos y se ha convertido en una herramienta crucial para mejorar las capacidades autónomas de posicionamiento y mapeo. Después de incorporar el marco de algoritmos de inteligencia artificial, el sistema SLAM de fusión ha mejorado la precisión y la solidez en una variedad de escenarios desafiantes al combinar los beneficios de ambos. En consecuencia, la técnica SLAM, que combina datos visuales y LIDAR, ha crecido constantemente en popularidad como área de investigación.

A pesar de mostrar una tendencia de desarrollo prometedora, la tecnología SLAM que combina visión y LiDAR todavía tiene ciertos inconvenientes. En primer lugar, los algoritmos existentes están incorporando mayores problemas de precisión y tiempo real debido a la complejidad de los casos de aplicación. En consecuencia, debemos optimizar los algoritmos del marco en la próxima fase de investigación para minimizar el uso de recursos computacionales y, en la mayor medida posible, mejorar la adaptabilidad del sistema en tiempo real y del entorno; En segundo lugar, debemos investigar formas de proponer métodos de fusión más eficientes sin comprometer el rendimiento mientras optimizamos los algoritmos para ahorrar recursos informáticos. La investigación debe centrarse en la realización de una fusión de datos multimodal de baja latencia y alta eficiencia, que reducirá eficazmente el consumo de energía y la carga computacional del sistema SLAM, al tiempo que mejorará la precisión y el tiempo real del sistema. A nivel de los algoritmos de fusión de datos, se puede implementar una fusión de datos efectiva mediante la adopción de marcos de estimación de estado avanzados, como el filtrado de información y el filtrado de partículas, para manejar de manera eficiente la heterogeneidad de los datos láser y visuales. En segundo lugar, el uso de la tecnología de aprendizaje profundo para la extracción de características y el aprendizaje multimodal también puede mejorar en gran medida la solidez de la coincidencia de características. Al mismo tiempo, los algoritmos de optimización dispersos y las estrategias de actualización de mapas incrementales están diseñados para reducir la complejidad computacional y la latencia. Finalmente, en investigaciones posteriores, lograremos un procesamiento de datos multimodal de baja latencia y alta eficiencia mediante el establecimiento de un marco unificado de estimación de estado y una estrategia de fusión adaptativa, asegurando así el rendimiento del sistema y mejorando significativamente la precisión del posicionamiento en tiempo real del sistema. Se cree que este método proporcionará una base sólida para aplicaciones SLAM en entornos más complejos y dinámicos. Por último, el alto costo de LiDAR evita que se use ampliamente en escenarios de aplicaciones de bajo costo, lo que también alentará a los académicos a buscar opciones de hardware menos costosas o crear algoritmos efectivos que funcionen con hardware de bajo costo.

En resumen, la técnica SLAM que combina visión y LiDAR ofrece un gran potencial para usos en el mundo real. La fusión de múltiples sensores, una mayor adaptación a los entornos cambiantes y el uso generalizado de tecnologías de aprendizaje profundo deberían ser las principales áreas de desarrollo futuro para aumentar la resistencia y la adaptabilidad del sistema SLAM. Además de fomentar el desarrollo y la expansión continuos de la tecnología, esto dará lugar a soluciones más creativas para dominios como la conducción autónoma y la navegación robótica.

Contribuciones de los autores: conceptualización, P.C., X.Z. y L.L. (Lin Li); metodología, L.Z. y Z.L.; Curación de datos, L.L. (Luxinyu Liu) y S.L.; redacción de borrador original, P.C., X.Z., L.Z., G.L. y Z.L.; redacción-revisión y edición, L.L. (Lianhe Li) y L.Z.; visualización, G.L., L.S., H.C. e Y.Q.; supervisión, L.L. (Lianhe Li), Z.Q., D.X. e Y.Q.; adquisición de fondos, L.Z., Y.Q. y L.L. (Lin Li). Todos los autores han leído y están de acuerdo con la versión publicada del manuscrito.

Financiación: Esta investigación fue financiada por el Proyecto de Ciencia y Tecnología Financiera de la provincia de Hainan, subvención número GHYF2025030 y ZDYF2025GXJS007, la Fundación Provincial de Ciencias Naturales de Hainan de China, subvención número 123MS035, Fundación Nacional de Ciencias Naturales de China, subvención números 62174046, 12164016, 62274048 y 62464006, y el Fondo Abierto para el Programa de Capacitación en Innovación de Estudiantes Universitarios de la Universidad Normal de Hainan (202411658025,202411658027,202311658002X, S202411658031).

Declaración de la Junta de Revisión Institucional: No aplicable.

Declaración de Consentimiento Informado: No aplicable.

Declaración de disponibilidad de datos: Los datos están contenidos en el artículo.

Conflictos de intereses: Los autores declaran no tener conflictos de intereses.

Referencias

1. Merzliakov, A.; Macenski,S. Una comparación de los enfoques modernos de SLAM visual de propósito general. En Actas de la Conferencia Internacional sobre Robots y Sistemas Inteligentes (IROS) 2021IEEE/RSJ, Praga, República Checa, 27 de septiembre-1 de octubre de 2021; págs.9190-9197. [Referencia cruzada]

2.Lu,Y.; Song,D.Navegación visual utilizando puntos de referencia heterogéneos y restricciones geométricas no supervisadas.IEEE Trans.Robot.2015,31,736-749. [Referencia cruzada]

3. Yang, S.; Scherer, S.CubeSLAM: Objeto monocular 3-D SLAM. IEEE Trans. Robótica 2019,35,925-938. [Referencia cruzada]

4. Qiu, Y.; Wang, C.; Wang, W.; Henein, M.; Scherer, S.AirDOS: El SLAM dinámico se beneficia de los objetos articulados. En Actas de la Conferencia Internacional sobre Robótica y Automatización (ICRA) de 2022, Filadelfia, PA, EE. UU., 23-27 de mayo de 2022; págs. 8047-8053. [Referencia cruzada]

5. Shin,Y.-S.; Parque, Y.S.; Kim, A. Direct Visual SLAM utilizando profundidad dispersa para el sistema Camera-LiDAR. En Actas de la Conferencia Internacional sobre Robótica y Automatización (ICRA) del IEEE 2018, Brisbane, QLD, Australia, 21-25 de mayo de 2018; págs. 5144-5151. [Referencia cruzada]

6. Droeschel, D.; Schwarz, M.; Behnke, S. Mapeo y localización continuos para la navegación autónoma en terrenos accidentados mediante un escáner láser 3D. Robot. Auton. Sistema 2017, 88, 104-115. [Referencia cruzada]

7. Davison, A.J.; Reid, I.D.; Molton, Dakota del Norte; Stasse, O.MonoSLAM: SLAM de una sola cámara en tiempo real. IEEE Trans.Pattern Anal.Mach.Intell. 2007,29, 1052-1067. [Referencia cruzada]

8. Cattaneo, D.; Vaghi, M.; Valada, A. LCDNet: Detección de cierre de bucle profundo y registro de nubes de puntos para LiDAR SLAM. Robot IEEE Trans. 2022, 38, 2074-2093. [Referencia cruzada]

9. Endres, E; Hess, J.; Engelhard, N.; Sturm, J.; Cremers, D.; Burgard, W. Una evaluación del sistema RGB-D SLAM. En Actas de la Conferencia Internacional IEEE 2012 sobre Robótica y Automatización, Saint Paul, MN, EE.UU., 14-18 de mayo de 2012; págs. 1691-1696. [Referencia cruzada]

10. Shin, Y.S.; Parque, Y.S.; Kim, A. DVL-SLAM: SLAM visual directo mejorado con profundidad dispersa. Auton. Robot 2020,44,115-130. [Referencia cruzada]

11.Wang, J.; Rünz, M.; Agapito, L. DSP-SLAM: SLAM orientado a objetos con priores de forma profunda. En Actas de la Conferencia Internacional sobre Visión 3D 2021 (3DV), Londres, Reino Unido, 7-10 de junio de 2021; págs. 1362-1371. [Referencia cruzada]

12. Debeunne, C.; Vivet, D. Una revisión de la localización y el mapeo simultáneos basados en Visual-LiDAR Fusion. Sensores 2020, 20, 2068. [Referencia cruzada][PubMed]

13. Jiang, G.; Yin, L.; Jin, S.; Tian1, C.; Ma, X.; Ou, Y. Un marco de trabajo de localización y mapeo simultáneo (SLAM) para la construcción de mapas 2.5D basado en LiDAR de bajo costo y Vision Fusion. Appl. Sci. 2019, 9,2105. [Referencia cruzada]

14.Covolan, J.P.M.; Sementille, A.C.; Sanches, S.R.R. Un mapeo de algoritmos SLAM visuales y sus aplicaciones en realidad aumentada. En Actas del 22º Simposio sobre Realidad Virtual y Aumentada (SVR) 2020, Porto de Galinhas, Brasil, 10-13 de noviembre de 2020; págs. 20-29. [Referencia cruzada]

15. Arshad, S.; Kim, G.-W. Papel del aprendizaje profundo en la detección de cierre de bucles para SLAM visual y Lidar: una encuesta. Sensores 2021,21,1243. [Referencia cruzada][PubMed]

16. Chen, W.; Shang, G.; Ji, A.; Zhou, C.; Wang, X.; Xu,C.; Li, Z.; Hu, K. Una visión general sobre el SLAM visual: de la tradición a la semántica.Remote Sens. 2022, 14,3010. [Referencia cruzada]

17. Whelan, T.; Salas-Moreno, R.F.; Glocker, B.; Davison, A.J.; Leutenegger,S.ElasticFusion: Estimación de fuentes de luz y SLAM densas en tiempo real. Int. J. Robot. Res. 2016,35, 1697-1716. [Referencia cruzada]

18. Zhang, T.; Zhang, H.; Li, Y.; Nakamura, Y.; Zhang, L. FlowFusion: Slam RGB-D denso dinámico basado en flujo óptico. En Actas de la Conferencia Internacional IEEE 2020 sobre Robótica y Automatización (ICRA), París, Francia, 31 de mayo-4 de junio de 2020; págs. 7322-7328. [Referencia cruzada]

19. Urbano, S.; Hinz,S.MultiCol-SLAM-Un sistema modular SLAM multicámara en tiempo real. arXiv 2016, arXiv:1610.07336. [Referencia cruzada]

20. Kolar, P.; Benavidez, P.; Jamshidi, M. Estudio de técnicas de fusión de datos para la integración de sensores basados en láser y visión para la navegación autónoma. Sensores 2020, 20,2180. [Referencia cruzada][PubMed]

21. Zheng, C.; Zhu, Q.; Xu,W.; Liu, X.; Guo,Q.; Zhang,F.FAST-LIVO:LiDAR-inercial-visual rápido y estrechamente acoplado Odometry.In Actas de la Conferencia Internacional IEEE/RSJ 2022 sobre Robots y Sistemas Inteligentes (IROS), Kioto, Japón, 23-octubre de 2022;pp. 4003-4009. [Referencia cruzada]

22. Cao, K.; Liu, R.; Wang, Z.; Peng, K.; Zhang, J.; Zheng, J.; Teng, Z.; Yang, K.; Stiefelhagen, R. SLAM LiDAR-visual estrechamente acoplado basado en características geométricas para dispositivos móviles Agents.In Actas de la Conferencia Internacional IEEE 2023 sobre Robótica y Biomimética (ROBIO), Koh Samui, Tailandia, 10-13 de diciembre de 2023; págs. 1-8. [Referencia cruzada]

23. Liang, T.; Xie, H.; Yu, K.; Xia, Z.; Lin, Z.; Wang, Y.; Wang, B.; Tang, Z. BEVFusion: A simple and robust LiDAR-Camera Fusion Framework.arXiv 2019,arXiv:2205.13790. [Referencia cruzada]

24. Johari, M.M.; Carta,C.; Fleuret,F.ESLAM:Sistema SLAM denso eficiente basado en la representación híbrida de campos de distancia con signo. En Actas de la Conferencia IEEE/CVF 2023 sobre Visión por Computador y Reconocimiento de Patrones (CVPR), Vancouver, BC, Canadá, 18-22 de junio de 2023; págs. 17408-17419. [Referencia cruzada]

25. Li, D.; Shi, X.; Largo, Q.; Liu, S.; Yang, W.; Wang, E.; Wei, Q.; Qiao, F. DXSLAM: Un sistema SLAM visual robusto y eficiente con Features.In profunda Actas de la Conferencia Internacional IEEE/RSJ 2020 sobre Robots y Sistemas Inteligentes (IROS), Las Vegas, NV, EE. UU., 24-27 de octubre de 2020; pp. 4958-4965. [Referencia cruzada]

26. Li,R.; Wang, S.; Gu, D.Evolución continua de Visual SLAM de la geometría al aprendizaje profundo: desafíos y oportunidades. Cómputo. 2018,10,875-889.[CrossRef]

27. Civera, J.; Davison, A.J.; Montiel, J.M.M. Parametrización de profundidad inversa para SLAM monocular. Robot IEEE Trans. 2008,24,932-945.[CrossRef]

28. Yuan, X.; Chen,S.SaD-SLAM: UN SLAM VISUAL basado en información semántica y de profundidad. En Actas de la Conferencia Internacional IEEE/RSJ 2020 sobre Robots y Sistemas Inteligentes (IROS), Las Vegas, NV, EE. UU., 24-27 de octubre de 2020; págs. 4930-4935. [Referencia cruzada]

29.Li, Y.; Yu, A.W.; Meng, T.; Caín, B.; Ngiam, J.; Peng, D.; Shen, J.; Lu, Y.; Zhou, D.; Le, Q.V.; et al. DeepFusion: Lidar-Camera Deep Fusion for Multi-Modal 3D Object Detection.In Actas de la Conferencia IEEE/CVF 2022 sobre Visión por Computadora y Reconocimiento de Patrones (CVPR), Nueva Orleans, LA, EE. UU., 19-24 de junio de 2022;pp. 17161-17170. [Referencia cruzada]

30. Zhang, Y.; Kang,J.; Sohn, G.PVL-Cartógrafo: SLAM basado en cartógrafo LiDAR asistido por visión panorámica para el sistema de mapeo móvil Maverick. Sensores remotos 2023,15,3383. [Referencia cruzada]

31. Campos, C.; Elvira, R.; Rodríguez, J.J.G.; Montiel, J.M.M.; Tardós, J.D. ORB-SLAM3: Una biblioteca de código abierto precisa para SLAM visual, visual-inercial y multimapa. Robot IEEE Trans. 2021, 37,1874-1890. [Referencia cruzada]

32. Liu, Y.; Miura,J.RDS-SLAM:SLAM dinámico en tiempo real utilizando métodos de segmentación semántica.IEEE Access 2021,9,23772-23785. [Referencia cruzada]

33.Lou,L.; Li,Y.; Zhang, Q.; Wei,H.SLAM y reconstrucción semántica 3D basada en la fusión de Lidar y visión monocular.Sensores 2023,23,1502. [Referencia cruzada][PubMed]

34.Parque, S.; Schöps, T.; Pollefeys, M. Robustez del cambio de iluminación en SLAM visual directo. En Actas de la Conferencia Internacional IEEE 2017 sobre Robótica y Automatización (ICRA), Singapur, 29 de mayo-3 de junio de 2017; págs. 4523-4530. [Referencia cruzada]

35. Engel, J.; Koltun, V.; Cremers, D. Odometría dispersa directa. IEEE Trans. Patrón Anal. Mach. Intell. 2018,40,611-625. [Referencia cruzada]

36.Usenko, V.; Engel, J.; Stückler, J.; Cremers,D.Odometría Visual-Inercial Directa con Cámaras Estereoscópicas. En Actas de la Conferencia Internacional IEEE 2016 sobre Robótica y Automatización (ICRA), Estocolmo, Suecia, 16-21 de mayo de 2016; pp. 1885-1892. [Referencia cruzada]

37. Bescos, B.; Fácil,J.M.; Civera, J.; Neira,J.DynaSLAM:Seguimiento, mapeo y pintado en escenas dinámicas. Robot IEEE. 2018,3,4076-4083. [Referencia cruzada]

38. Engel, J.; Schöps, T.; Cremers, D. LSD-SLAM: Monocular directo a gran escala SLAM.In Computer Vision-ECCV 2014; Fleet,D.,Pajdla,T.,Schiele,B., Tuytelaars, T., Eds.; Apuntes de Cátedra de Ciencias de la Computación; Springer: Cham, Suiza, 2014; Tomo 8690, pp.834-849. [Referencia cruzada]

39. Tan, W.; Liu, H.; Dong, Z.; Zhang, G.; Bao, H. SLAM monocular robusto en entornos dinámicos. En Actas del Simposio Internacional IEEE 2013 sobre Realidad Mixta y Aumentada (ISMAR), Adelaida, SA, Australia, 1-4 de octubre de 2013; págs.209-218. [Referencia cruzada]

40. Palazzolo, E.; Behley, J.; Lottes, P.; Giguère, P.; Stachniss, C. ReFusion: Reconstrucción 3D en entornos dinámicos para cámaras RGB-D que explotan Residuals.In Actas de la Conferencia Internacional IEEE / RSJ 2019 sobre Robots y Sistemas Inteligentes (IROS), Macao, China, 4-8 de noviembre de 2019; págs. 7855-7862. [Referencia cruzada]

41. Zhou, Z.; Yang,M.; Wang, C.; Wang,B.ROI-Cloud: Un método de extracción de regiones clave para la odometría y localización de LiDAR. En Actas de la Conferencia Internacional IEEE 2020 sobre Robótica y Automatización (ICRA), París, Francia, 31 de mayo-4 de junio de 2020; págs. 3312-3318. [Referencia cruzada]

42. Parque, Y.S.; Jang, H.; Kim, A. I-LOAM: Odometría y mapeo LiDAR de intensidad mejorada. En Actas de la 17ª Conferencia Internacional sobre Robots Ubicuos (UR) de 2020, Kioto, Japón, 15-18 de julio de 2020; pp. 455-458. [Referencia cruzada]

43. Lamarca, J.; Parashar, S.; Bartoli, A.; Montiel,J.M.M. DefSLAM: Seguimiento y Mapeo de Escenas Deformantes de Secuencias Monoculares.IEEE Trans. Robot. 2021,37,291-303.[CrossRef]

44. Ahmadi, M.; Naeini, A.A.; Sheikholeslami, M.M.; Arjmandi, Z.; Zhang, Y.; Sohn, G.HDPV-SLAM: SLAM VISUAL PANORÁMICO HÍBRIDO AUMENTADO EN PROFUNDIDAD PARA SISTEMA DE MAPEO MÓVIL CON LIDAR INCLINADO Y Camera.In visual panorámico Actas de la 19ª Conferencia Internacional IEEE 2023 sobre Ciencia e Ingeniería de la Automatización (CASE), Auckland, Nueva Zelanda, 22-25 de agosto de 2023; págs. 1-8. [Referencia cruzada]

45.Maddern, W.; Milford, M.; Wyeth, G. SLAM de trayectoria continua basada en la apariencia. En Actas de la Conferencia Internacional IEEE 2011 sobre Robótica y Automatización, Shanghái, China, 9-13 de mayo de 2011; pp. 3595-3600. [Referencia cruzada]

46. Zou, D.; Tan,P.CoSLAM: SLAM visual colaborativo en entornos dinámicos. IEEE Trans. Patrón Anal. Mach. Intell. 2013,35,354-366.[CrossRef]

47.Bescos, B.; Campos, C.; Tardós, J.D.; Neira, J. DynaSLAM II: Seguimiento multiobjeto estrechamente acoplado y SLAM. IEEE Robotics Autom. Lett. 2021, 6,5191-5198. [CrosRef]

48. Joo, K.; Kim, P.; Hebert, M.; Kweon, I.S.; Kim,H.J.Linear RGB-D SLAM para entornos estructurados. Patrón IEEE Trans. Anal.Mach.Intell.2022,44,8403-8419. [Referencia cruzada]

49. Kerl, C.; Sturm, J.; Cremers, D. SLAM visual denso para cámaras RGB-D. En Actas de la Conferencia Internacional IEEE/RSJ 2013 sobre Robots y Sistemas Inteligentes, Tokio, Japón, 3-7 de noviembre de 2013; págs. 2100-2106. [Referencia cruzada]

50. Sturm, J.; Engelhard, N.; Endres, F.; Burgard, W.; Cremers, D. Un punto de referencia para la evaluación de sistemas SLAM RGB-D. En Actas de la Conferencia Internacional IEEE/RSJ 2012 sobre Robots y Sistemas Inteligentes, Vilamoura-Algarve, Portugal, 7-12 de octubre de 2012; pp. 573-580. [Referencia cruzada]

51. Ma,L.; Kerl,C.; Stückler, J.; Cremers,D.CPA-SLAM: Alineación consistente de plano-modelo para RGB-D slam directo. En Actas de la Conferencia Internacional IEEE 2016 sobre Robótica y Automatización (ICRA), Estocolmo, Suecia, 16-21 de mayo de 2016; pp. 1285-1291. [Referencia cruzada]

52. Yu,C.; Liu, Z.; Liu, X.-J.; Xie, F.; Yang, Y.; Wei, Q.; Fei, Q. DS-SLAM: Un SLAM visual semántico hacia el Environments.In dinámico Actas de la Conferencia Internacional IEEE/RSJ 2018 sobre Robots y Sistemas Inteligentes (IROS), Madrid, España, 1-5 de octubre de 2018; págs. 1168-1174. [Referencia cruzada]

53.Blochliger, F.; Fehr, M.; Dymczyk, M.; Schneider, T.; Siegwart, R. Mapa topológico: cartografía topológica y navegación basada en mapas visuales SLAM. En Actas de la Conferencia Internacional IEEE 2018 sobre Robótica y Automatización (ICRA), Brisbane, QLD, Australia, 21-25 de mayo de 2018; págs. 3818-3825. [Referencia cruzada]

54. Laidlow, T.; Czarnowski, J.; Leutenegger, S. DeepFusion: Reconstrucción 3D densa en tiempo real para SLAM monocular utilizando predicciones de profundidad y gradiente de vista única. En Actas de la Conferencia Internacional sobre Robótica y Automatización (ICRA) de 2019, Montreal, QC, Canadá, 20-24 de mayo de 2019; págs. 4068-4074. [Referencia cruzada]

55. Wasenmüller, O.; Meyer, M.; Stricker, D.CoRBS: Punto de referencia RGB-D completo para SLAM usando Kinect v2. En Actas de la Conferencia de Invierno del IEEE 2016 sobre Aplicaciones de la Visión por Computador (WACV), Lake Placid, NY, EE. UU., 7-10 de marzo de 2016; págs.1-7. [Referencia cruzada]

56. Nicholson, L.; Milford, M.; Sünderhauf, N.QuadricSLAM: Quadrics duales de detecciones de objetos como puntos de referencia en SLAM orientado a objetos. Robot IEEE. Autom. Lett. 2019,4,1-8. [Referencia cruzada]

57. Salas-Moreno, R.F.; Newcombe, R.A.; Strasdat, H.; Kelly, P.H.J.; Davison, A.J. SLAM++: Localización y mapeo simultáneos a nivel de objetos. En Actas de la Conferencia IEEE 2013 sobre Visión por Computadora y Reconocimiento de Patrones, Portland, Oregón, EE. UU., 23-28 de junio de 2013; pp. 1352-1359. [Referencia cruzada]

58. Ibragimov, I.Z.; Afanasyev, I.M.Comparación de los métodos SLAM visuales basados en ROS en un entorno interior homogéneo. En Actas del 14° Taller de Posicionamiento, Navegación y Comunicaciones (WPNC) de 2017, Bremen, Alemania, 22-23 de noviembre de 2017; págs. 1-6. [Referencia cruzada]

59. Liu, Y.; Miura, J. RDMO-SLAM: Slam visual en tiempo real para entornos dinámicos mediante predicción de etiquetas semánticas con flujo óptico. Acceso IEEE 2021,9,106981-106997. [Referencia cruzada]

60. Sol, Y.; Liu, M.; Meng, M.Q.H. Eliminación de movimiento para un SLAM RGB-D fiable en entornos dinámicos. Robot. Auton. Sistema 2018,108,115-128. [Referencia cruzada]

61. Chen, W.; Zhou, C.; Shang, G.; Wang, X.; Li, Z.; Xu, C.; Hu, K. Descripción general de SLAM: de un solo sensor a una fusión heterogénea.Remote Sens. 2022, 14, 6033. [Referencia cruzada]

62. Yang, S.; Canción, Y.; Kaess, M.; Scherer,S.Pop-up SLAM: plano monocular semántico SLAM para entornos de baja textura. En Actas de la Conferencia Internacional IEEE/RSJ 2016 sobre Robots y Sistemas Inteligentes (IROS), Daejeon, República de Corea, 9-14 de octubre de 2016; págs. 1222-1229. [Referencia cruzada]

63. Deschaud, J.-E. IMLS-SLAM: Coincidencia de escaneo a modelo basada en datos 3D. En Actas de la Conferencia Internacional IEEE 2018 sobre Robótica y Automatización (ICRA), Brisbane, QLD, Australia, 21-25 de mayo de 2018; págs. 2480-2485. [Referencia cruzada]

64. Xu, Y.; Ou, Y.; Xu, T. SLAM de robot basado en la fusión de visión y LIDAR. En Actas de la Conferencia Internacional IEEE 2018 sobre Cyborg y Sistemas Biónicos (CBS), Shenzhen, China, 31 de octubre-3 de noviembre de 2018; pp. 121-126. [Referencia cruzada]

65. Pumarola, A.; Vakhitov, A.; Agudo, A.; Sanfeliu, A.; Moreno-Noguer, F. PL-SLAM: SLAM visual monocular en tiempo real con puntos y líneas. En Actas de la Conferencia Internacional IEEE 2017 sobre Robótica y Automatización (ICRA), Singapur, 29 de mayo-3 de junio de 2017; pp. 4503-4508. [Referencia cruzada]

66. Newcombe, R.A.; Fox, D.; Seitz, S.M. DynamicFusion: reconstrucción y seguimiento de escenas no rígidas en tiempo real. En Actas de la Conferencia IEEE 2015 sobre Visión por Computador y Reconocimiento de Patrones (CVPR), Boston, MA, EE. UU., 7-12 de junio de 2015; págs. 343-352. [Referencia cruzada]

67. Ji,T.; Wang, C.; Xie, L. Hacia el SLAM semántico RGB-D en tiempo real en entornos dinámicos. En Actas de la Conferencia Internacional IEEE 2021 sobre Robótica y Automatización (ICRA), Xi'an, China, 30 de mayo-5 de junio de 2021; págs. 11175-11181. [Referencia cruzada]

68. Whelan, T.; Leutenegger, S.; Salas-Moreno, R.F.; Glocker, B.; Davison, A.J. ElasticFusion: Dense SLAM without a Pose Graph.In Proceedings of the Robotics: Science and Systems, Roma, Italia, 12-16 de julio de 2015; MIT Press: Cambridge, MA, EE. UU., 2015; Volumen 11. [Referencia cruzada]

69.Li,R.; Wang, S.; Gu,D.DeepSLAM: Un robusto sistema SLAM monocular con aprendizaje profundo no supervisado. IEEE Trans. Ind.Electron. 2021, 68,3577-3587. [Referencia cruzada]

70. Mur-Artal, R.; Tardós, J.D., Mapeo semidenso probabilístico de SLAM.In monocular basado en características de alta precisión, Actas de la Robótica: Ciencia y Sistemas, Roma, Italia, 12-16 de julio de 2015. [Referencia cruzada]

71. Burgard, W.; Stachniss, C.; Grisetti, G.; Steder, B.; Kummerle, R.; Dornhege, C.; Ruhnke, M.; Kleiner, A.; Tardos, J.D. Una comparación de algoritmos SLAM basada en un gráfico de relaciones. En Actas de la Conferencia Internacional IEEE/RSJ 2009 sobre Robots y Sistemas Inteligentes, St. Louis, MO, EE.UU., 10-15 de octubre de 2009; págs. 2089-2095. [Referencia cruzada]

72. Shan, T.; Englot, B.; Ratti, C.; RUS, D. LVI-SAM: Odometría Lidar-visual-inercial estrechamente acoplada mediante suavizado y mapeo. En Actas de la Conferencia Internacional IEEE 2021 sobre Robótica y Automatización (ICRA), Xi'an, China, 30 de mayo-5 de junio de 2021; págs. 5692-5698. [Referencia cruzada]

73. Sturm, J.; Magnenat, S.; Engelhard, N.; Pomerleau, FE.; Colas, F.; Cremers, D.; Siegwart, R.; Burgard, W. Hacia un punto de referencia para la evaluación de SLAM RGB-D. En Actas del Taller RGB-D sobre Razonamiento Avanzado con Cámaras de Profundidad en la Conferencia de Robótica: Ciencia y Sistemas (RSS), Los Ángeles, CA, EE.UU., 27 de junio-1 de julio de 2011.

74. Greene, W.N.; Ok,K.; Lommel, P.; Roy, N. Mapeo multinivel: SLAM.In monocular denso en tiempo real Actas de la Conferencia Internacional IEEE 2016 sobre Robótica y Automatización (ICRA), Estocolmo, Suecia, 16-21 de mayo de 2016; pp. 833-840. [Referencia cruzada]

75. Sucar, E.; Liu, S.; Ortiz, J.; Davison, A.J. iMAP: Mapeo implícito y posicionamiento en tiempo real. En Actas de la Conferencia Internacional sobre Visión por Computador (ICCV) 2021IEEE/CVF, Montreal, QC, Canadá, 11-17, 17 de octubre de 2021;pp. 6209-6218. [Referencia cruzada]

76. Vicente, J.; Labbé, M.; Lauzon, J.-S.; Grondin, E.; Comtois-Rivet, P.-M.; Michaud, F. Seguimiento dinámico de objetos y enmascaramiento para SLAM.In visual Actas de la Conferencia Internacional IEEE / RSJ 2020 sobre Robots y Sistemas Inteligentes (IROS), Las Vegas, NV, EE. UU., 24-27 de octubre de 2020; págs. 4974-4979. [Referencia cruzada]

77. Forster, C.; Pizzoli, M.; Scaramuzza, D.SVO:Odometría visual monocular semidirecta rápida. En Actas de la Conferencia Internacional IEEE 2014 sobre Robótica y Automatización (ICRA), Hong Kong, China, 31 de mayo-7 de junio de 2014; págs. 15-22. [Referencia cruzada]

78. Mur-Artal, R.; Tardós, J.D. ORB-SLAM2: Un sistema SLAM de código abierto para cámaras monoculares, estéreo y RGB-D. IEEE Trans.Robot. 2017,33,1255-1262. [Referencia cruzada]

79. Nardi, L.; Bodin, B.; Zia, M.Z.; Mawer, J.; Nisbet, A.; Kelly, P.H.J.; Davison, A.J.; Luján, M.; O'Boyle, M.F.P.; Riley, G.; et al. Presentamos SLAMBench, una metodología de evaluación comparativa de rendimiento y precisión para SLAM. En Actas de la Conferencia Internacional IEEE 2015 sobre Robótica y Automatización (ICRA), Seattle, WA, EE. UU., 26-30 de mayo de 2015; págs. 5783-5790. [Referencia cruzada]

80. Yan, J.; Zheng, Y.; Yang, J.; Mihaylova, L.; Yuan, W.; Gu,F.PLPF-VSLAM: Un SLAM visual de interior con fusión adaptativa de características de punto-línea-plano. J.Robot de campo. 2024,41,50-67.[CrossRef]

81. Mur-Artal, R.; Tardós,J.D.SLAM Monocular Visual-Inercial con Reutilización de Mapas. Robot IEEE. Autom. Lett. 2017,2,796-803. [Referencia cruzada]

82. Zhu, Z.; Peng, S.; Larsson, V.; Xu, W.; Bao, H.; Cui, Z.; Oswald, M.R.; Pollefeys, M. NICE-SLAM: Codificación escalable implícita neuronal para SLAM.In Actas de la Conferencia IEEE/CVF 2022 sobre Visión por Computadora y Reconocimiento de Patrones (CVPR), Nueva Orleans, LA, EE. UU., 19-24 de junio de 2022; págs. 12776-12786. [Referencia cruzada]

83. Chen, G.; Hong, L. Investigación sobre el sistema de percepción del entorno de robots cuadrúpedos basado en LiDAR y visión. Drones 2023,7,329. [Referencia cruzada]

84. Mur-Artal, R.; Montiel, J.M.M.; Tardós,J.D.ORB-SLAM: Un sistema SLAM monocular versátil y preciso. IEEE Trans. Robot.2015,31,1147-1163. [Referencia cruzada]

85. Frosi, M.; Matteucci, M. ART-SLAM: SLAM LiDAR 6DoF preciso en tiempo real. Robot IEEE. Autom. Letra 2022,7,2692-2699. [Referencia cruzada]

86.Gálvez-López, D.; Salas, M.; Tardós, J.D.; Montiel, J.M.M. Objeto monocular en tiempo real SLAM. Robot. Auton. Sistema 2016,75,435-449. [Referencia cruzada]

87. Chaplot, D.S.; Gandhi, D.; Gupta, S.; Gupta, A.; Salakhutdinov, R. Aprender a explorar mediante el uso de SLAM.In neuronal activo, Actas de la 8ª Conferencia Internacional sobre Representaciones del Aprendizaje (ICLR 2020), Addis Abeba, Etiopía, 26-30 de abril de 2020. [Referencia cruzada]

88. Chen, X.; Läbe, T.; Milioto, A.; Röhling, T.; Vysotska, O.; Haag, A.; Behley, J.; Stachniss, C. OverlapNet: Cierre de bucle para SLAM basado en LiDAR. arXiv 2021,arXiv:2105.11344. [Referencia cruzada]

89. Teed, Z.; Deng,J.DROID-SLAM: SLAM VISUAL PROFUNDO para cámaras monoculares, estéreo y RGB-D. Proceso Inf. Neuronal. Sistema 2021,34,16558-16569. [Referencia cruzada]

90. Bruno, H.M.S.; Colombini, E.L. LIFT-SLAM: Un método SLAM visual monocular basado en características de aprendizaje profundo.Neurocomputing 2021,455,97-110. [Referencia cruzada]

91. Ai, Y.; Rui, T.; Lu, M.; Fu, L.; Liu, S.; Wang, S. DDL-SLAM: Un robusto SLAM RGB-D en entornos dinámicos combinado con aprendizaje profundo. Acceso IEEE 2020, 8, 162335-162342. [Referencia cruzada]

92. Chung, C.-M.; Tseng, Y.-C.; Hsu, Y.-C.; Shi, X.-Q.; Hua, Y.-H.; Yeh, J.-E.; Chen, W.-C.; Chen, Y.-T.; Hsu, W.H. Orbeez-SLAM: Un SLAM visual monocular en tiempo real con características ORB y mapeo realizado por NeRF. En Actas de la Conferencia Internacional sobre Robótica y Automatización (ICRA) del IEEE 2023, Londres, Reino Unido, 29 de mayo-2 de junio de 2023; págs. 9400-9406. [Referencia cruzada]

93. Zhu, Z.; Peng, S.; Larsson, V.; Cui, Z.; Oswald, M.R.; Geiger, A.; Pollefeys,M. NICER-SLAM: Codificación de escenas implícitas neuronales para RGB SLAM.In Actas de la Conferencia Internacional sobre Visión 3D 2024 (3DV), Davos, Suiza, 9-12 de septiembre de 2024;pp. 42-52. [Referencia cruzada]

94. Huang, B.; Zhao, J.; Liu,J. Un estudio de localización y mapeo simultáneos con una visión en redes inalámbricas 6G.J.Glob. Posición. Sistema 2021, 17, 206-236. [Referencia cruzada]

95. Shu, F; Lesur, P.; Xie, Y.; Pagani, A.; Stricker, D. SLAM en el campo: una evaluación del mapeo monocular y la localización en Environment.In agrícolas dinámicas desafiantes Actas de la Conferencia de Invierno IEEE 2021 sobre Aplicaciones de la Visión por Computadora (WACV), Waikoloa, HI, EE. UU., 5-9 de enero de 2021; págs. 1760-1770. [Referencia cruzada]

96. Schöps, T.; Sattler, T.; Pollefeys, M.BAD SLAM:Bundle Adjusted Direct RGB-D SLAM.In Actas de la Conferencia IEEE/CVF 2019 sobre Visión por Computadora y Reconocimiento de Padres (CVPR), Long Beach, CA, EE. UU., 16-20 de junio de 2019; págs. 134-144. [Referencia cruzada]

97. Keetha, N.; Karhade, J.; Jatavallabhula, K.M.; Yang, G.; Scherer, S.; Ramanan, D.; Luiten, J. SplaTAM: Splat, Track & Map 3D Gaussians for Dense RGB-D SLAM.In Actas de la Conferencia IEEE/CVF 2024 sobre Visión por Computadora y Reconocimiento de Patrones (CVPR), Seattle, WA, EE. UU., 16-20 de junio de 2024; págs. 21357-21366. [Referencia cruzada]

98. Kim, G.; Kim,A.LT-mapper: Un marco modular para el mapeo de por vida basado en LiDAR. En Actas de la Conferencia Internacional sobre Robótica y Automatización (ICRA) de 2022, Filadelfia, PA, EE. UU., 23-27 de mayo de 2022; págs. 7995-8002. [Referencia cruzada]

99. Tiwari, L.; Ji, P.; Tran, Q.H.; Zhuang, B.; Anand, S.; Chandraker, M. Pseudo RGB-D para la mejora automática del SLAM monocular y la predicción de profundidad. En Visión por Computador-ECCV 2020; Vedaldi, A., Bischof, H., Brox, T., Frahm, J.M., Eds.; Apuntes de Cátedra de Ciencias de la Computación; Springer: Cham, Suiza, 2020; Tomo 12356, pp. 437-455. [Referencia cruzada]

Descargo de responsabilidad/Nota del editor: Las declaraciones, opiniones y datos contenidos en todas las publicaciones son únicamente los del autor (s) y colaborador (s) individual (s) y no de MDPI y / o el editor (s). MDPI y/o el/los editor/es renuncian a la responsabilidad por cualquier daño a personas o propiedad que resulte de cualquier idea, método, instrucción o producto al que se haga referencia en el contenido.